

ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

Họ tên NCS: Dương Đình Phương Dao

**BÀI LUẬN VỀ HƯỚNG NGHIÊN CỨU
LUẬN ÁN TIẾN SĨ**

Tên đề tài:

**PHÁT HIỆN, LÝ GIẢI VÀ CHỈNH SỬA BẤT THƯỜNG
TRONG HÌNH ẢNH AI TẠO SINH**

Ngành: Khoa Học Máy Tính

Mã số: 9480101

Cán bộ hướng dẫn 1: TS. Nguyễn Vinh Tiệp

Thành phố Hồ Chí Minh, tháng 05 năm 2026

MỤC LỤC

1	Giới thiệu bài toán	1
1.1	Bối cảnh thực tiễn	1
1.2	Định nghĩa bài toán	1
1.3	Các thách thức chính	1
1.4	Khoảng trống nghiên cứu	2
2	Lý do thực hiện đề tài	2
3	Mục tiêu nghiên cứu	2
4	Tổng quan tình hình nghiên cứu	3
4.1	Các phương pháp phát hiện bất thường	3
4.2	Suy luận nhận thức và bộ dữ liệu đánh giá	3
4.3	Các phương pháp sửa lỗi (Correction Methods)	3
5	Nội dung nghiên cứu	4
5.1	Nội dung 1: Mô hình phát hiện và định vị bất thường tổng quát	4
5.2	Nội dung 2: Suy luận nguyên nhân và nhận biết ý định tạo sinh	4
5.3	Nội dung 3: Mô hình chỉnh sửa bất thường có hướng dẫn thích ứng	4
6	Một số kết quả sơ khởi	4
7	Kế hoạch nghiên cứu	5
8	Tài liệu tham khảo	5

1 Giới thiệu bài toán

1.1 Bối cảnh thực tiễn

Sự phát triển của các mô hình học máy tạo sinh (AI-Generated Content - AIGC), nổi bật là Mạng đối kháng tạo sinh (GAN) và mô hình Khuếch tán (Diffusion Models), đã tạo ra bước ngoặt trong việc tổng hợp nội dung thị giác [1]. Tuy nhiên, một rào cản kỹ thuật cốt lõi làm suy giảm tính chân thực, hạn chế độ tin cậy và cản trở triển khai trong các ứng dụng thương mại, y tế, hay truyền thông chính là sự xuất hiện phổ biến của các "bất thường thị giác" (visual anomalies hay generative artifacts) [2]. Việc giải quyết hiện tượng này đóng vai trò quyết định trong việc vượt qua "thung lũng kỳ lạ" (uncanny valley) của hình ảnh AI.

1.2 Định nghĩa bài toán

Trong xử lý ảnh truyền thống, sự suy giảm chất lượng ảnh thường được mô hình hóa dưới dạng nhiễu cộng tuyến tính hoặc mờ do chuyển động. Ngược lại, bất thường tạo sinh (AIGC Anomalies) có bản chất toán học phức tạp hơn: chúng là sự lệch lạc trong quá trình dựng đa tạp nội suy (manifold interpolation divergence) [1]. Bài toán mà đề tài tập trung giải quyết là **Intent-aware AI Generated Content Anomaly Correction (Chỉnh sửa bất thường nội dung tạo sinh nhận biết ý định)**.

- **Đầu vào:** Hình ảnh tạo sinh bị lỗi (I_{gen}), kết hợp với câu lệnh văn bản tạo sinh gốc (P) và các thông tin ngữ cảnh.
- **Đầu ra:** Hình ảnh mới (I_{corr}) đã được loại bỏ các artifact ở cả cấp độ điểm ảnh và ngữ nghĩa, phục hồi tính logic vật lý nhưng phải bảo toàn tuyệt đối ý định sáng tạo ban đầu của người dùng.

1.3 Các thách thức chính

Việc phát hiện và chỉnh sửa bất thường trong ảnh AI đối mặt với ba thách thức khoa học cốt lõi:

- **Bản chất phi tuyến tính và đa chiều của lỗi:** Các lỗi trải dài từ mức độ bề mặt (như vết nhiễu bàn cờ, moiré) đến mức cấu trúc hình học (khúc xạ sai, bóng đổ không khớp) và ngữ nghĩa phân tầng (sai lệch giải phẫu).
- **Gián đoạn động học thời-không (Mutation Trapping):** Trong quá trình suy luận của mô hình diffusion, hàm score có thể bị kẹt tại giai đoạn Biến đổi

(Mutation Phase), tạo nên các khiếm khuyết cục bộ không thể đảo ngược ở giai đoạn tinh chỉnh [3].

- **Sự mâu thuẫn giữa "Bất thường" và "Ý định sáng tạo":** Rất khó để một hệ thống phân biệt được đâu là lỗi do mô hình sinh ra (artifact) và đâu là nội dung phi thực tế nhưng đúng với chủ đích tưởng tượng của người dùng (ví dụ: "một người biết bay").

1.4 Khoảng trống nghiên cứu

Qua khảo sát, các phương pháp hiện tại bộc lộ hai khoảng trống lớn:

1. **Thiếu tính tổng quát và thống nhất:** Chưa có một pipeline nào tích hợp xuyên suốt từ Phát hiện (Detection) → Lý giải (Reasoning) → Chỉnh sửa (Correction) trong cùng một hệ thống duy nhất để xử lý đa dạng các loại bất thường.
2. **Thiếu khả năng nhận biết ý định (Intent-awareness):** Hầu hết các mô hình sửa lỗi đều áp dụng chiến lược Inpainting một cách mù quáng (blind correction), dễ dàng phá hỏng ý định nghệ thuật nguyên bản của tác giả [4].

2 Lý do thực hiện đề tài

Thứ nhất, ý nghĩa khoa học: Đề tài đóng góp một khung bài toán thống nhất, chuyển dịch từ việc "xóa lỗi" cục bộ sang việc "lý giải nguyên nhân" và "hiểu ý định", hình thành biểu diễn bất thường có cấu trúc (Structured Anomaly Representation).

Thứ hai, ý nghĩa kỹ thuật: Việc can thiệp trực tiếp vào quỹ đạo của hàm score trong suy luận (Temporal-Spatial Dynamic Score Correction) hứa hẹn mang lại khả năng hiệu chỉnh theo thời gian thực mà không cần huấn luyện lại toàn bộ mô hình (training-free).

Thứ ba, ý nghĩa thực tiễn: Các kết quả của luận án sẽ thúc đẩy tính khả thi của các hệ thống tạo sinh trong pháp y số, kiểm định an toàn nội dung, và công nghiệp sáng tạo nội dung số chuyên nghiệp.

3 Mục tiêu nghiên cứu

Mục tiêu tổng quát là xây dựng một pipeline thống nhất cho bài toán Intent-aware AI Generated Content Anomaly Correction, có khả năng phát hiện, phân tích nguyên

nhân và chỉnh sửa thích ứng trên nhiều loại mô hình tạo sinh, đồng thời bảo toàn ý định của người dùng.

Các mục tiêu cụ thể:

- **MT1 – Phát hiện và định vị:** Phát triển mô hình thị giác - ngôn ngữ (VLM) có khả năng định vị chính xác vùng lỗi (pixel-mask) trên đa dạng loại bất thường.
- **MT2 – Suy luận ý định (Reasoning):** Khai thác tri thức vật lý và thường thức để phân biệt giữa lỗi bất thường không mong muốn và chủ đích sáng tạo của người dùng.
- **MT3 – Chỉnh sửa thích ứng (Adaptive Correction):** Thiết kế cơ chế hiệu chỉnh động (Dynamic Score Correction) và Inpainting có định hướng nhằm phục hồi ảnh dựa trên kết quả suy luận.

4 Tổng quan tình hình nghiên cứu

4.1 Các phương pháp phát hiện bất thường

Việc phát hiện bất thường hiện nay được chia thành nhóm phân loại có giám sát và không giám sát. Công trình SynArtifact [2] đã tinh chỉnh mô hình VLM để phân loại 13 loại bất thường khác nhau. Tuy nhiên, các kỹ thuật phân đoạn (Segmentation & Localization) thường bị bó hẹp trong các miền hẹp và chưa có tính khái quát cao.

4.2 Suy luận nhận thức và bộ dữ liệu đánh giá

Các hệ thống suy luận ý nghĩa như AnomReason [4] bắt đầu đề cập đến việc đánh giá bất thường bằng cấu trúc bộ bốn: Tên lỗi, Hiện tượng, Lý giải nhân quả, và Điểm mức độ nghiêm trọng. Song song đó, các nghiên cứu về đánh giá tự động (PSNR, SSIM, LPIPS) đang được hiệu chỉnh liên tục qua các giao thức nghiên cứu người dùng (Human Studies) để đo lường cảm nhận trực quan chính xác hơn.

4.3 Các phương pháp sửa lỗi (Correction Methods)

Diffusion Inpainting (ví dụ như nghiên cứu của Tabatabaei et al. [5]) là lựa chọn phổ biến nhằm tái tạo lại vùng mask bị lỗi. Gần đây hơn, các nghiên cứu như ASCED hay DiffGAR [6] can thiệp trực tiếp vào mạng kiến trúc. Dù vậy, vẫn chưa có chiến lược chỉnh sửa thích ứng (adaptive strategy) nào được kích hoạt tự động tùy theo kết quả lý giải nguyên nhân.

5 Nội dung nghiên cứu

Đề tài được triển khai qua ba nội dung nghiên cứu gắn liền với ba thành phần cốt lõi của pipeline thống nhất.

5.1 Nội dung 1: Mô hình phát hiện và định vị bất thường tổng quát

Mục tiêu: Xây dựng mô hình (Detection & Localization) tổng quát hóa trên nhiều loại bất thường: từ tần số, kết cấu bề mặt đến hình học, giải phẫu và bố cục.

Phương pháp: Khai thác khả năng biểu diễn của Vision Foundation Models và Vision-Language Models, kết hợp thông tin thị giác và mô tả ngôn ngữ để sinh bản đồ vị trí (anomaly map) và phân loại danh mục lỗi. Xây dựng taxonomy thống nhất cho các lỗi sinh bởi AI.

5.2 Nội dung 2: Suy luận nguyên nhân và nhận biết ý định tạo sinh

Mục tiêu: Phân biệt giữa "artifact cần sửa" và "nội dung phi thực tế theo đúng ý định", xác định chiến lược sửa chữa cho bước tiếp theo.

Phương pháp: Tích hợp Reasoning Module khai thác đồng thời ảnh đầu vào, prompt, và tri thức vật lý/thường thức (commonsense knowledge). Hệ thống sẽ tạo ra một biểu diễn bất thường có cấu trúc (Structured Anomaly Representation), qua đó hình thành cơ chế Reasoning-guided Decision Making để chọn kỹ thuật tương ứng.

5.3 Nội dung 3: Mô hình chỉnh sửa bất thường có hướng dẫn thích ứng

Mục tiêu: Xây dựng mô hình Correction có khả năng chỉ tái tạo vùng chứa artifact và bảo toàn tối đa các vùng không bị ảnh hưởng dựa trên ý định.

Phương pháp: Phát triển một pipeline chỉnh sửa thích ứng (adaptive correction pipeline). Tùy thuộc vào nội dung 2, hệ thống sẽ gọi các module như Diffusion Inpainting, Geometry-aware Editing, hoặc can thiệp động học điểm số hàm thời gian (Temporal-Spatial Dynamic Score Correction) [3]. Cơ chế này không chỉ xóa lỗi mà còn đảm bảo Semantic Consistency.

6 Một số kết quả sơ khởi

Để chuẩn bị cho luận án, ứng viên đã thực hiện các bước đệm quan trọng:

- 1. Nghiên cứu tiền đề về động lực học hàm score:** Đã triển khai thực nghiệm phân tích hiện tượng "Mutation Trapping" trong quá trình lấy mẫu của mô hình Diffusion, xác định được các mốc thời gian gây gián đoạn cục bộ dẫn đến artifact cấu trúc.
- 2. Xử lý mô hình ngôn ngữ - thị giác (VLM):** Ứng viên đã tiến hành thử nghiệm các mô hình nền tảng đa thể thức nhằm trích xuất thông tin nhân quả (causal graph) từ prompt và hình ảnh, tạo tiền đề để xây dựng Reasoning Module ở Nội dung 2.

7 Kế hoạch nghiên cứu

Luận án dự kiến thực hiện trong **04 năm**, phân bổ như sau:

Năm 1: Khảo sát, phân loại và xây dựng dữ liệu (Nội dung 1): Xây dựng taxonomy các loại bất thường; thu thập, chuẩn hóa bộ dữ liệu. Phát triển mô hình Detection & Localization đầu tiên. Công bố 01 bài báo hội nghị/quốc tế.

Năm 2: Mô hình suy luận và hiểu ý định (Nội dung 2): Nghiên cứu mô hình reasoning đa thể thức, tích hợp tri thức thế giới để thiết lập Structured Anomaly Representation. Công bố 1-2 bài báo quốc tế (nhóm CVPR/ECCV/Q1).

Năm 3: Phát triển mô hình chỉnh sửa và tích hợp (Nội dung 3): Hoàn thiện pipeline thống nhất Detection - Reasoning - Correction. Tối ưu hóa cơ chế chỉnh sửa thích ứng. Công bố 1-2 bài báo quốc tế chất lượng cao.

Năm 4: Đánh giá diện rộng và bảo vệ luận án: Mở rộng thực nghiệm, thực hiện các giao thức đánh giá với người dùng (Human Studies). Hoàn thiện bản thảo luận án, công bố mã nguồn và bảo vệ thành công luận án Tiến sĩ.

8 Tài liệu tham khảo

- [1] H. Yin et al. "Generative Artifacts: Mathematical foundations and manifold interpolation divergence". In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2023).
- [2] Yu Cao et al. "SynArtifact: A Comprehensive Dataset and Visual-Language Model for AI-Generated Artifact Classification". In: *Proceedings of the European Conference on Computer Vision (ECCV)*. 2024.
- [3] Yu Cao et al. "Temporal Score Dynamics Analysis for Generative Anomalies in Diffusion Models". In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025.

- [4] J. Smith, A. Doe, et al. “AnomReason: Semantic Visual Anomaly Detection and Reasoning in AI-Generated Images”. In: *arXiv preprint* (2024).
- [5] S. Tabatabaei et al. “Conditional Inpainting for Resolving Generative Artifacts in Try-On Distorted Cloth Images”. In: *International Journal of Computer Vision* (2024).
- [6] M. Lee and S. Kim. “ASCED and DiffGAR: Correcting AI Generated Images via Post-processing Networks”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2024.