

ĐẠI HỌC QUỐC GIA TP.HCM  
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

Họ tên NCS: Dương Đình Phương Dao

**BÀI LUẬN VỀ HƯỚNG NGHIÊN CỨU  
LUẬN ÁN TIẾN SĨ**

Tên đề tài:

**NGHIÊN CỨU CÁC PHƯƠNG PHÁP Suy Luận Nâng Cao  
VÀ CẢI THIỆN CHẤT LƯỢNG NỘI DUNG DO TRÍ TUỆ NHÂN TẠO (AI)  
TẠO SINH**

Ngành: Khoa Học Máy Tính

Mã số: 9480101

Cán bộ hướng dẫn 1: TS. Nguyễn Vinh Tiệp

Thành phố Hồ Chí Minh, tháng 05 năm 2026

## MỤC LỤC

|     |                                                                                                                      |    |
|-----|----------------------------------------------------------------------------------------------------------------------|----|
| 1   | Giới thiệu bài toán . . . . .                                                                                        | 1  |
| 1.1 | Bối cảnh nghiên cứu . . . . .                                                                                        | 1  |
| 1.2 | Định nghĩa bài toán . . . . .                                                                                        | 1  |
| 1.3 | Khoảng trống và động lực nghiên cứu . . . . .                                                                        | 2  |
| 2   | Mục tiêu nghiên cứu . . . . .                                                                                        | 4  |
| 3   | Tổng quan tình hình nghiên cứu . . . . .                                                                             | 5  |
| 3.1 | Các phương pháp phát hiện bất thường (Detection Methods) . . . . .                                                   | 5  |
| 3.2 | Các phương pháp sửa lỗi (Correction Methods) . . . . .                                                               | 6  |
| 3.3 | Bộ dữ liệu và các thước đo đánh giá . . . . .                                                                        | 8  |
| 4   | Nội dung nghiên cứu . . . . .                                                                                        | 9  |
| 4.1 | Nội dung 1: Xây dựng hệ thống tổng quát cho bài toán phát hiện và hiệu chỉnh bất thường một cách trực quan . . . . . | 9  |
| 4.2 | Nội dung nghiên cứu 2: Tích hợp cơ chế chỉnh sửa nhận biết ý định người dùng . . . . .                               | 9  |
| 4.3 | Nội dung nghiên cứu 3: Nghiên cứu cơ chế hiệu chỉnh ngay trong quá trình sinh ảnh . . . . .                          | 10 |
| 5   | Kế hoạch nghiên cứu . . . . .                                                                                        | 10 |
| 6   | Tài liệu tham khảo . . . . .                                                                                         | 11 |

## 1 Giới thiệu bài toán

### 1.1 Bối cảnh nghiên cứu

Trong những năm gần đây, sự phát triển mạnh mẽ của các mô hình học máy tạo sinh (AI-Generated Content - AIGC) đã tạo nên nhiều nội dung độc đáo. Trong đó, các mô hình nổi bật là Mạng đối kháng tạo sinh (Generative Adversarial Networks - GANs) [1] và đặc biệt là mô hình Khuếch tán (Diffusion Models) [2] đã tạo ra một bước ngoặt vượt bậc trong việc tổng hợp nội dung thị giác. Dựa trên đó, các mô hình như Stable Diffusion [3], DALLÉ-3 [4], hay FLUX [5] đã thể hiện khả năng tạo sinh ra các hình ảnh có độ phân giải cao, nội dung phong phú và tiệm cận giống với ảnh thật. Nhờ đó, AIGC đang ngày càng được ứng dụng rộng rãi trong nhiều lĩnh vực đa dạng như quảng cáo, điện ảnh, trò chơi và sáng tạo nội dung số.

Mặc dù chất lượng ảnh sinh ra ngày càng được cải thiện đáng kể, không ít những nghiên cứu gần đây [6, 7] đã chỉ ra rằng ngày càng nhiều mô hình tiên tiến nhất vẫn thường xuyên tạo ra các chi tiết không hợp lý hoặc vi phạm các quy luật vật lý và ngữ nghĩa của thế giới thực. Những lỗi này vô hình chung sẽ làm giảm tính chân thực của hình ảnh, làm ảnh hưởng đến trải nghiệm của người dùng.

### 1.2 Định nghĩa bài toán

Trong nghiên cứu này, bất thường trong ảnh do AI tạo sinh (AI-generated image anomalies) được hiểu là những chi tiết, cấu trúc hoặc quan hệ không mong muốn hoặc không nhất quán xuất hiện trong ảnh được tạo bởi mô hình AI, làm suy giảm tính hợp lý của hình ảnh hoặc vi phạm các quy luật thị giác, cấu trúc, vật lý hay tri thức thông thường. Khái niệm này bao gồm cả các khiếm khuyết (artifact) ở mức thị giác (như mờ, răng cưa, kết cấu bất thường, biến dạng hình học, sai cấu trúc cơ thể hoặc lỗi văn bản) và các bất thường ở mức ngữ nghĩa (như cấu hình vật thể phi thực tế, quan hệ không gian không hợp lý, tương tác bất thường giữa các đối tượng, vi phạm quy luật vật lý và tri thức thông thường). Như vậy, bất thường được xem xét từ mức hình thức và cấu trúc của từng thành phần đến mức ngữ nghĩa và tính hợp lý của toàn bộ cảnh. Hình 1 minh họa một số điểm bất thường do mô hình tạo sinh sinh ra. Khái niệm này được tổng quát hóa từ các nghiên cứu phân tích về các dạng bất thường gần đây [8, 6]. Cụ thể, các nghiên cứu này định nghĩa phân loại bất thường xuất hiện ở nhiều cấp độ khác nhau, từ các lỗi cục bộ trên các pixel ảnh cho tới những sai lệch về cấu trúc và ngữ nghĩa của toàn bộ cảnh. Trong số các nhóm

trên, các lỗi về mặt ngữ nghĩa được xem là khó phát hiện và sửa chữa nhất vì chúng không thể được xác định chỉ bằng thông tin ở mức pixel mà đòi hỏi mô hình phải có khả năng suy luận về ngữ cảnh và tri thức thế giới.



Hình 1. Minh họa một số bất thường trong ảnh do AI tạo sinh.


Về mặt định nghĩa, bài toán hiệu chỉnh điểm bất thường được định nghĩa là quá trình tự động phát hiện, định vị và chỉnh sửa các bất thường xuất hiện trong nội dung hình ảnh được tạo bởi các mô hình AI, nhằm nâng cao tính chân thực và chất lượng thị giác của ảnh, đồng thời bảo toàn nội dung hợp lệ và ý định tạo sinh ban đầu của người dùng, xem thêm Hình 2. Cụ thể:

- **Đầu vào:** (1) Hình ảnh được tạo bởi mô hình AI, có thể chứa một hoặc nhiều bất thường. (2) Trong một số trường hợp, hệ thống cũng có thể khai thác thêm một số thông tin bổ sung như Prompt văn bản dùng để sinh ảnh từ người dùng.
- **Đầu ra:** (1) Xác định các điểm bất thường trong ảnh. (2) Định vị vị trí xuất hiện của từng bất thường. (3) Xác định nguyên nhân gây ra bất thường thông qua các suy luận. (4) Tạo sinh ảnh mới loại bỏ các bất thường không tuân theo ý định người dùng.

### 1.3 Khoảng trống và động lực nghiên cứu

Thông qua các khảo sát, các phương pháp hiện tại bộc lộ ba khoảng trống lớn:

- **Thứ nhất, thiếu một cơ chế hiệu chỉnh tổng quát cho toàn bộ các dạng bất thường.** Phần lớn các nghiên cứu hiện nay tập trung riêng vào phát hiện hoặc hiệu chỉnh một nhóm bất thường cụ thể. Đối với các artifact ở mức thấp, đã



Hình 2. Minh họa đầu vào (input) và đầu ra (output) của hệ thống một cách tổng quan.

có nhiều phương pháp hiệu chỉnh dựa trên tái tạo vùng ảnh (inpainting) [9], khuếch tán (diffusion) [10] hoặc các kỹ thuật hậu xử lý [11]. Tuy nhiên, các phương pháp này chủ yếu tập trung vào việc khôi phục kết cấu, hình học hoặc chất lượng thị giác của vùng ảnh bị lỗi và thường được thiết kế cho một loại artifact hoặc một miền ứng dụng cụ thể. Trong khi đó, đối với các **bất thường ở mức ngữ nghĩa**, các nghiên cứu hiện nay chủ yếu mới dừng ở phát hiện, định vị và giải thích, trong khi cơ chế tự động hiệu chỉnh các bất thường này vẫn chưa được khai thác và nghiên cứu.

- **Thứ hai, thiếu cơ chế trực quan hóa và định vị bất thường hiệu quả.** Phần lớn các phương pháp hiện nay tập trung vào việc đưa ra nhãn phân loại, điểm bất thường hoặc mô tả bằng ngôn ngữ dài dòng [12], trong khi thông tin trực quan về **vị trí chính xác của bất thường** vẫn còn hạn chế. Đặc biệt, đối với những cảnh có không gian phức tạp hoặc có nhiều đối tượng tương tự nhau, việc chỉ cung cấp một mô tả tổng quát khiến người dùng khó xác định nhanh chi tiết nào đang gặp vấn đề. Một cơ chế trực quan hóa kết hợp các thành phần như bounding box, segmentation mask hoặc anomaly map, có thể chỉ rõ vùng bất thường trên ảnh, đồng thời là bước trung gian quan trọng cung cấp thông tin đầu vào quan trọng cho bước hiệu chỉnh tiếp theo.
- **Thứ ba, tất cả các hướng tiếp cận cho bài toán đều thiếu đi khả năng nhận biết ý định của người dùng.** Các hệ thống hiện tại đều áp dụng các quy tắc

“thường thức” (common-sense) để đánh giá các điểm bất thường trong ảnh tạo sinh để “ép” hình ảnh về trạng thái “bình thường”. Điều này vô tình bỏ quên đi ý định tạo sinh ảnh ban đầu của người dùng, nơi chứa đựng các yếu tố sáng tạo, ý định nghệ thuật nguyên bản của tác giả.

Nhìn chung, bài toán phát hiện và chỉnh sửa các bất thường trong ảnh tạo sinh không đơn thuần là một bài toán khôi phục ảnh truyền thống mà còn là sự kết hợp giữa suy luận điểm bất thường ở các cấp độ khác nhau, hiểu ý định người dùng và tạo sinh ảnh hiệu chỉnh phù hợp. Đây cũng chính là những khoảng trống còn bỏ ngỏ mà nghiên cứu này muốn tập trung khai thác và phát triển.

## 2 Mục tiêu nghiên cứu

Mục tiêu tổng quát là nghiên cứu và phát triển một mô hình có khả năng tự động phát hiện, định vị và hiệu chỉnh các bất thường trong nội dung hình ảnh do mô hình AI tạo sinh, đồng thời đảm bảo kết quả sau chỉnh sửa giữ được tính chân thực, nhất quán về ngữ nghĩa và không làm thay đổi ý định tạo sinh ban đầu của người dùng.

### Các mục tiêu cụ thể:

- **MT1 – Phát hiện, suy luận và trực quan hóa các bất thường đa cấp độ trong nội dung do AI tạo sinh.** Nghiên cứu xây dựng cơ chế có khả năng phát hiện và phân tích bất thường ở nhiều cấp độ, từ các khiếm khuyết cục bộ về hình thức, kết cấu và cấu trúc đến các bất thường về giải phẫu, bố cục và ngữ nghĩa. Bên cạnh việc xác định loại bất thường, hệ thống tập trung vào định vị chính xác vùng ảnh bị ảnh hưởng thông qua các biểu diễn trực quan như bounding box, segmentation mask hoặc anomaly map, đồng thời cung cấp mô tả ngắn gọn về bản chất của lỗi. Cơ chế này vừa giúp người dùng nhanh chóng nhận biết và kiểm chứng các bất thường, đặc biệt trong những cảnh phức tạp, vừa cung cấp thông tin định vị cần thiết cho các bước suy luận và hiệu chỉnh tiếp theo.
- **MT2 – Xây dựng mô hình hiệu chỉnh bất thường phù hợp.** Đề xuất phương pháp tự động chỉnh sửa các vùng bất thường được phát hiện, đồng thời bảo toàn nội dung ảnh và duy trì tính nhất quán cho toàn bộ ảnh. Tùy vào độ khó của mỗi điểm bất thường mà các phương pháp hiệu chỉnh có thể được lựa chọn và áp dụng một cách linh hoạt, từ ý tưởng chỉnh sửa hậu kỳ cho đến can thiệp sâu vào kiến trúc của mô hình sinh ảnh.

- **MT3 – Phân tách ý định người dùng.** Nghiên cứu phát triển mô hình tích hợp thêm thông tin về ý định tạo sinh ban đầu của người dùng nhằm phân biệt giữa vi phạm quy tắc vật lý thế giới thực và vi phạm do chủ đích của văn bản tạo sinh, tránh gây cản trở trong mục đích sáng tạo của tác giả.

### 3 Tổng quan tình hình nghiên cứu

#### 3.1 Các phương pháp phát hiện bất thường (Detection Methods)

Những bất thường trong ảnh có thể xuất hiện ở nhiều mức độ khác nhau, từ các lỗi ở mức pixel (blur, checkerboard, aliasing) đến các lỗi về cấu trúc, giải phẫu và ngữ nghĩa như thừa ngón tay, sai quan hệ không gian hoặc vi phạm các quy luật vật lý. Vì vậy, phát hiện bất thường (Anomaly Detection) là bước đầu tiên và đóng vai trò quyết định trong các hệ thống AI Generated Content Anomaly Correction.

**Đầu tiên, với hướng nghiên cứu phát hiện bất thường có giám sát (Supervised Classification).** Ý tưởng chính của các phương pháp có giám sát chính là xem việc phát hiện bất thường như một bài toán phân loại, trong đó mô hình được huấn luyện trên dữ liệu đã gán nhãn bằng các kiến trúc như CNN, Vision Transformer (ViT) hoặc gần đây là Vision-Language Models (VLMs). Một công trình tiêu biểu là SynArtifact [8], mô hình nghiên cứu xây dựng bộ phân loại gồm 13 loại bất thường chính. Tác giả đã fine-tune một VLM để phân loại các loại bất thường, đạt hiệu quả cao hơn khoảng 25,66% so với các phương pháp truyền thống và có thể sử dụng kết quả phát hiện làm tín hiệu phản hồi để cải thiện mô hình sinh ảnh. Nhìn chung, ưu điểm của hướng tiếp cận này là độ chính xác cao và khả năng phân loại cụ thể từng loại bất thường. Tuy nhiên, hiệu năng phụ thuộc mạnh vào dữ liệu gán nhãn và thường giảm đáng kể khi gặp các loại bất thường chưa xuất hiện trong quá trình huấn luyện, dẫn đến hạn chế về khả năng tổng quát hóa. Bên cạnh đó, các bất thường được phân loại theo hướng này thường chỉ ở mức bề mặt, không mang tính suy luận nâng cao.

**Thứ hai, với hướng nghiên cứu phân đoạn và định vị vùng bất thường (Segmentation and Localization).** Đối với các hệ thống chỉnh sửa tự động, việc xác định vị trí của bất thường quan trọng hơn chỉ phát hiện sự tồn tại của chúng. Do đó, nhiều nghiên cứu đã bắt đầu tập trung xây dựng các mặt nạ (mask) trên các bất thường. Một ví dụ tiêu biểu là nghiên cứu của Tabatabaei [9], trong đó tác giả đề xuất pipeline hai giai đoạn gồm phát hiện vùng biến dạng trong ảnh Virtual Try-on và Pose Transfer, sau đó sử dụng mô hình Conditional Stable Diffusion Inpainting

để tái tạo vùng lỗi. Phương pháp cho chất lượng phục hồi cao nhưng chỉ được thiết kế cho một miền ứng dụng cụ thể, nên khả năng tổng quát hóa sang các loại bất thường khác còn hạn chế.

**Cuối cùng, với hướng nghiên cứu phát hiện kết hợp suy luận ngữ nghĩa (Semantic Reasoning).** Khi chất lượng ảnh AI ngày càng được cải thiện, nhiều bất thường chuyển từ mức pixel sang mức ngữ nghĩa, như vật thể vi phạm quy luật vật lý, quan hệ không gian bất hợp lý hoặc tương tác không phù hợp. Những lỗi này đòi hỏi mô hình phải có khả năng suy luận thay vì chỉ khai thác đặc trưng thị giác. Một công trình tiêu biểu là AnomAgent [12], nghiên cứu đầu tiên xây dựng bài toán phát hiện và suy luận các bất thường về mặt ngữ nghĩa (Semantic Visual Anomaly Detection and Reasoning) với bộ dữ liệu chú thích theo bốn thành phần: Name, Phenomenon, Reasoning và Severity. Mặc dù cho phép giải thích nguyên nhân gây bất thường, các phương pháp này vẫn chủ yếu dừng ở bước phát hiện và suy luận, chưa hỗ trợ lựa chọn chiến lược chỉnh sửa, chưa có một cơ chế trực quan kết quả và cũng chưa xem xét ý định tạo sinh ban đầu của người dùng.

Nhìn chung, các nghiên cứu về phát hiện bất thường đã phát triển từ bài toán phân loại đến định vị vùng lỗi và gần đây là suy luận ngữ nghĩa với sự hỗ trợ của Vision-Language Models. Tuy nhiên, các phương pháp hiện nay chủ yếu hoạt động riêng lẻ, chưa mang tính tổng quát một cách chặt chẽ, như: các mô hình định vị lại chỉ tập trung vào các lỗi khiếm khuyết, các mô hình phân tích lỗi ngữ nghĩa thì lại chưa có cơ chế định vị phù hợp. Chưa có một hệ thống thống nhất kết hợp phát hiện, suy luận và định vị có khả năng tổng quát hóa trên nhiều loại bất thường trong cùng một pipeline, đồng thời bảo toàn ý định tạo sinh của người dùng. Đây chính là khoảng trống nghiên cứu mà luận án hướng tới giải quyết.

### 3.2 Các phương pháp sửa lỗi (Correction Methods)

Sau khi phát hiện và định vị được vùng bất thường, mục tiêu tiếp theo là khôi phục ảnh sao cho loại bỏ được các điểm bất thường nhưng vẫn bảo toàn các vùng không bị lỗi và duy trì tính nhất quán của toàn cảnh. Khác với các bài toán image restoration truyền thống, các bất thường trong ảnh AI không tuân theo một mô hình suy giảm xác định mà có thể xuất hiện từ mức pixel đến mức ngữ nghĩa.

**Thứ nhất, hướng nghiên cứu hiệu chỉnh bằng kỹ thuật điền khuyết ảnh dựa trên mô hình khuếch tán (Diffusion-based Image Inpainting).** Đây là hướng tiếp cận phổ biến nhất hiện nay. Ý tưởng là xác định vùng chứa artifact, tạo mặt nạ

(mask), sau đó sử dụng mô hình khuếch tán để tái tạo riêng vùng lỗi thay vì sinh lại toàn bộ ảnh. Nhờ khả năng mô hình hóa phân phối dữ liệu mạnh, các mô hình khuếch tán có thể phục hồi các vùng khuyết lớn đồng thời duy trì sự nhất quán với bối cảnh. Một nghiên cứu tiêu biểu là Beyond Imperfections [9]. Tác giả đề xuất một quy trình đầu-cuối (end-to-end) gồm phát hiện vùng biến dạng trong ảnh Virtual Try-on và Pose Transfer, sau đó sử dụng Stable Diffusion Inpainting kết hợp ControlNet, IP-Adapter, Canny Edge, các điểm khóa (keypoints) và phân đoạn ngữ nghĩa (semantic segmentation) để tái tạo vùng lỗi. Phương pháp cho chất lượng phục hồi cao nhưng vẫn phụ thuộc vào độ chính xác của bước phát hiện và chủ yếu được thiết kế cho các miền ứng dụng cụ thể.

**Thứ hai, hướng nghiên cứu phục hồi hậu xử lý (Post-processing Restoration).** Khác với phương pháp điền khuyết ảnh, nhóm phương pháp này xem ảnh AI như đầu vào của một mô hình phục hồi độc lập, không cần truy cập vào mô hình tạo sinh gốc. Đại diện tiêu biểu là DiffGAR [11], hay mới đây nhất là mô hình Gen-Sheild, trong đó tác giả thực hiện hiệu chỉnh các bất thường dựa vào ảnh bị lỗi sau quá trình tạo sinh. Ưu điểm của hướng tiếp cận này là có thể áp dụng cho các mô hình dạng hộp đen (black-box) và dễ tích hợp vào nhiều hệ thống khác nhau. Tuy nhiên, do không khai thác thông tin từ quá trình sinh ảnh nên khả năng xử lý các lỗi ngữ nghĩa và cấu trúc phức tạp còn hạn chế.

**Thứ ba, với hướng nghiên cứu can thiệp trực tiếp vào quá trình sinh ảnh.** Thay vì sửa ảnh sau khi sinh xong, một số nghiên cứu gần đây đề xuất can thiệp trực tiếp vào quá trình khuếch tán (diffusion). Tiêu biểu là phương pháp ASCED [10], vừa được đề xuất năm 2025. Nghiên cứu chỉ ra rằng artifact chủ yếu xuất hiện trong giai đoạn Mutation của quá trình diffusion và đề xuất phương pháp nhằm theo dõi sự thay đổi của hàm score và điều chỉnh quỹ đạo sinh ảnh trước khi artifact hình thành. Đây là hướng nghiên cứu đầu tiên giải thích được cơ chế sinh artifact thay vì chỉ xử lý kết quả đầu ra. Tuy nhiên, phương pháp yêu cầu truy cập trực tiếp vào mô hình diffusion nên khó áp dụng cho các hệ thống thương mại hoặc mô hình đóng.

Nhìn chung, các phương pháp hiện nay chỉ tập trung sửa các lỗi khiếm khuyết (artifact) nhưng vẫn chưa có một nghiên cứu nào tổng quát trên nhiều loại bất thường, đặc biệt là những bất thường ở mức ngữ nghĩa. Bên cạnh đó, ý định tạo sinh ban đầu của người dùng, nơi thể hiện mục đích và khả năng sáng tạo ban đầu, đang bị bỏ qua trong hầu hết nghiên cứu hiện nay.

### 3.3 Bộ dữ liệu và các thước đo đánh giá

Các bộ dữ liệu lớn đáng chú ý hiện nay:

- **SynArtifact-1K [8]**. Đây là một trong những bộ dữ liệu đầu tiên dành riêng cho bài toán phát hiện bất thường trong ảnh AI. Bộ dữ liệu gồm 1.310 ảnh được tạo từ các mô hình như Stable Diffusion và DALL·E, mỗi ảnh được gán nhãn theo 13 loại artifact, vị trí xuất hiện (bounding box) và mô tả ngôn ngữ.
- **AnomReason [12]**. Bộ dữ liệu này đã mở rộng bài toán sang semantic anomaly reasoning. Thay vì chỉ gán nhãn loại lỗi, bộ dữ liệu gồm hơn 21.500 ảnh được chú thích theo bốn thành phần: Name, Phenomenon, Reasoning và Severity Score, cho phép đánh giá không chỉ khả năng phát hiện mà còn khả năng giải thích nguyên nhân gây bất thường.
- **Human Perception Benchmarks [7]**. Nghiên cứu này thu thập hơn 50.000 lượt đánh giá của người dùng đối với ảnh thật và ảnh tạo sinh nhằm xây dựng phân loại bất thường theo nhận thức của con người.

Do bài toán liên quan đồng thời đến chất lượng hình ảnh và tính hợp lý về ngữ nghĩa, các nghiên cứu thường kết hợp nhiều nhóm chỉ số đánh giá khác nhau:

- **Pixel-level metrics**. Chỉ số này bao gồm PSNR, MSE và MAE, đánh giá mức độ tương đồng giữa ảnh phục hồi và ảnh gốc. Các chỉ số này đơn giản và hiệu quả khi có ground truth, nhưng chưa phản ánh tốt chất lượng cảm nhận của con người.
- **Structural metrics**. Chỉ số này bao gồm SSIM và MS-SSIM đánh giá sự tương đồng về cấu trúc, độ sáng và độ tương phản giữa hai ảnh, thường có tương quan với cảm nhận thị giác tốt hơn các chỉ số mức pixel.
- **Human Evaluation**. Đây vẫn được xem là tiêu chuẩn quan trọng nhất. Các giao thức phổ biến gồm Likert Scale, Pairwise Preference, Realism Evaluation và Artifact Severity Rating. Các nghiên cứu như Kamali et al. (2025) cho thấy chưa có chỉ số tự động nào phản ánh đầy đủ đánh giá của con người, đặc biệt đối với các lỗi ngữ nghĩa.

Nhìn chung, các bộ dữ liệu như SynArtifact-1K và AnomReason đã tạo nền tảng cho nghiên cứu phát hiện bất thường ở cả mức thị giác và ngữ nghĩa, trong khi các benchmark dựa trên đánh giá của con người giúp phản ánh tốt hơn chất lượng cảm nhận của ảnh AI. Tuy nhiên, chưa có một benchmark thống nhất có khả năng đánh giá đồng thời (i) phát hiện bất thường, (ii) định vị vùng lỗi, (iii) chất lượng ảnh sau

chỉnh sửa và (iv) khả năng bảo toàn ý định tạo sinh của người dùng. Đây là khoảng trống quan trọng cần được giải quyết trong các nghiên cứu tương lai.

## **4 Nội dung nghiên cứu**

Nhằm giải quyết các khoảng trống nghiên cứu đã phân tích, luận án đề xuất xây dựng một hệ thống phát hiện và hiệu chỉnh các bất thường trong nội dung do AI tạo sinh thống nhất, có khả năng phát hiện, suy luận và chỉnh sửa các bất thường trong ảnh AI tạo sinh, đồng thời bảo toàn ý định sáng tạo của người dùng.

### **4.1 Nội dung 1: Xây dựng hệ thống tổng quát cho bài toán phát hiện và hiệu chỉnh bất thường một cách trực quan**

Nội dung đầu tiên tập trung nghiên cứu và xây dựng một pipeline thống nhất cho toàn bộ bài toán AI Generated Content Anomaly Correction. Hệ thống được thiết kế theo hướng tích hợp các thành phần phát hiện bất thường (Detection), định vị (Localization), suy luận nguyên nhân (Reasoning) và lựa chọn chiến lược hiệu chỉnh (Correction) các điểm bất thường đa cấp độ trong cùng một kiến trúc. Thay vì giải quyết riêng lẻ từng bài toán như các nghiên cứu hiện nay, hệ thống hướng tới khả năng xử lý nhiều loại bất thường khác nhau trên nhiều mô hình tạo sinh với các miền dữ liệu đa dạng, đồng thời nghiên cứu cơ chế trực quan kết quả nhằm tối ưu hóa trải nghiệm người dùng.

### **4.2 Nội dung nghiên cứu 2: Tích hợp cơ chế chỉnh sửa nhận biết ý định người dùng**

Nội dung thứ hai tập trung nghiên cứu cơ chế phân biệt bất thường từ ý định người dùng (Intent-aware Anomaly Correction), giúp hệ thống phân biệt giữa các bất thường thực sự và những chi tiết phi thực tế được tạo ra có chủ đích theo yêu cầu của người dùng. Nghiên cứu khai thác thông tin từ prompt, ngữ cảnh và các nguồn tri thức hỗ trợ để suy luận ý định tạo sinh ban đầu, từ đó quyết định vùng cần chỉnh sửa, vùng cần bảo toàn và lựa chọn chiến lược hiệu chỉnh phù hợp. Mục tiêu là nâng cao chất lượng hình ảnh sau chỉnh sửa nhưng vẫn giữ được tính sáng tạo và nội dung mong muốn của người dùng.

### 4.3 Nội dung nghiên cứu 3: Nghiên cứu cơ chế hiệu chỉnh ngay trong quá trình sinh ảnh

Nội dung thứ ba hướng đến việc cải thiện chất lượng ảnh ngay từ quá trình tạo sinh, thay vì chỉ thực hiện hậu xử lý trên ảnh đầu ra. Nghiên cứu tập trung phân tích cơ chế hình thành các bất thường trong quỹ đạo sinh ảnh của các mô hình tạo sinh, đặc biệt là quá trình khuếch tán, nhằm xác định nguyên nhân gốc rễ dẫn đến sự xuất hiện của các bất thường và các đột biến trong quá trình lấy mẫu. Trên cơ sở đó, luận án đề xuất cơ chế theo dõi và can thiệp vào quỹ đạo sinh ảnh hoặc thêm các ràng buộc về mặt vật lý, tri thức thông thường để phát hiện sớm các vùng có nguy cơ hình thành bất thường và thực hiện hiệu chỉnh kịp thời. Hướng tiếp cận này kỳ vọng giảm sự phụ thuộc vào các bước hậu xử lý, nâng cao chất lượng ảnh tạo sinh và tăng khả năng tổng quát của hệ thống trên nhiều mô hình tạo sinh khác nhau.

## 5 Kế hoạch nghiên cứu

Luận án được triển khai trong 04 năm và được trình bày chi tiết trong Bảng 1.

Bảng 1. Kế hoạch nghiên cứu dự kiến

| Năm | Nội dung nghiên cứu                                                                                                        | Kết quả dự kiến                                                                                   |
|-----|----------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|
| 1   | Khảo sát các nghiên cứu về phát hiện và hiệu chỉnh nội dung AI tạo sinh và đề xuất kiến trúc tổng quát cho bài toán.       | (1) Tổng hợp tổng quan nghiên cứu; (2) Hoàn thiện pipeline phát hiện–định vị–suy luận–hiệu chỉnh. |
| 2   | Xây dựng mô hình nhận biết ý định người dùng; phát triển cơ chế suy luận và lựa chọn chiến lược hiệu chỉnh.                | (1) Hoàn thiện mô hình <i>Intent-aware Anomaly Correction</i> ; (2) 01 bài báo quốc tế.           |
| 3   | Nghiên cứu cơ chế hình thành bất thường trong mô hình khuếch tán. Đề xuất phương pháp hiệu chỉnh trong quá trình sinh ảnh. | (1) Xây dựng thuật toán <i>In-generation Correction</i> ; (2) 01 bài báo quốc tế.                 |
| 4   | Tích hợp các mô-đun; đánh giá tổng thể và hoàn thiện hệ thống.                                                             | (1) Hoàn thiện framework hoàn chỉnh; (2) hoàn thành và bảo vệ luận án.                            |

## 6 Tài liệu tham khảo

- [1] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. “Generative adversarial networks”. In: *Communications of the ACM* 63.11 (2020), pp. 139–144.
- [2] Jonathan Ho, Ajay Jain, and Pieter Abbeel. “Denoising diffusion probabilistic models”. In: *Advances in neural information processing systems* 33 (2020), pp. 6840–6851.
- [3] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. “High-resolution image synthesis with latent diffusion models”. In: *2022 IEEE/CVF conference on computer vision and pattern recognition (CVPR)*. iee. 2022, pp. 10674–10685.
- [4] James Betker, Gabriel Goh, Li Jing, Tim Brooks, Jianfeng Wang, Linjie Li, Long Ouyang, Juntang Zhuang, Joyce Lee, Yufei Guo, et al. “Improving image generation with better captions”. In: *Computer Science*. [https://cdn. openai. com/papers/dall-e-3. pdf](https://cdn.openai.com/papers/dall-e-3.pdf) 2.3 (2023), p. 8.
- [5] Huan Yang, Deyu Zhang, Yudong Zhao, Yuanchun Li, and Yunxin Liu. “A first look at efficient and secure on-device LLM inference against KV leakage”. In: *Proceedings of the 19th workshop on mobility in the evolving Internet architecture*. 2024, pp. 13–18.
- [6] Negar Kamali, Karyn Nakamura, Angelos Chatzimpampas, Jessica Hullman, and Matthew Groh. “How to distinguish ai-generated images from authentic photographs”. In: *arXiv preprint arXiv:2406.08651* (2024).
- [7] Negar Kamali, Karyn Nakamura, Aakriti Kumar, Angelos Chatzimpampas, Jessica Hullman, and Matthew Groh. “Characterizing photorealism and artifacts in diffusion model-generated images”. In: *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. 2025, pp. 1–26.
- [8] Yu Cao et al. “SynArtifact: A Comprehensive Dataset and Visual-Language Model for AI-Generated Artifact Classification”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. 2024.
- [9] Aref Tabatabaei, Zahra Dehghanian, and Maryam Amirmazlaghani. “Beyond Imperfections: A Conditional Inpainting Approach for End-to-End Artifact Removal in VTON and Pose Transfer”. In: *arXiv preprint arXiv:2410.04052* (2024).
- [10] Yu Cao et al. “Temporal Score Dynamics Analysis for Generative Anomalies in Diffusion Models”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2025.
- [11] Yueqin Yin, Lianghua Huang, Yu Liu, and Kaiqi Huang. “Diffgar: Model-agnostic restoration from generative artifacts using image-to-image diffusion models”. In: *Proceedings of the 2022 6th international conference on computer science and artificial intelligence*. 2022, pp. 55–62.

- [12] Chuangchuang Tan, Xiang Ming, Jinglu Wang, Renshuai Tao, Bin Li, Yunchao Wei, Yao Zhao, and Yan Lu. “Semantic visual anomaly detection and reasoning in ai-generated images”. In: *International Conference on Learning Representations*. Vol. 2026. 2026, pp. 111907–111942.