

ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

Họ tên NCS: Dương Đình Phương Dao

**BÀI LUẬN VỀ HƯỚNG NGHIÊN CỨU
LUẬN ÁN TIẾN SĨ**

Tên đề tài:

**NGHIÊN CỨU PHƯƠNG PHÁP PHÂN TÍCH VÀ LÝ GIẢI
YẾU TỐ TẠO SINH TRONG NỘI DUNG HÌNH ẢNH**

Ngành: Khoa Học Máy Tính

Mã số: 9480101

Cán bộ hướng dẫn 1: TS. Nguyễn Vinh Tiệp

Thành phố Hồ Chí Minh, tháng 05 năm 2026

MỤC LỤC

1	Giới thiệu bài toán	1
1.1	Bối cảnh nghiên cứu	1
1.2	Định nghĩa bài toán	2
1.3	Khoảng trống và động lực nghiên cứu	2
2	Mục tiêu nghiên cứu	4
2.1	MT1: Phân tích, định vị và hệ thống hóa các yếu tố tạo sinh trong hình ảnh	4
2.2	MT2: Xác định nguồn tạo sinh dựa trên các yếu tố tạo sinh	5
2.3	MT3: Suy luận và lý giải nguồn tạo sinh dựa trên bằng chứng	5
3	Tổng quan tình hình nghiên cứu	6
3.1	Bài toán nhận diện ảnh thật và ảnh tạo sinh	6
3.2	Bài toán truy tìm nguồn gốc tạo sinh ảnh	9
3.3	Benchmark và dataset	10
4	Nội dung nghiên cứu	11
4.1	Nội dung 1: Phân tích và định vị các yếu tố tạo sinh trong hình ảnh	11
4.2	Nội dung 2: Xác định nguồn tạo sinh dựa trên các yếu tố tạo sinh	12
4.3	Nội dung 3: Suy luận và lý giải nguồn tạo sinh dựa trên bằng chứng	12
5	Kế hoạch nghiên cứu	13
5.1	Năm 1: Tổng hợp và hệ thống hóa các yếu tố tạo sinh	13
5.2	Năm 2: Xây dựng hệ thống phân loại ảnh và định vị yếu tố tạo sinh	13
5.3	Năm 3: Tích hợp khả năng truy tìm nguồn tạo sinh	14
5.4	Năm 4: Xây dựng khả năng suy luận, lý giải và hoàn thiện hệ thống	14
6	Tài liệu tham khảo	15

1 Giới thiệu bài toán

1.1 Bối cảnh nghiên cứu

Trong những năm gần đây, các mô hình tạo sinh hình ảnh như Stable Diffusion [cite], DALL-E [cite], Midjourney [cite], FLUX [cite] và nhiều mô hình thế hệ mới đã có khả năng tạo ra hình ảnh chất lượng cao, đa dạng và ngày càng chân thực. Thông qua mô tả bằng ngôn ngữ tự nhiên, người dùng có thể tạo ra hình ảnh về con người, vật thể, phong cảnh hoặc những sự kiện chưa từng tồn tại. Sự phát triển này mang lại nhiều ứng dụng trong thiết kế, quảng cáo, giáo dục, giải trí và sáng tạo nội dung. Tuy nhiên, khả năng tạo ảnh ngày càng chân thực cũng đặt ra thách thức mới cho bài toán xác thực hình ảnh. Nếu trước đây trọng tâm trong lĩnh vực phân tích pháp chứng hình ảnh (image forensics) là xác định ảnh có bị chỉnh sửa hay không, thì hiện nay cần quan tâm thêm các câu hỏi như: ảnh có được tạo bởi AI hay không, dấu hiệu nào cho thấy điều đó, nguồn nào có khả năng tạo ra ảnh và vì sao có thể đưa ra kết luận như vậy?

Các nghiên cứu xoay quanh bài toán này đã cho thấy ảnh tạo sinh có thể để lại nhiều loại dấu vết, từ nhiễu, miền tần số, quan hệ giữa các điểm ảnh đến kết cấu (texture), hình học, ánh sáng, bóng, phản chiếu và quan hệ giữa các vật thể trong ảnh. Tuy nhiên, các phương pháp hiện nay thường khai thác từng loại dấu vết riêng lẻ, chưa có sự thống kê và kết hợp phân tích ảnh trên nhiều khía cạnh. Điều đó dẫn đến sự cấp thiết trong việc xác định chính xác dấu vết hoặc bằng chứng nào đã dẫn đến quyết định phân loại ảnh tạo sinh và bằng chứng đó nằm ở vị trí nào trên ảnh. Vì vậy, các nghiên cứu gần đây đã bắt đầu quan tâm đến vấn đề suy luận và lý giải cho quyết định phân loại của mô hình. Tuy nhiên, lời giải thích vẫn có thể chưa gắn chặt với bằng chứng thực sự được sử dụng trong quá trình phân loại. Do đó, một câu hỏi quan trọng được đặt ra là: có thể xác định một cách có hệ thống các yếu tố tạo sinh trong ảnh, định vị chúng và sử dụng chúng làm cơ sở cho quá trình suy luận hay không? Gần đây, AIDE (ICLR 2025) [cite] cho thấy nhiều bộ phát hiện hiện có vẫn dễ thất bại trên Chameleon [cite], một tập ảnh tạo sinh có mức độ chân thực cao, cho thấy bài toán này vẫn còn nhiều thách thức.


Nhìn chung, bài toán hiện nay không còn chỉ là phân loại ảnh thật hay ảnh tạo sinh mà còn đòi hỏi sự phân tích và lý giải một cách trực quan hơn về nguồn gốc của mô hình tạo sinh ảnh. Do đó, nghiên cứu này được đề xuất nhằm tập trung vào chuỗi vấn đề này, với trọng tâm là phân tích các yếu tố tạo sinh trong hình ảnh, định

vị chúng, xác định mối quan hệ của chúng với nguồn tạo sinh và sử dụng chúng làm cơ sở cho suy luận và lý giải.

1.2 Định nghĩa bài toán

Định nghĩa bài toán được minh họa trong Hình 1, theo đó ta có thể tổng quát hóa như sau:

- **Đầu vào:** Một hình ảnh bất kỳ I .
- **Đầu ra:**
 - ◇ (1) y : nhãn phân loại thuộc $\{Real; AI - Generated\}$, tương ứng với ảnh thật và ảnh được tạo bởi AI.
 - ◇ (2) $E = \{e_1, e_2, \dots, e_n\}$: tập các yếu tố hay bằng chứng tạo sinh trên ảnh.
 - ◇ (3) $M = \{m_1, m_2, \dots, m_n\}$: tập các vị trí của từng bằng chứng tạo sinh trong ảnh.
 - ◇ (4) s : nguồn tạo sinh, có thể là mô hình, nhóm mô hình hoặc Unknown, đối với mô hình tạo sinh không được huấn luyện;




Hình 1. Minh họa đầu vào (input) và đầu ra (output) của hệ thống một cách tổng quan.

1.3 Khoảng trống và động lực nghiên cứu

Nghiên cứu được đề xuất xuất phát từ ba vấn đề chính:

- **Thứ nhất, bằng chứng tạo sinh trên ảnh hiện còn đang được khai thác một cách rời rạc.** Ảnh tạo sinh có thể chứa đồng thời nhiều loại dấu vết khác nhau tùy theo các khía cạnh phân tích hình ảnh. Một hình ảnh tạo sinh có thể để lại dấu vết tần số ở nền, lỗi hình học ở vật thể, bất thường ánh sáng ở vùng bóng và bất thường ngữ nghĩa ở quan hệ giữa hai vật thể. Tuy nhiên, các hướng hiện nay thường chuyên sâu vào một dạng tín hiệu. Ví dụ như HyperDet [cite] và NPR [cite] tập trung nhiều vào tín hiệu cấp thấp và quan hệ điểm ảnh; Sarkar và cộng sự [cite] tập trung vào hình học, đường thẳng và quan hệ vật thể–bóng; trong khi, AnomReason [cite] tập trung vào bất thường ngữ nghĩa. Khi các mô hình chỉ tập trung khai thác một khía cạnh trên ảnh, độ chính xác trong quá trình nhận diện ảnh tạo sinh có thể bị ảnh hưởng trong nhiều trường hợp ảnh tạo sinh quá chân thật và tinh vi. Vì thế, việc xem các tín hiệu khác nhau như những nguồn bằng chứng bổ sung, thay vì xem một loại tín hiệu là lời giải cho toàn bộ bài toán, sẽ mang lại nhiều giá trị nghiên cứu đầy hứa hẹn.
- **Thứ hai, các mô hình mã nguồn đóng (closed-source models) vẫn là một thách thức trong bài toán truy tìm nguồn gốc ảnh tạo sinh.** Nhiều nghiên cứu cho bài toán này có thể tận dụng khai thác kiến trúc của các mô hình sinh ảnh để nắm bắt các đặc trưng tạo sinh riêng biệt trên ảnh của mỗi mô hình. Cách tiếp cận này mang lại hiệu quả khi mô hình là mã nguồn mở (open source), giúp các nhà nghiên cứu đào sâu vào bên trong mô hình hoặc dễ dàng tạo sinh lượng lớn dữ liệu phục vụ cho quá trình huấn luyện. Ngược lại, với các hệ thống thương mại phát triển rất nhanh như Midjourney [cite], DALL-E [cite], Gemini [cite] hoặc các dịch vụ tạo ảnh thương mại mã nguồn đóng (closed source), các nghiên cứu thường gặp phải khó khăn trong việc truy cập vào kiến trúc, latent space (không gian ẩn) hoặc trọng số của mô hình và vẫn đề thiếu hụt dữ liệu huấn luyện. Điều này đặt ra thách thức lớn cho các nghiên cứu thuộc bài toán truy tìm thuộc tính nguồn gốc (source attribution) của ảnh tạo sinh.
- **Thứ ba, các giải thích hiện nay chưa thực sự được ràng buộc và suy luận bởi bằng chứng.** Các mô hình đa phương thức lớn (MLLM – mô hình ngôn ngữ lớn đa phương thức) đã cho phép sinh giải thích bằng ngôn ngữ tự nhiên. AIGI-Holmes [cite] xây dựng dữ liệu chứa nhãn và giải thích; SIDA [cite] kết hợp phát hiện, định vị và giải thích. Tuy nhiên, vẫn tồn tại một câu hỏi quan trọng: Lời giải thích có thực sự phản ánh bằng chứng mà hệ thống sử dụng

để đưa ra quyết định hay chỉ là một lời giải thích hợp lý được sinh ra sau đó? Minh họa trong Hình 2 cho thấy lời giải thích do mô hình sinh ra vẫn còn tồn tại nhiều hạn chế. Cụ thể, mô hình có thể tạo ra lời lý giải sai lệch và không ánh xạ đến được vùng trực tiếp nào trong ảnh, hoặc đưa ra mô tả mơ hồ mà không xác định rõ được vật thể cụ thể. Vì vậy, nghiên cứu này xem giải thích không phải là một đoạn văn sinh ra sau kết quả phân loại mà là kết quả suy luận từ một tập bằng chứng đã được phát hiện và định vị.



Hình 2. Minh họa hạn chế trong giải thích của AnomAgent [1]: các mô tả dài và phức tạp dẫn đến định vị bằng chứng mơ hồ hoặc không thể xác định chính xác vật thể được đề cập trong ảnh.

Tất cả những vấn đề nêu trên chính là động lực chính thúc đẩy nghiên cứu này.

2 Mục tiêu nghiên cứu

2.1 MT1: Phân tích, định vị và hệ thống hóa các yếu tố tạo sinh trong hình ảnh

Mục tiêu đầu tiên là xây dựng một hệ thống có khả năng phân tích hình ảnh từ nhiều góc nhìn và xác định các dấu vết nào có liên quan đến quá trình tạo sinh. Mục tiêu này hướng đến kết quả không chỉ là một vector đặc trưng khó hiểu và lý giải mà là một tập bằng chứng có ý nghĩa cho việc xác định ảnh tạo sinh và nguồn tạo sinh tương ứng. Điều này kế thừa một nhận định quan trọng từ các nghiên cứu trước rằng dấu vết có thể tồn tại ở nhiều mức khác nhau, từ nhiều và quan hệ điểm ảnh đến hình học và quan hệ ngữ nghĩa. Bên cạnh đó, tập bằng chứng còn cần phải được chỉ ra và

định vị rõ ràng trên ảnh, mang lại sự trực quan và tin cậy cho loại bằng chứng tương ứng.

Bởi lẽ, nếu không biết hệ thống đang dựa trên yếu tố nào thì việc xác định nguồn gốc và tạo sinh lý giải rất khó có cơ sở. Điều này mang lại ý nghĩa về mặt lý luận vì nó đưa bằng chứng trở thành một lớp trung gian rõ ràng giữa dữ liệu quan sát và quyết định cuối cùng.

2.2 MT2: Xác định nguồn tạo sinh dựa trên các yếu tố tạo sinh

Mục tiêu thứ hai là sử dụng các yếu tố tạo sinh đã phát hiện để xác định nguồn tạo sinh có khả năng tạo ra hình ảnh. Do không phải yếu tố tạo sinh nào trên ảnh cũng mang lại ý nghĩa để phân loại nguồn tạo sinh, nên đòi hỏi các bước sàng lọc, lựa chọn cho phù hợp với bài toán. Điều này đặt ra vấn đề trong việc tách các yếu tố liên quan trực tiếp đến quá trình tạo sinh khỏi nội dung ngữ nghĩa của ảnh. Khi đó, các yếu tố đó có thể trở thành cơ sở ổn định hơn cho truy tìm nguồn.

Đặc biệt, nghiên cứu hướng đến khai thác hai vấn đề khá mới. Thứ nhất, nguồn tạo sinh được mở rộng sang các mô hình thương mại hoặc mã nguồn đóng (closed source models). Các mô hình này có đặc điểm là không cho phép truy cập trực tiếp vào kiến trúc mô hình cũng như hạn chế về dữ liệu huấn luyện do vấn đề chi phí. Vì vậy, đòi hỏi một hệ thống nhận diện nguồn tạo sinh phải luôn bắt kịp các phiên bản mới liên tục với lượng dữ liệu huấn luyện nhỏ. Thứ hai, vấn đề khi hệ thống gặp nguồn tạo sinh mới mà chưa từng được huấn luyện trước đó. Khi đó, nếu ảnh được tạo bởi một mô hình chưa từng xuất hiện trong quá trình huấn luyện, hệ thống được kỳ vọng sẽ không nên buộc phải gán ảnh đó vào một mô hình đã biết. Vấn đề này cũng đã được khai thác nhiều trong các nghiên cứu đây nhưng không nên chỉ dừng lại ở việc trả lời ‘Unknown’ cho trường hợp này. Điều này đòi hỏi hệ thống cần có cơ chế cập nhật nhanh các mô hình mới.

2.3 MT3: Suy luận và lý giải nguồn tạo sinh dựa trên bằng chứng

Mục tiêu thứ ba là xây dựng cơ chế suy luận để kết hợp các yếu tố như bằng chứng, vị trí và nội dung hình ảnh tại vùng tương ứng để đưa ra lời giải thích hợp lý và thân thiện với người dùng cuối. Một lời giải thích phù hợp là khi chúng có thể chỉ ra được bằng chứng nào hỗ trợ cho các kết luận trước đó của hệ thống. Tức, thay vì để một MLLM nhìn ảnh và tự sinh một câu trả lời nghe có vẻ hợp lý, hệ thống sẽ phải dựa trên các bằng chứng đã được trích xuất.

3 Tổng quan tình hình nghiên cứu

3.1 Bài toán nhận diện ảnh thật và ảnh tạo sinh

Hình 3 [ref Hình] minh họa các hướng tiếp cận trực quan cho bài toán nhận diện ảnh thật và ảnh tạo sinh. Cụ thể:

Thứ nhất, với hướng tiếp cận phân tích tín hiệu cấp thấp và đặc trưng thống kê.

Các nghiên cứu đầu tiên xem detection như một bài toán phân loại nhị phân dựa trên các đặc trưng hình ảnh ở mức đơn giản. Các hệ thống ban đầu [cite CNNSpot, Towards Universal Fake Image Detectors that Generalize Across Generative Models] sử dụng đặc trưng ảnh được trích xuất từ các mạng CNN làm biểu diễn đặc trưng (feature representation) để phân loại giữa ảnh thật và ảnh tạo sinh. Mặc dù các phương pháp này ban đầu đạt kết quả rất cao (ACC: 85-90

Sau đó, các nghiên cứu tập trung trích xuất những dấu vết vi mô ở mức điểm ảnh như phân bố nhiễu, phổ tần số hay tương quan không gian — những yếu tố được chứng minh là vẫn tồn tại dù bức ảnh trông hoàn toàn tự nhiên đối với thị giác con người. Cụ thể, HyperDet [cite] khai thác nhóm bộ lọc pháp chứng SRM (Spatial Rich Model) — tập hợp các bộ lọc thông cao (high-pass filters) giúp triệt tiêu nội dung ảnh và giữ lại các đường nét ranh giới (edges) trên ảnh, tạo ra nhiều góc nhìn phân tích đa dạng cho các đường nét trong ảnh. Trong khi đó, NPR (Neighboring Pixel Relationships) tập trung phân tích mối quan hệ tương quan giữa các điểm ảnh lân cận nhằm phát hiện các chênh lệch bất thường xuất phát từ cơ chế tăng kích thước ảnh (upsampling) trong các mô hình tạo sinh [cite]. Phương pháp này có khả năng phát hiện hiệu quả trên cả kiến trúc mô hình GAN lẫn Diffusion Models. Nhờ vậy, tín hiệu NPR đã trở thành một đặc trưng rất phổ biến trong lĩnh vực này và được nhiều bài báo sau đó tiếp tục kế thừa để phân loại ảnh tạo sinh.

Tóm lại, các phương pháp phân tích tín hiệu cấp thấp sở hữu ưu điểm vượt trội khi không phụ thuộc vào khả năng hiểu ngữ nghĩa, và dễ dàng phát hiện các bất thường siêu nhỏ mà mắt người không thể nhận biết, ngay cả trên những bức ảnh hoàn toàn không chứa lỗi trực quan. Dù vậy, hạn chế cốt lõi của hướng tiếp cận này nằm ở việc thiếu tính giải thích. Do dựa trên các tương quan tín hiệu phức tạp, hệ thống rất khó chỉ ra cụ thể bằng chứng nằm ở đâu và mang ý nghĩa gì trên ảnh. Bên cạnh đó, các mô hình này thường dễ bị phụ thuộc vào chất lượng của dữ liệu huấn luyện. Vì vậy, một chỉ số độ chính xác cao trên thực nghiệm chưa thể khẳng định

mô hình đã thực sự hiểu đúng bản chất của quá trình tạo sinh, từ đó đặt ra nhu cầu cấp thiết về các hướng nghiên cứu mới có khả năng ràng buộc chặt chẽ giữa quyết định phân loại và bằng chứng suy luận trực quan.

Thứ hai, với hướng tiếp cận phân tích bất thường ở mức độ ngữ nghĩa trên ảnh.

Một hướng đi khác đặt trọng tâm vào những khuyết điểm trực quan (visible artifacts) mà con người có thể quan sát và nhận biết trực tiếp trên bức ảnh. Ở giai đoạn đầu, các nghiên cứu chủ yếu tập trung khai thác những biến dạng bất hợp lý trên ảnh, chẳng hạn như sự biến dạng đồng tử [cite Eyes Tell All: Irregular Pupil Shapes Reveal GAN-Generated Faces], cho đến sự mất cân đối cấu trúc trên khuôn mặt hoặc các vật thể phụ trợ theo cặp như gọng kính,... [cite Exposing Deep Fakes Using Facial Landmarks Connection Inconsistency; Exposing GAN-Generated Faces via Eyeglasses Inconsistency]. Ưu điểm lớn nhất của hướng tiếp cận này là tính giải thích cao (high explainability), giúp đưa ra bằng chứng trực quan, dễ hiểu và đầy thuyết phục đối với người dùng. Tuy nhiên, các mô hình tạo sinh đang ngày càng hoàn thiện, kéo theo sự ra đời của nhiều nghiên cứu chủ động phát hiện và triệt tiêu các khiếm khuyết này ngay trong quá trình tạo ảnh [cite Temporal score analysis for understanding and correcting diffusion artifacts]. Vì vậy, việc chỉ dựa vào các dấu vết biến dạng bề mặt đơn thuần dần không còn đủ bền vững, đặt ra nhu cầu về các phương pháp suy luận sâu hơn về ngữ nghĩa và quy luật vật lý tổng thể của bức ảnh.

Để giải quyết hạn chế này, các nghiên cứu gần đây đã dịch chuyển từ việc phát hiện các lỗi hình dáng cục bộ sang khai thác các quy luật vật lý và hình học không gian toàn cục. Nghiên cứu của Sarkar [cite] chỉ ra rằng các mô hình tạo sinh có thể tạo ra hình ảnh nhìn hợp lý ở mức tổng thể nhưng vi phạm các quy luật về hình học, đường thẳng, bóng và quan hệ giữa vật thể với bóng. Công trình này đưa các nguyên lý hình học của thế giới thực vào bài toán phát hiện ảnh tạo sinh. Đây là một hướng tiếp cận khá thú vị khi khai thác một góc nhìn trực quan trong ảnh, kiểm tra toàn bộ quan hệ không gian trong ảnh. AnomReason [cite] đã phát triển mạnh hơn theo hướng này bằng cách xây dựng benchmark cho việc phát hiện và suy luận bất thường thị giác giữa các vật thể trong ảnh. Họ cố gắng xây dựng bộ dữ liệu liệt kê toàn bộ các bất thường dưới dạng có cấu trúc. Ví dụ, một bất thường được bài báo định nghĩa dưới 4 trường thông tin chính (minh họa ở Hình [ref]), bao gồm: tên (name), hiện tượng quan sát (phenomenon), lý do suy luận (reasoning) và mức độ nghiêm trọng (severity). Phương pháp này đáng chú ý với cách biểu diễn cấu trúc các thành phần

một cách rõ ràng, giúp phân tích chi tiết nguyên nhân bất hợp lý, tạo cơ sở để kiểm định kết quả phân loại.

Ưu điểm nổi bật của hướng tiếp cận dựa trên các bất thường trực quan là mang lại khả năng giải thích cao, giúp con người dễ dàng quan sát và đối chiếu bằng chứng. Tuy nhiên, nhược điểm lớn nằm ở chỗ các bất thường ngữ nghĩa không phải lúc nào cũng là đặc trưng duy nhất để xác định ảnh tạo sinh. Một bức ảnh thật vẫn có thể chứa những điểm kỳ lạ do ý đồ nghệ thuật của nhiếp ảnh gia; ngược lại, không phải mọi ảnh tạo sinh đều xuất hiện lỗi trực quan rõ rệt. Để khắc phục các hạn chế đơn lẻ, xu hướng nghiên cứu hiện nay đang hướng tới việc kết hợp cả đặc trưng cấp thấp (như chênh lệch điểm ảnh,...) và đặc trưng cấp cao (như cấu trúc ngữ nghĩa của các đối tượng) vào cùng một hệ thống phân loại [cite REVEAL, EXACT]. Dù vậy, mặc dù việc tích hợp đa cấp độ này mang lại độ chính xác cao cho bài toán phân loại nhị phân, hệ thống vẫn tồn tại nhiều bất cập nghiêm trọng trong việc suy luận, giải thích bản chất và định vị chính xác vùng bằng chứng mà mô hình đã dựa vào để đưa ra quyết định.

Thứ ba, với việc tích hợp định vị và lý giải cho quyết định phân loại.

Gần đây, việc ứng dụng các mô hình đa phương thức lớn (MLLM) đã mở ra xu hướng mới trong việc kết hợp khả năng phân loại với sinh giải thích bằng ngôn ngữ tự nhiên và định vị vùng bất thường trên ảnh. Điển hình, AIGI-Holmes [cite] xây dựng tập dữ liệu Holmes-Set chứa các nhãn phân loại cùng lời giải thích chi tiết, đồng thời áp dụng quy trình huấn luyện nhiều giai đoạn nhằm nâng cao khả năng giải thích dựa trên tín hiệu thị giác. Tuy mô hình đạt độ chính xác cao trên tập dữ liệu thử nghiệm, hệ thống vẫn bộc lộ nhiều hạn chế khi gặp phải những kịch bản ảnh phức tạp. Minh họa trong Hình [ref] cho thấy kết quả của AIGI-Agent khi xử lý bức ảnh chứa nhiều vật thể nhập nhằng: mặc dù phân loại ảnh tạo sinh chính xác, lời giải thích mà hệ thống đưa ra lại hoàn toàn sai lệch. Điều này chứng minh rằng hệ thống vẫn đang cố gắng hợp lý hóa lời giải thích dựa trên kết quả phân loại có sẵn, chứ chưa thực sự suy luận dựa trên bằng chứng thuyết phục.

Trong khi đó, SIDA [cite] mở rộng quy mô với tập dữ liệu SID-Set (300.000 ảnh) và đề xuất hệ thống dựa trên MLLM, cho phép thực hiện đồng thời ba tác vụ: phân loại ảnh, định vị vùng ảnh tạo sinh bằng mặt nạ phân đoạn (segmentation mask), và sinh văn bản giải thích. Mặc dù đạt được những tiến bộ đáng ghi nhận, các tiếp cận này vẫn tồn tại một hạn chế cốt lõi: lời giải thích và kết quả định vị vùng bất thường được sinh ra đồng thời nhờ vào một mô hình LISA, một MLLM có khả năng phân

đoạn vật thể trên ảnh. Nói cách khác, hệ thống vẫn có thể đưa ra một lời giải thích nghe rất hợp lý nhưng không thực sự dựa trên bằng chứng thị giác mà nó đã khoanh vùng.

Để giải quyết triệt để vấn đề này, nghiên cứu đề xuất một hướng tiếp cận mới: lời giải thích phải được suy luận trực tiếp từ tập bằng chứng (evidence-grounded reasoning) đã được phát hiện và định vị, thay vì chỉ là một thành phần đầu ra được sinh ra đồng thời cùng với kết quả dự đoán.

3.2 Bài toán truy tìm nguồn gốc tạo sinh ảnh

Nếu bài toán phân loại chỉ đưa ra quyết định nhị phân giữa ảnh thật và ảnh tạo sinh, thì bài toán truy tìm nguồn gốc (source attribution) giải quyết một khía cạnh sâu hơn: định danh chính xác mô hình AI nào đã tạo ra bức ảnh đó. So với bài toán phân loại thì bài toán truy tìm nguồn gốc tạo sinh ảnh hiện vẫn còn nhiều khoảng trống chưa được nghiên cứu và khai thác. Thách thức cốt lõi của bài toán này nằm ở việc trích xuất được đặc trưng dấu vân tay (model fingerprint) mang tính đặc trưng riêng biệt của từng thuật toán sinh ảnh. Trước đây, các nghiên cứu tập trung khai thác đặc trưng cấp cao để giải quyết bài toán. Tuy nhiên, hiện nay các nghiên cứu lại có xu hướng chuyển dần sang hướng tiếp cận khai thác đặc trưng cấp thấp (low-level forensic features) cho bài toán này.

Ở hướng tiếp cận đặc trưng cấp cao, tiêu biểu là nghiên cứu "Are CLIP Features All You Need for Universal Synthetic Image Origin Attribution?" [cite], các tác giả đề xuất sử dụng không gian đặc trưng ngữ nghĩa của các mô hình đã được huấn luyện trước đó như CLIP để phân biệt nguồn gốc ảnh. Tuy phương pháp này đơn giản và tận dụng khả năng biểu diễn ngữ nghĩa của các mô hình tiền huấn luyện (pre-train models) nhưng mô hình dễ bị phụ thuộc vào phong cách và ngữ nghĩa riêng của từng mô hình tạo sinh. Điều này có nghĩa là hệ thống phân loại thực chất chỉ đang dựa vào phong cách hiển thị bề mặt (rendering style) riêng của từng mô hình, chứ chưa trích xuất được dấu vết từ kiến trúc mô hình. Do đó, trong trường hợp hai mô hình tạo sinh khác nhau cùng tạo ra bức ảnh có nội dung và phong cách hoàn toàn tương đồng (như khi sử dụng chung một câu lệnh tả thực khắt khe), không gian đặc trưng ngữ nghĩa của CLIP sẽ bị nhầm lẫn. Kết quả là mô hình dễ đưa ra quyết định sai lệch.

Chính vì hạn chế trên, đại đa số các nghiên cứu trong bài toán source attribution sau này dần chuyển sang hướng tiếp cận đặc trưng cấp thấp (low-level features). Lý

do là vì thông tin ngữ nghĩa cấp cao có thể giống nhau giữa các mô hình sinh, nhưng các dấu vết vi mô ở cấp độ điểm ảnh lại mang đặc tính riêng biệt. Các công trình gần đây như [cite "Forensic Self-Descriptions Are All You Need" (CVPR 2025) hay "Causal Fingerprints of AI Generative Models" (ICASSP 2026)] đã thể hiện rõ xu hướng này khi tập trung khai thác các thông tin tín hiệu từ các mối quan hệ giữa các điểm ảnh. Đặc trưng “causal fingerprints” [cite] đã đề xuất tách phần thông tin nội dung (content) và phong cách (style) ra khỏi bức ảnh, từ đó chỉ giữ lại dải tín hiệu đặc trưng để phân biệt nguồn tạo sinh trên ảnh. Phương pháp này triệt tiêu được sự ảnh hưởng của ngữ nghĩa, giúp hệ thống tập trung hoàn toàn vào các bằng chứng thị giác vi mô. Tuy nhiên, do quá tập trung vào các dải tín hiệu nhiễu trên ảnh nên các phương pháp này dễ bị thất bại trước những kịch bản ảnh thực tế như bị mờ hoặc bị nén ảnh khiến cho các dấu vết nhiễu bị phá hủy.

Một khoảng trống nghiên cứu lớn khác trong bài toán truy tìm nguồn gốc tạo sinh (source attribution) là sự thiếu hụt hoàn toàn các hướng tiếp cận về định vị (localization) và lý giải (explanation/reasoning). Trong khi bài toán phát hiện ảnh giả nhái phân đã có những bước tiến mạnh mẽ hướng tới việc khoanh vùng chi tiết tạo sinh (visual grounding) và sinh lời giải thích bằng ngôn ngữ tự nhiên, các phương pháp truy tìm nguồn gốc tạo sinh hiện nay vẫn hầu như chỉ dừng lại ở việc gán nhãn phân loại. Hệ thống chỉ đưa ra tên mô hình tạo sinh (như Midjourney, SDXL hay DALL-E) dưới dạng hộp đen (blackbox), mà không thể chỉ ra cụ thể vùng không gian nào trên bức ảnh đang chứa dấu vết đặc trưng, cũng như không thể lý giải bằng ngôn ngữ nguyên nhân dẫn đến quyết định phân loại đó. Điều này cũng hoàn toàn dễ hiểu do các mô hình hiện nay chỉ sử dụng đặc trưng cấp thấp, dẫn đến khó trong việc tạo ra giải thích dễ hiểu cho người dùng cuối. Tuy nhiên việc thiếu hụt khả năng định vị vùng bằng chứng và giải thích cơ chế suy luận này làm giảm đi đáng kể tính minh bạch, đồng thời tạo ra rào cản lớn khi đưa bài toán source attribution vào các kịch bản giám định đòi hỏi sự minh bạch cao.

3.3 Benchmark và dataset

Một vấn đề quan trọng là bộ dữ liệu, điều ảnh hưởng rất lớn việc một detector hay attribution system thực sự đang học điều gì. Các benchmark và dataset được tổng hợp trong bảng [ref Bảng].

Nhìn chung, các bộ dữ liệu hiện nay cho thấy mức độ đa dạng ngày càng tăng, không chỉ về loại mô hình sinh ảnh mà còn về miền dữ liệu, prompt và mức độ

Bảng 1. Tóm tắt một số bộ dữ liệu cho nhóm bài toán nhận diện ảnh tạo sinh, truy tìm nguồn gốc trên ảnh.

Dataset / Benchmark	Conference / Year	Samples	# Sources	Generation Sources	Closed Source	Detection	Attribution	Localization	Explanation
CIFAKE	IEEE Access, 2024	120K = 60K real + 60K fake	1	Stable Diffusion 1.4	None	✓	×	×	×
WildFake	AAAI 2025	3.69M = $\approx 1.01M$ real + $\approx 2.68M$ fake	23	BigGAN; StyleGAN; StarGAN; DF-GAN; GALIP; GigaGAN; ADM; DDPM; DDIM; Imagen; VQDM; DALL-E 2; DALL-E 3; Midjourney v4; Midjourney v5; SDXL; OriginalSD; ControlNet; LoRA-based SD models; LyCORIS-based models; personalized SD models; MAGI; VQGAN; VQVAE; MAE	Imagen; DALL-E 2; DALL-E 3; Midjourney v4; Midjourney v5	✓	×	×	×
AIGIBench	NeurIPS 2025 Datasets & Benchmarks	144K	Multiple	ProGAN; R3GAN; StyleGAN-XL; Stable Diffusion 1.4; Stable Diffusion 3; FLUX.1-dev; Midjourney V6; Imagen; DALL-E 3; InstantID; Infinite-ID; BLIP; FaceSwap; InSwap; BlendFace; WHIR; CommunityAI; SocialRF; open-source/community generators	Midjourney V6; DALL-E 3; Imagen; Stable Diffusion 3; FLUX.1-dev	✓	×	×	×
SID-Set	CVPR 2025	$\approx 300K$	Multiple	FLUX; Kandinsky 3.0; SDXL; AbsoluteReality	None	✓	×	✓	✓
Synthbuster	IEEE Open Journal of Signal Processing, 2023	10K fake + 1K real	9	DALL-E 2; DALL-E 3; Adobe Firefly; Midjourney v5; Stable Diffusion 1.3; Stable Diffusion 1.4; Stable Diffusion 2; Stable Diffusion XL; GLIDE	DALL-E 2; DALL-E 3; Adobe Firefly; Midjourney v5	✓	✓	×	×
GenImage	2024	$\approx 2.68M = \approx 1.33M$ real + $\approx 1.35M$ fake	8	ADM; BigGAN; GLIDE; Midjourney; Stable Diffusion 1.4; Stable Diffusion 1.5; VQDM; Wakong	Midjourney	✓	✓	×	×
DRAGON	2025	2.6M	24 diffusion models	SD 1.5; SD 2.1; SDXL; SDXL Turbo; SDXL Lightning; LCM-SDXL; Flash-SDXL; SDXL derivatives; SD 3; Flash-SD3; Flux.1; IF; Kandinsky; Luminar; PixArt-Alpha; PixArt-Sigma; Flash-PixArt; SSD-1B; LCM-SSD-1B; SD Cascade; Kokoro; JuggernautXL; Realistic Stock Photo; Mobius; Hyper-SD	None	✓	✓	×	×
AnomReason	ICLR 2026	21,539 images	3	Midjourney; SD3.5; Flux	Midjourney; Flux	✓	×	×	✓

chân thực của ảnh. Một số benchmark gần đây đã bắt đầu mở rộng sang các generator thương mại/closed-source như Midjourney, DALL-E hay các nền tảng sinh ảnh thương mại, qua đó phản ánh tốt hơn sự đa dạng của ảnh AIGC trong thực tế. Tuy nhiên, phần lớn các benchmark vẫn tập trung vào bài toán phát hiện (detection) và phân loại/nhận diện nguồn sinh (attribution). Ngược lại, các bộ dữ liệu có annotation ở mức bằng chứng (evidence), định vị vùng bất thường (localization) và giải thích nguyên nhân (explanation/reasoning) vẫn còn tương đối hạn chế và thường chỉ tập trung vào một khía cạnh riêng lẻ. Điều này cho thấy vẫn còn khoảng trống trong việc xây dựng một benchmark thống nhất có khả năng đánh giá toàn diện, đặc biệt trên các ảnh được sinh bởi cả open-source/open-weight và closed-source generators.

4 Nội dung nghiên cứu

4.1 Nội dung 1: Phân tích và định vị các yếu tố tạo sinh trong hình ảnh

Nội dung đầu tiên tập trung xây dựng phương pháp xác định: Ảnh chứa những yếu tố tạo sinh nào và các yếu tố đó nằm ở đâu? Điều này có nghĩa là hệ thống không chỉ đưa ra quyết định phân loại mà đang hướng đến việc cung cấp các bằng chứng một cách cụ thể.

Nếu không xác định được bằng chứng, thì bài toán phân loại hay xác định nguồn gốc ảnh dễ trở thành một bài toán phân loại hộp đen. Khi đó hệ thống có thể nói: “Nguồn là Model A” nhưng không biết tại sao. Ngược lại, nếu khai thác được các bằng chứng chỉ ra yếu tố hoặc dấu vết tạo sinh trên ảnh, chúng sẽ là cầu nối quan trọng để đưa ra các giải thích hợp lý và trực quan.

Nghiên cứu dự kiến tổ chức các bộ phân tích theo nhiều cấp độ, từ các tín hiệu cấp thấp (như phân tích nhiễu, tần suất, quan hệ giữa các điểm ảnh,...) đến các tín hiệu cấp cao (như phân tích quan hệ ngữ nghĩa, tính chất vật lý giữa các vật thể trong ảnh, ...). Mỗi bộ phân tích sẽ không nhất thiết đưa ra nhãn phân loại riêng biệt mà sẽ là một mắt xích bằng chứng quan trọng dẫn đến kết luận cuối cùng và là ánh xạ cho các giải thích ngôn ngữ với người dùng cuối.

4.2 Nội dung 2: Xác định nguồn tạo sinh dựa trên các yếu tố tạo sinh

Mục tiêu của nội dung này là từ tập bằng chứng được trích xuất từ ảnh tạo sinh hệ thống cần xác định nguồn tạo sinh tương ứng. Mục tiêu không dừng lại ở mô hình đã biết mà hướng tới cả những nguồn tạo sinh mà mô hình chưa từng được huấn luyện trước đó. Điều này giúp mô hình không cố ép các ảnh chưa biết nguồn tạo sinh vào các mô hình đã biết, dẫn đến sự sai lệch nghiêm trọng.

Về bản chất, bài toán nhận diện và truy tìm nguồn tạo sinh ảnh cần phân tích những tính chất khác nhau trên ảnh. Điều này có nghĩa là một loại bằng chứng tạo sinh có thể đồng thời xuất hiện ở nhiều mô hình tạo sinh khác nhau. Vì vậy, tuy nó có thể dùng để nhận diện ảnh tạo sinh nhưng lại không đủ sức thuyết phục để phân biệt giữa các nguồn tạo sinh. Tuy nhiên, một đặc trưng rất riêng của mô hình tạo sinh bất kỳ có thể giúp phân định nguồn gốc ảnh nhưng lại có thể không ổn định nếu ảnh bị thay đổi định dạng hoặc bị giảm chất lượng. Do đó, cần phân tích rõ ràng vai trò của mỗi bằng chứng để xác định chính xác tầm quan trọng và sự đóng góp của mỗi bằng chứng trong việc phân loại nguồn tạo sinh. Đây cũng chính là lý do không nên bắt đầu từ các bộ phân loại đơn giản hay phụ thuộc vào một đặc trưng riêng lẻ nào cho bài toán truy tìm nguồn gốc ảnh tạo sinh, mà nên bắt đầu từ việc khai phá các dấu vết và bằng chứng tạo sinh một cách tổng quát.

Bên cạnh đó, nghiên cứu cũng hướng đến một hệ thống thực tế phải có khả năng nói: “Ảnh chắc chắn là ảnh tạo sinh, nhưng chưa có đủ bằng chứng để gán cho các nguồn đã biết.” thay vì buộc chúng phải gán nguồn đã biết. Nghiên cứu vì vậy hướng đến cơ chế reject option (từ chối gán nguồn).

4.3 Nội dung 3: Suy luận và lý giải nguồn tạo sinh dựa trên bằng chứng

Từ các bằng chứng và vị trí được định vị trên ảnh, nghiên cứu kỳ vọng sẽ xây dựng một lời giải thích bằng ngôn ngữ tự nhiên một cách dễ hiểu và thân thiện với người dùng cuối. Bởi lẽ, một hệ thống xác định nguồn sinh ảnh có độ chính xác cao nhưng

không giải thích được vẫn còn hạn chế trong các môi trường cần kiểm chứng.

Trong nghiên cứu này, MLLM có thể được sử dụng như một reasoning engine (bộ suy luận), nhưng không nên là nguồn duy nhất tạo ra bằng chứng. Mô hình có thể nhận ảnh toàn cảnh kèm với vị trí dấu vết và loại bằng chứng tương ứng và sinh ra các suy luận dựa trên các thông tin đó. Đây là khác biệt quan trọng về kiến trúc so với các hệ thống trước đây, thường chỉ cố sinh ra các giải thích có vẻ hợp lý cho quyết định trước đó.

5 Kế hoạch nghiên cứu

5.1 Năm 1: Tổng hợp và hệ thống hóa các yếu tố tạo sinh

Trong năm đầu tiên, nghiên cứu tập trung khảo sát và hệ thống hóa các dạng dấu vết và yếu tố có thể được sử dụng để nhận diện ảnh được tạo sinh bởi trí tuệ nhân tạo. Việc khảo sát được thực hiện từ nhiều hướng nghiên cứu liên quan, bao gồm pháp chứng ảnh (image forensics), phân tích miền tần số (frequency analysis), pháp chứng ảnh sinh bởi mô hình khuếch tán (diffusion forensics), phát hiện bất thường ngữ nghĩa (semantic anomaly detection) và nhận dạng dấu vân tay của mô hình sinh (model fingerprinting).

Trên cơ sở khảo sát, nghiên cứu xây dựng một hệ thống phân loại các yếu tố tạo sinh theo nhiều mức độ, từ các dấu vết cấp thấp trong tín hiệu ảnh đến các bất thường về cấu trúc, hình học, vật lý và ngữ nghĩa. Đồng thời, nghiên cứu xác định các tiêu chí để một yếu tố có thể được xem là bằng chứng (evidence) cho quá trình xác định nguồn gốc của ảnh.

Kết quả dự kiến:

- Xây dựng hệ thống phân loại các yếu tố tạo sinh (taxonomy);
- Tổng hợp các chuẩn thử nghiệm (benchmark) và bộ dữ liệu (dataset) trên các loại yếu tố tạo sinh;

5.2 Năm 2: Xây dựng hệ thống phân loại ảnh và định vị yếu tố tạo sinh

Trong năm thứ hai, nghiên cứu tập trung phát triển các phương pháp tự động phát hiện và phân loại các yếu tố tạo sinh trên ảnh. Hệ thống được xây dựng theo hướng kết hợp nhiều nhóm dấu vết khác nhau, bao gồm tín hiệu cấp thấp, đặc trưng miền tần số, kết cấu (texture), hình học, các quy luật vật lý và các bất thường ngữ nghĩa.

Trên cơ sở các yếu tố được xác định trong năm thứ nhất, nghiên cứu xây dựng các

bộ phân tích chuyên biệt cho từng nhóm bằng chứng và nghiên cứu cơ chế kết hợp các bằng chứng để xác định trạng thái của ảnh, chẳng hạn ảnh thật hoặc ảnh được tạo sinh bởi trí tuệ nhân tạo. Bên cạnh khả năng phân loại, nghiên cứu tập trung vào bài toán định vị bằng chứng (evidence localization), nhằm xác định vị trí xuất hiện của các yếu tố bất thường trên ảnh. Tùy thuộc vào đặc điểm của từng loại bằng chứng, các phương thức biểu diễn như hộp giới hạn (bounding box), mặt nạ (mask) hoặc vùng ảnh có liên quan sẽ được nghiên cứu.

Kết quả dự kiến:

- Hệ thống nhận diện ảnh tạo sinh trên cơ sở bằng chứng;
- Các phương pháp định vị bằng chứng trên ảnh bằng hộp giới hạn, mặt nạ hoặc vùng ảnh;

5.3 Năm 3: Tích hợp khả năng truy tìm nguồn tạo sinh

Trong năm thứ ba, nghiên cứu mở rộng từ việc xác định ảnh có phải ảnh được tạo sinh hay không sang bài toán truy tìm nguồn tạo sinh (source attribution), tức xác định mô hình hoặc nhóm mô hình có khả năng đã tạo ra ảnh.

Phương pháp truy tìm nguồn được xây dựng dựa trên các bằng chứng đã được phát hiện và định vị ở giai đoạn trước. Thay vì chỉ dựa trên đặc trưng toàn cục của ảnh, nghiên cứu tập trung khai thác mối quan hệ giữa các bằng chứng quan sát được và đặc điểm của từng nguồn tạo sinh. Nghiên cứu đặc biệt quan tâm đến các trường hợp trong đó nguồn tạo sinh không được cung cấp trực tiếp trong quá trình huấn luyện hoặc không thể truy cập vào mô hình sinh. Các hướng nghiên cứu bao gồm mô hình sinh dạng hộp đen (black-box), mô hình có nguồn đóng (closed-source), khả năng tổng quát giữa các mô hình sinh khác nhau (cross-generator generalization), nhận dạng nguồn chưa từng quan sát (open-set recognition) và thích nghi với số lượng mẫu nhỏ (few-shot adaptation).

Kết quả dự kiến:

- Hệ thống nhận diện và phân biệt nhiều nguồn tạo sinh dựa trên bằng chứng;
- Bộ kiểm chuẩn đánh giá khả năng truy tìm nguồn trong điều kiện nguồn phức tạp;

5.4 Năm 4: Xây dựng khả năng suy luận, lý giải và hoàn thiện hệ thống

Trong năm cuối, nghiên cứu tích hợp các thành phần phát hiện, định vị và truy tìm nguồn thành một hệ thống thống nhất có khả năng suy luận và đưa ra giải thích dựa

trên bằng chứng quan sát được.

Hệ thống không chỉ đưa ra kết luận về trạng thái và nguồn tạo sinh của ảnh mà còn xây dựng chuỗi suy luận từ bằng chứng đến kết luận. Với mỗi kết luận, hệ thống cần chỉ ra các bằng chứng liên quan, vị trí của bằng chứng trên ảnh và mối quan hệ giữa các bằng chứng đó với nguồn tạo sinh được dự đoán.

Kết quả dự kiến:

- Hệ thống hoàn chỉnh từ phát hiện, định vị, truy tìm nguồn đến suy luận và lý giải;
- Đánh giá thực nghiệm trên nhiều thể hệ và nhiều nhóm mô hình tạo sinh;

6 Tài liệu tham khảo

- [1] Chuangchuan Tan, Xiang Ming, Jinglu Wang, Renshuai Tao, Bin Li, Yunchao Wei, Yao Zhao, and Yan Lu. “Semantic visual anomaly detection and reasoning in ai-generated images”. In: *International Conference on Learning Representations*. Vol. 2026. 2026, pp. 111907–111942.