ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

Họ tên NCS: Dương Đình Phương Dao

BÀI LUẬN VỀ HƯỚNG NGHIÊN CỨU LUẬN ÁN TIẾN SĨ

Tên đề tài:

NGHIÊN CỨU PHƯƠNG PHÁP PHÂN TÍCH VÀ PHÁT HIỆN DẤU VẾT MÔ HÌNH TẠO SINH TRONG NỘI DUNG HÌNH ẢNH

Ngành: Khoa Học Máy Tính
Mã số: 9480101

Cán bộ hướng dẫn 1: TS. Nguyễn Vinh Tiệp
Cán bộ hướng dẫn 2: TS. Lê Trung Nghĩa

Thành phố Hồ Chí Minh, tháng 10 năm 2026

MỤC LỤC

1 Giới thiệu bài toán 1
1.1 Bối cảnh nghiên cứu 1
1.2 Định nghĩa bài toán 2
1.3 Khoảng trống và động lực nghiên cứu 3
2 Mục tiêu nghiên cứu 6
2.1 MT1: Phân tích, biểu diễn và định vị các dấu vết tạo sinh trong hình ảnh 6
2.2 MT2: Truy tìm nguồn tạo sinh dựa trên các bằng chứng phân biệt nguồn 7
2.3 MT3: Suy luận và lý giải kết quả nhận diện và truy tìm nguồn dựa trên bằng chứng 7
3 Tổng quan tình hình nghiên cứu 8
3.1 Bài toán nhận diện ảnh thật và ảnh tạo sinh 8
3.2 Bài toán truy tìm nguồn gốc tạo sinh ảnh 12
3.3 Benchmark và dataset 15
4 Nội dung nghiên cứu 16
4.1 Nội dung 1: Phân tích, biểu diễn và định vị các dấu vết tạo sinh trong hình ảnh 16
4.2 Nội dung 2: Truy tìm nguồn tạo sinh dựa trên các bằng chứng phân biệt nguồn 17
4.3 Nội dung 3: Suy luận và lý giải kết quả dựa trên bằng chứng 18
5 Kế hoạch nghiên cứu 19
5.1 Năm 1: Khảo sát và hệ thống hóa các dấu vết tạo sinh 19
5.2 Năm 2: Phát triển phương pháp phát hiện và định vị bằng chứng . . . 19
5.3 Năm 3: Phát triển phương pháp truy tìm nguồn tạo sinh dựa trên bằng chứng 20
5.4 Năm 4: Xây dựng cơ chế suy luận, lý giải và hoàn thiện hệ thống . . . 20
6 Tài liệu tham khảo 21

1 Giới thiệu bài toán

1.1 Bối cảnh nghiên cứu

Trong những năm gần đây, các mô hình tạo sinh hình ảnh như Stable Diffusion [1], DALL-E [2], FLUX [3] và nhiều mô hình thế hệ mới đã có khả năng tạo ra hình ảnh chất lượng cao, đa dạng và ngày càng chân thực. Thông qua mô tả bằng ngôn ngữ tự nhiên, người dùng có thể tạo ra hình ảnh về con người, vật thể, phong cảnh hoặc những sự kiện chưa từng tồn tại. Sự phát triển này mang lại nhiều ứng dụng trong thiết kế, quảng cáo, giáo dục, giải trí và sáng tạo nội dung. Tuy nhiên, khả năng tạo ảnh ngày càng chân thực cũng đặt ra thách thức mới cho bài toán xác thực hình ảnh. Nếu trước đây trọng tâm trong lĩnh vực phân tích hình ảnh là xác định ảnh có bị chỉnh sửa hay không, thì hiện nay cần quan tâm thêm các câu hỏi như: ảnh có được tạo bởi AI hay không, nguồn nào có khả năng tạo ra ảnh và những dấu hiệu nào cho thấy điều đó.

Việc phân tích ảnh tạo sinh đặt ra hai bài toán có liên quan nhưng đòi hỏi những loại bằng chứng khác nhau. Thứ nhất, bài toán nhận diện ảnh tạo sinh (AI-generated image detection) nhằm phân biệt ảnh thật và ảnh được tạo bởi các hệ thống AI. Các bằng chứng phục vụ nhiệm vụ này có thể bao gồm những bất thường về kết cấu, quy luật vật lý, quan hệ ngữ nghĩa giữa các vật thể, cũng như các dấu vết thống kê ở mức điểm ảnh và miền tần số. Thứ hai, bài toán truy tìm nguồn tạo sinh (source attribution) hướng đến xác định mô hình hoặc hệ thống có khả năng đã tạo ra hình ảnh. Khác với bài toán nhận diện, nhiệm vụ này đòi hỏi những bằng chứng có khả năng phân biệt giữa các nguồn tạo sinh, chẳng hạn các đặc trưng thống kê hoặc dấu vân tay mô hình (model fingerprints). Đáng chú ý, một dấu vết có thể hữu ích trong việc phân biệt ảnh thật và ảnh tạo sinh nhưng không nhất thiết mang đủ thông tin để xác định nguồn sinh cụ thể, bởi những dấu vết tương tự có thể xuất hiện ở nhiều mô hình khác nhau. Ngược lại, một số dấu vết đặc trưng cho nguồn sinh có thể khó quan sát trực tiếp hoặc dễ bị ảnh hưởng bởi các phép xử lý ảnh. Vì vậy, việc phát hiện dấu vết tạo sinh cần đi kèm với phân tích vai trò và sự đóng góp của từng bằng chứng đối với từng bài toán. Các nghiên cứu gần đây như AIDE [4] cũng cho thấy nhiều bộ phát hiện hiện có vẫn gặp khó khăn trên Chameleon [4], một tập ảnh tạo sinh có mức độ chân thực cao. Điều này cho thấy sự cần thiết của việc khai thác và kết hợp các dấu vết tạo sinh ở nhiều mức độ nhằm nâng cao khả năng nhận diện, truy tìm nguồn và giải thích kết quả.

Nhìn chung, thách thức trong phân tích ảnh tạo sinh không chỉ nằm ở việc đưa ra kết quả phân loại chính xác mà còn ở khả năng xác định những bằng chứng thực sự hỗ trợ cho từng kết luận. Các dấu vết tạo sinh có thể tồn tại ở nhiều mức độ và vị trí khác nhau, từ các bất thường trực quan có thể định vị trên ảnh đến những đặc trưng thống kê phân bố trên toàn bộ hình ảnh. Do đó, nghiên cứu này được đề xuất nhằm phân tích, hệ thống hóa và biểu diễn các dấu vết tạo sinh, đồng thời xác định vai trò của chúng trong nhận diện ảnh tạo sinh và truy tìm nguồn gốc. Trên cơ sở đó, nghiên cứu hướng đến xây dựng cơ chế suy luận và lý giải dựa trên bằng chứng, trong đó các kết luận về trạng thái và nguồn tạo sinh của ảnh được liên kết với những dấu vết tương ứng, góp phần nâng cao tính minh bạch và khả năng kiểm chứng của hệ thống.

1.2 Định nghĩa bài toán

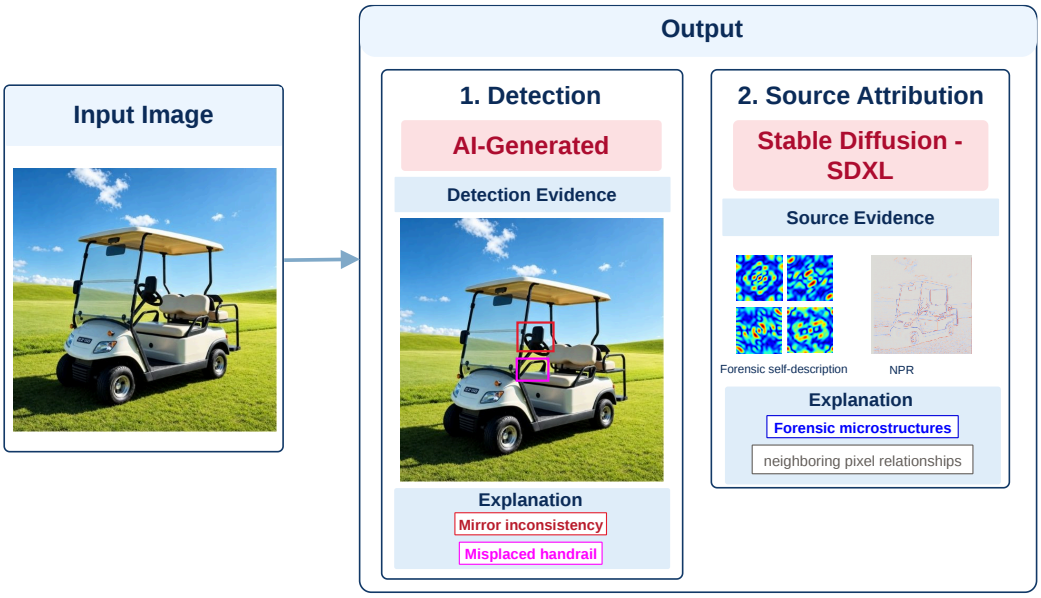
Bài toán được minh họa trong Hình 1, với mục tiêu phân tích các dấu vết tạo sinh trong hình ảnh nhằm hỗ trợ nhận diện ảnh tạo sinh, truy tìm nguồn gốc và lý giải kết quả dựa trên bằng chứng. Bài toán được tổng quát hóa như sau:

- **Đầu vào:** Một hình ảnh bất kỳ I.
- **Đầu ra:**
  - (1) $\hat{y} \in \{\text{Real}, \text{AI-Generated}\}$: nhãn dự đoán cho biết ảnh là ảnh thật hay ảnh tạo sinh.
  - (2) E_{det}: tập các bằng chứng hỗ trợ nhận diện ảnh tạo sinh.
  - (3) $\hat{s} \in \mathcal{S} \cup \{\text{Unknown}, \text{N/A}\}$: nguồn tạo sinh được dự đoán, trong đó $\mathcal{S}$ là tập các nguồn đã biết. Nhãn Unknown được sử dụng khi ảnh được nhận diện là ảnh tạo sinh nhưng không đủ cơ sở để gán cho một nguồn đã biết, trong khi N/A áp dụng cho ảnh được phân loại là ảnh thật.
  - (4) E_{src}: tập các bằng chứng có khả năng phân biệt giữa các nguồn tạo sinh.
  - (5) R: lời giải thích dựa trên các bằng chứng tương ứng.

Các bằng chứng trong E_{det} và E_{src} có thể được biểu diễn dưới nhiều dạng, bao gồm vùng ảnh (bounding box, segmentation mask) hoặc đặc trưng thống kê toàn cục. Hai tập bằng chứng này không nhất thiết độc lập, nghĩa là một dấu vết có thể

hỗ trợ cả hai nhiệm vụ. Như vậy, đầu ra kỳ vọng của hệ thống được biểu diễn bởi:

$$F(I) = (\hat{y}, E_{\text{det}}, \hat{s}, E_{\text{src}}, R). \tag{1}$$



Hình 1. Minh họa đầu vào (input) và đầu ra (output) của hệ thống một cách tổng quan.

1.3 Khoảng trống và động lực nghiên cứu

Mặc dù các nghiên cứu về nhận diện và truy tìm nguồn gốc ảnh tạo sinh đã đạt được nhiều tiến bộ, vẫn còn những thách thức liên quan đến việc khai thác, phân tích và sử dụng các dấu vết tạo sinh làm bằng chứng cho quá trình suy luận. Nghiên cứu được đề xuất xuất phát từ ba vấn đề chính:

- **Thứ nhất, các dấu vết tạo sinh chưa được khai thác và phân tích một cách thống nhất theo vai trò của từng loại bằng chứng.** Ảnh tạo sinh có thể chứa đồng thời nhiều loại dấu vết khác nhau, từ các đặc trưng thống kê ở mức điểm ảnh, miền tần số đến các bất thường về kết cấu, hình học, quy luật vật lý và quan hệ ngữ nghĩa giữa các vật thể. Các nghiên cứu hiện nay đã khai thác những khía cạnh này theo nhiều hướng tiếp cận khác nhau. Chẳng hạn, HyperDet [5] và NPR [6] tập trung vào các tín hiệu cấp thấp và quan hệ giữa các điểm ảnh; Sarkar và cộng sự [7] khai thác các bất thường hình học và quan hệ vật thể–bóng; trong khi AnomReason [8] tập trung vào các bất thường ngữ nghĩa. Một số nghiên cứu gần đây cũng đã kết hợp nhiều loại đặc trưng nhằm cải thiện khả năng nhận diện ảnh tạo sinh. Tuy nhiên, bên cạnh việc kết hợp

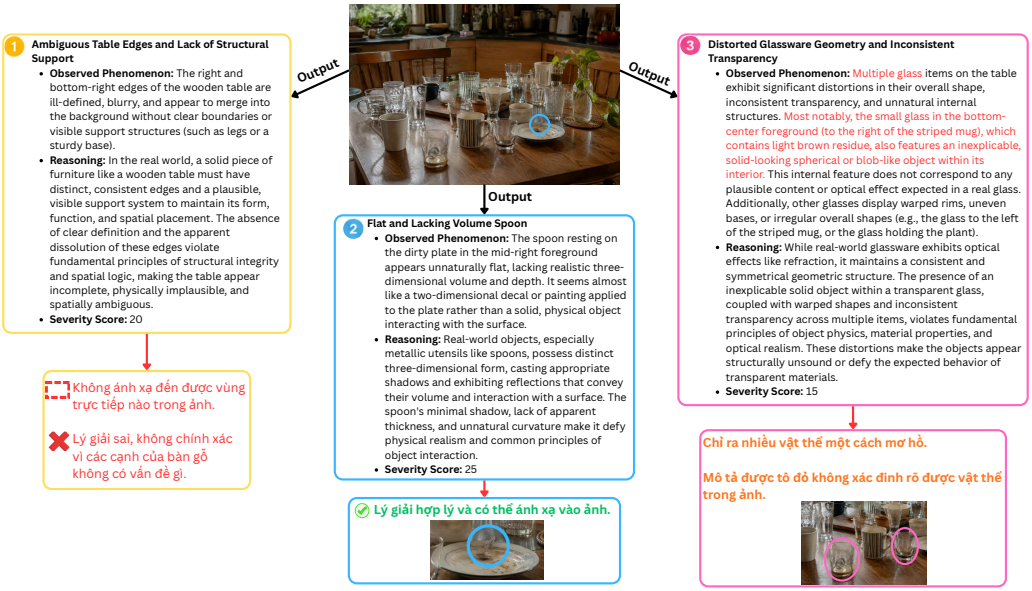
các đặc trưng để nâng cao hiệu quả phân loại, vẫn cần phân tích rõ hơn vai trò và giá trị của từng loại dấu vết đối với các nhiệm vụ khác nhau. Đặc biệt, một dấu vết có thể hữu ích trong việc phân biệt ảnh thật và ảnh tạo sinh nhưng chưa chắc mang đủ thông tin để phân biệt giữa các nguồn tạo sinh. Ngược lại, một số dấu vết có tính đặc trưng cho nguồn sinh có thể không dễ quan sát trực tiếp hoặc không thể định vị bằng một vùng ảnh cụ thể. Vì vậy, việc nghiên cứu cách phát hiện, biểu diễn và hệ thống hóa các dấu vết tạo sinh ở nhiều mức độ, đồng thời đánh giá khả năng đóng góp của chúng đối với từng nhiệm vụ, là cơ sở quan trọng để xây dựng quá trình phân tích dựa trên bằng chứng.

- **Thứ hai, tính nhất quán và độ trung thực của lời giải thích đối với các bằng chứng trong bài toán nhận diện ảnh tạo sinh chưa đáng tin cậy.** Sự phát triển của các mô hình ngôn ngữ lớn đa phương thức (MLLM) đã mở ra hướng tiếp cận kết hợp nhận diện ảnh tạo sinh với định vị bằng chứng và sinh lời giải thích bằng ngôn ngữ tự nhiên. Tiêu biểu, AIGI-Holmes [9] xây dựng bộ dữ liệu chứa nhãn nhận diện cùng các lời giải thích tương ứng; SIDA [10] kết hợp nhận diện, định vị và giải thích trong cùng một hệ thống. Gần đây, FakeXplain [11] tiếp tục phát triển hướng tiếp cận này thông qua việc xây dựng dữ liệu gồm các vùng bất thường được chú thích và mô tả bằng ngôn ngữ tự nhiên, nhằm cải thiện khả năng giải thích gắn với bằng chứng thị giác. Những nghiên cứu này cho thấy tiềm năng của việc kết hợp phát hiện, định vị và lý giải trong phân tích ảnh tạo sinh. Tuy nhiên, việc một mô hình có thể đưa ra lời giải thích hợp lý và xác định được vùng ảnh tương ứng chưa đủ để khẳng định rằng những bằng chứng đó thực sự được sử dụng trong quá trình đưa ra quyết định. Minh họa trong Hình 2 cho thấy một số trường hợp lời giải thích còn sai lệch, mô tả đối tượng mơ hồ hoặc khó ánh xạ chính xác đến vùng ảnh được đề cập. Bên cạnh đó, nghiên cứu X-AIGD [12] cũng chỉ ra rằng các bộ phát hiện ảnh tạo sinh có thể chưa thực sự dựa nhiều vào những bất thường trực quan có thể diễn giải, ngay cả khi được huấn luyện để nhận biết các dấu vết này. Điều đó đặt ra yêu cầu không chỉ định vị và mô tả bằng chứng, mà còn phải kiểm chứng mối liên hệ giữa bằng chứng được trình bày và quyết định của hệ thống. Vì vậy, nghiên cứu này hướng đến cơ chế suy luận và lý giải dựa trên bằng chứng có thể kiểm chứng, thay vì chỉ tạo ra những lời giải thích có vẻ hợp lý sau khi đã đưa ra kết quả phân loại.
- **Thứ ba, mối quan hệ giữa dấu vết tạo sinh và khả năng lý giải kết quả**

truy tìm nguồn tạo sinh chưa được làm rõ đầy đủ. Bài toán truy tìm nguồn gốc ảnh tạo sinh (source attribution) đã đạt nhiều tiến bộ nhờ các phương pháp học đặc trưng và dấu vân tay mô hình (model fingerprints) từ dữ liệu ảnh. Các bộ dữ liệu và benchmark [13, 14, 15, 16] ngày càng mở rộng sang nhiều nguồn sinh, bao gồm cả các hệ thống thương mại và mã nguồn đóng (closed-source). Tuy nhiên, phần lớn các phương pháp vẫn tập trung tối ưu khả năng phân loại mà chưa làm rõ đầy đủ bản chất và nguyên nhân hình thành các dấu vết phân biệt nguồn. Đặc biệt, với các hệ thống mã nguồn đóng, thông tin về kiến trúc, trọng số và quy trình sinh ảnh thường không được công khai, gây khó khăn cho việc phân tích sâu. Vì vậy, nghiên cứu này ưu tiên khai thác các mô hình mã nguồn mở như một môi trường có kiểm soát để tìm hiểu mối quan hệ giữa cơ chế tạo sinh và dấu vết quan sát được. Các dấu vết này có thể chịu ảnh hưởng từ kiến trúc mô hình, dữ liệu huấn luyện và quá trình sinh ảnh, trong khi nhiều đặc trưng cấp thấp như nhiễu, tương quan điểm ảnh và phổ tần số thường khó diễn giải trực quan. Mặc dù một số nghiên cứu [17, 18] đã phân tích dấu vân tay mô hình, việc phân tách ảnh hưởng của từng yếu tố và xác định các bằng chứng thực sự mang giá trị phân biệt nguồn vẫn cần được nghiên cứu sâu hơn. Gần đây, EXACT [19] đã kết hợp nhận diện, truy tìm nguồn, định vị và giải thích bằng ngôn ngữ tự nhiên, nhưng việc tích hợp các chức năng này chưa đồng nghĩa với việc đã làm rõ nguồn gốc và mức độ đóng góp của từng bằng chứng. Do đó, nghiên cứu hướng đến phân tích bản chất các dấu vết tạo sinh, lựa chọn bằng chứng có giá trị phân biệt nguồn và xây dựng lời giải thích có thể kiểm chứng, đồng thời hỗ trợ nhận biết và từ chối gán nguồn khi gặp các mô hình chưa xuất hiện trong dữ liệu huấn luyện.

Những khoảng trống nghiên cứu trên đã đặt ra ba câu hỏi nghiên cứu chính làm động lực thúc đẩy cho nghiên cứu này, bao gồm:

- **Research Question 1 – Evidence Discovery and Localization:** Làm thế nào để phát hiện, biểu diễn và định vị các dấu vết tạo sinh ở nhiều mức độ, đồng thời đánh giá vai trò của chúng như những bằng chứng phục vụ nhận diện ảnh tạo sinh và truy tìm nguồn?
- **Research Question 2 – Evidence-based Source Attribution:** Làm thế nào để phân tích mối quan hệ giữa cơ chế tạo sinh và các dấu vết quan sát được nhằm lựa chọn những bằng chứng có giá trị phân biệt nguồn?
- **Research Question 3 – Faithful Evidence-grounded Explanation:** Làm thế



Hình 2. Một số hạn chế trong giải thích của AnomAgent [8]: các mô tả dài và phức tạp dẫn đến định vị bằng chứng mơ hồ hoặc không thể xác định chính xác vật thể được đề cập trong ảnh.

nào để xây dựng và kiểm chứng quá trình suy luận, lý giải kết quả nhận diện và truy tìm nguồn, bảo đảm rằng các bằng chứng được trình bày có mối liên hệ rõ ràng và thực sự đóng góp vào quyết định của hệ thống?

2 Mục tiêu nghiên cứu

2.1 MT1: Phân tích, biểu diễn và định vị các dấu vết tạo sinh trong hình ảnh

Mục tiêu đầu tiên là xây dựng phương pháp phân tích hình ảnh từ nhiều góc nhìn nhằm phát hiện, hệ thống hóa và biểu diễn các dấu vết liên quan đến quá trình tạo sinh. Các dấu vết này có thể tồn tại ở nhiều mức độ, từ các đặc trưng cấp thấp như phân bố nhiễu, quan hệ điểm ảnh và miền tần số đến các bất thường cấp cao về kết cấu, hình học, quy luật vật lý và quan hệ ngữ nghĩa. Thay vì chỉ trích xuất các vector đặc trưng phục vụ phân loại, nghiên cứu hướng đến xây dựng một tập bằng chứng có cấu trúc, trong đó mỗi bằng chứng được phân tích về đặc điểm, vai trò và khả năng đóng góp cho hai nhiệm vụ: nhận diện ảnh tạo sinh và truy tìm nguồn tạo sinh.

Bên cạnh đó, nghiên cứu hướng đến khả năng định vị và biểu diễn trực quan các bằng chứng khi phù hợp, thông qua vùng ảnh, bản đồ đóng góp hoặc các đặc trưng thống kê. Do không phải mọi dấu vết đều có thể ánh xạ đến một vùng ảnh cụ thể, phương pháp cần hỗ trợ các hình thức biểu diễn khác nhau tùy theo bản chất của bằng chứng. Kết quả được đánh giá dựa trên khả năng phát hiện, độ chính xác định

vị đối với các bằng chứng có chú thích vị trí và mức độ ổn định của các dấu vết trong những điều kiện ảnh khác nhau. Qua đó, nghiên cứu hướng đến xây dựng một lớp biểu diễn bằng chứng làm cơ sở cho các nhiệm vụ truy tìm nguồn và suy luận, lý giải ở các giai đoạn tiếp theo.

2.2 MT2: Truy tìm nguồn tạo sinh dựa trên các bằng chứng phân biệt nguồn

Mục tiêu thứ hai là phát triển phương pháp xác định nguồn tạo sinh dựa trên các dấu vết và bằng chứng đã được phân tích. Do không phải mọi dấu vết giúp nhận diện ảnh tạo sinh đều có giá trị phân biệt giữa các nguồn sinh, nghiên cứu tập trung đánh giá, lựa chọn và kết hợp những bằng chứng có khả năng đặc trưng cho từng mô hình hoặc nhóm mô hình tạo sinh. Đặc biệt, nghiên cứu ưu tiên khai thác các mô hình tạo sinh mã nguồn mở như một môi trường có kiểm soát để phân tích mối quan hệ giữa kiến trúc mô hình, dữ liệu huấn luyện, quy trình sinh ảnh và các dấu vết quan sát được. Trên cơ sở đó, nghiên cứu hướng đến xác định những đặc trưng thực sự có giá trị phân biệt nguồn, hạn chế sự phụ thuộc vào nội dung, phong cách hoặc các khác biệt không liên quan đến bản chất của quá trình tạo sinh. Hiệu quả được đánh giá thông qua độ chính xác truy tìm nguồn, mức độ đóng góp của từng nhóm bằng chứng và khả năng duy trì kết quả trong các điều kiện dữ liệu khác nhau.

Bên cạnh khả năng phân biệt các nguồn đã biết, nghiên cứu còn hướng đến việc nhận biết các nguồn tạo sinh chưa xuất hiện trong dữ liệu huấn luyện. Trong những trường hợp không đủ bằng chứng để xác định nguồn, hệ thống cần có khả năng từ chối gán nhãn thay vì buộc ảnh thuộc về một nguồn đã biết. Đồng thời, nghiên cứu xem xét khả năng thích nghi với nguồn tạo sinh mới khi có thêm dữ liệu tham chiếu, nhằm hỗ trợ mở rộng hệ thống mà không cần huấn luyện lại toàn bộ mô hình.

2.3 MT3: Suy luận và lý giải kết quả nhận diện và truy tìm nguồn dựa trên bằng chứng

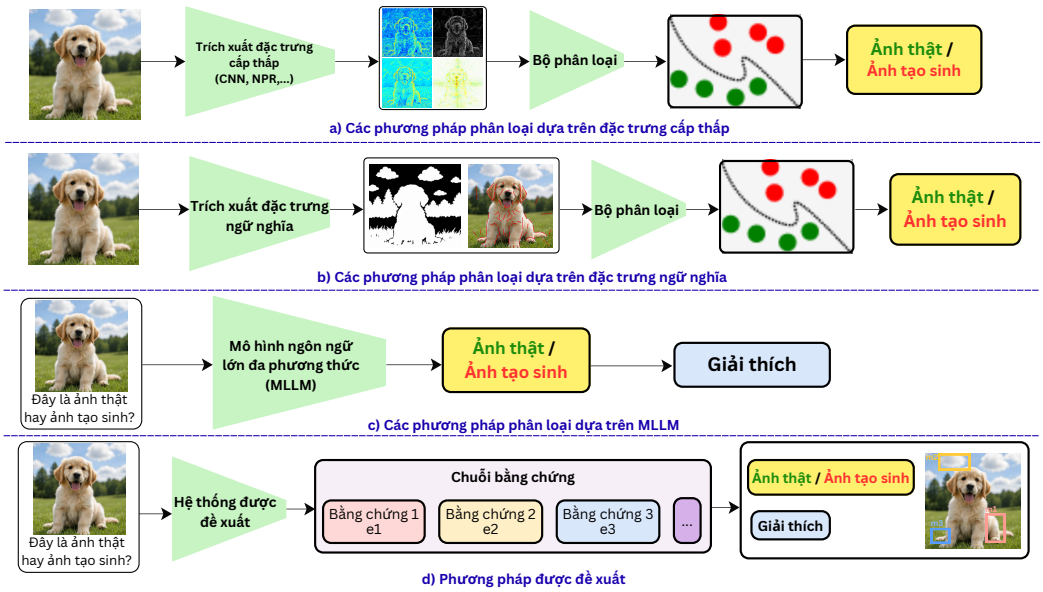
Mục tiêu thứ ba là xây dựng cơ chế suy luận và lý giải kết quả nhận diện ảnh tạo sinh và truy tìm nguồn dựa trên các bằng chứng đã được phát hiện, phân tích và lựa chọn. Thay vì chỉ sử dụng mô hình ngôn ngữ lớn đa phương thức (MLLM) để sinh lời giải thích trực tiếp từ hình ảnh hoặc kết quả phân loại, nghiên cứu hướng đến việc kết hợp các bằng chứng, thông tin vị trí khi có thể xác định và mức độ đóng góp của chúng để hình thành lời giải thích có cơ sở. Đối với bài toán nhận diện, lời giải thích cần làm rõ những dấu vết nào hỗ trợ kết luận ảnh tạo sinh; trong khi đối với bài toán

truy tìm nguồn, cần chỉ ra những bằng chứng nào mang giá trị phân biệt và hỗ trợ việc lựa chọn nguồn sinh tương ứng.

Đặc biệt, nghiên cứu không chỉ hướng đến những lời giải thích hợp lý về mặt ngôn ngữ mà còn chú trọng tính nhất quán và độ trung thực của chúng đối với quyết định của hệ thống. Điều này đòi hỏi cơ chế kiểm chứng mối liên hệ giữa bằng chứng và kết quả dự đoán, chẳng hạn đánh giá sự thay đổi của quyết định khi loại bỏ hoặc làm suy yếu một bằng chứng trong điều kiện kiểm soát. Đồng thời, hệ thống cần hạn chế những giải thích sai lệch, không có cơ sở và thể hiện được mức độ bất định khi bằng chứng chưa đủ để đưa ra kết luận đáng tin cậy. Qua đó, nghiên cứu hướng đến nâng cao tính minh bạch, khả năng kiểm chứng và độ tin cậy của quá trình phân tích nguồn gốc ảnh tạo sinh.

3 Tổng quan tình hình nghiên cứu

3.1 Bài toán nhận diện ảnh thật và ảnh tạo sinh



Hình 3. Minh họa các hướng tiếp cận cho bài toán nhận diện ảnh thật và ảnh tạo sinh.

Hình 3 minh họa các hướng tiếp cận trực quan cho bài toán nhận diện ảnh thật và ảnh tạo sinh. Cụ thể:

Thứ nhất, với hướng tiếp cận phân tích tín hiệu cấp thấp và đặc trưng thống kê.

Các nghiên cứu đầu tiên xem detection như một bài toán phân loại nhị phân dựa trên các đặc trưng hình ảnh. Các hệ thống ban đầu [20, 21] sử dụng đặc trưng trích

xuất từ mạng CNN hoặc các mô hình thị giác tiền huấn luyện để phân loại giữa ảnh thật và ảnh tạo sinh. Mặc dù các phương pháp này ban đầu đạt kết quả rất cao (ACC: 85-90%), nhưng thành công này phần lớn xuất phát từ tính chất lý tưởng của dữ liệu: các mô hình tạo sinh (generator) thế hệ cũ còn đơn giản, dễ để lại các dấu vết khiếm khuyết (artifacts) rõ ràng mà mắt người đôi khi có thể phân biệt được, và tập ảnh thử nghiệm có độ phân giải cao mà chưa qua nén dữ liệu. Tuy nhiên, khi các bộ dữ liệu ngày càng được nâng cấp để phản ánh sát môi trường thực tế, nơi ảnh thường bị giảm chất lượng qua các nền tảng mạng xã hội, và các mô hình sinh liên tục phát triển lên nhiều phiên bản mới, các phương pháp phân loại dựa trên đặc trưng hình ảnh đơn thuần này thường vấp phải thất bại nghiêm trọng trong khả năng tổng quát hóa [22, 15, 23].

Để cải thiện khả năng nhận diện, nhiều nghiên cứu tập trung khai thác những dấu vết vi mô ở mức điểm ảnh như phân bố nhiễu, phổ tần số và quan hệ không gian giữa các điểm ảnh. Cụ thể, HyperDet [5] khai thác nhóm bộ lọc pháp chứng SRM (Spatial Rich Model) — tập hợp các bộ lọc thông cao (high-pass filters) giúp triệt tiêu nội dung ảnh và giữ lại các đường nét ranh giới (edges) trên ảnh, tạo ra nhiều góc nhìn phân tích đa dạng cho các đường nét trong ảnh. Trong khi đó, NPR (Neighboring Pixel Relationships) tập trung phân tích mối quan hệ tương quan giữa các điểm ảnh lân cận nhằm phát hiện các chênh lệch bất thường xuất phát từ cơ chế tăng kích thước ảnh (upsampling) trong các mô hình tạo sinh [6]. Phương pháp này có khả năng phát hiện hiệu quả trên cả kiến trúc mô hình GAN lẫn Diffusion Models. Nhờ vậy, tín hiệu NPR đã trở thành một đặc trưng rất phổ biến trong lĩnh vực này và được nhiều bài báo sau đó tiếp tục kế thừa để phân loại ảnh tạo sinh.

Ưu điểm của hướng tiếp cận dựa trên tín hiệu cấp thấp là khả năng khai thác các dấu vết thống kê khó nhận biết bằng mắt thường, ngay cả khi hình ảnh không chứa những bất thường trực quan rõ rệt. Tuy nhiên, các đặc trưng này thường khó diễn giải trực tiếp bằng ngôn ngữ tự nhiên và khó xác định ý nghĩa của chúng đối với từng quyết định phân loại. Bên cạnh đó, hiệu quả của các phương pháp còn có thể chịu ảnh hưởng bởi sự thay đổi phân bố dữ liệu và các phép xử lý ảnh. Vì vậy, độ chính xác phân loại cao chưa đủ để khẳng định rằng hệ thống đã xác định được những bằng chứng thực sự phản ánh quá trình tạo sinh, đặt ra nhu cầu nghiên cứu các phương pháp có khả năng phân tích và kiểm chứng vai trò của từng dấu vết trong quyết định nhận diện.

Thứ hai, với hướng tiếp cận phân tích bất thường ở mức độ ngữ nghĩa trên

ảnh.

Một hướng đi khác đặt trọng tâm vào những khuyết điểm trực quan (visible artifacts) mà con người có thể quan sát và nhận biết trực tiếp trên bức ảnh. Trong lĩnh vực phân tích ảnh giả khuôn mặt, các nghiên cứu đã khai thác những dấu hiệu như sự biến dạng đồng tử [24], bất thường cấu trúc khuôn mặt [25] hoặc sự không nhất quán của các vật thể phụ trợ như gọng kính [26]. Những dấu hiệu này có ưu điểm là dễ quan sát và có thể liên hệ trực tiếp lên các vùng trong ảnh. Tuy nhiên, khi các mô hình tạo sinh ngày càng hoàn thiện, những khiếm khuyết trực quan đơn giản có thể trở nên ít rõ ràng hơn, khiến việc chỉ dựa vào một số loại bất thường riêng lẻ khó bảo đảm khả năng nhận diện ổn định.

Để giải quyết hạn chế này, các nghiên cứu gần đây đã dịch chuyển từ việc phát hiện các lỗi hình dáng cục bộ sang khai thác các quy luật vật lý và hình học không gian toàn cục. Nghiên cứu của Sarkar và cộng sự [7] khai thác các dấu hiệu không nhất quán về hình học, đường thẳng, bóng và quan hệ vật thể–bóng để nhận diện ảnh tạo sinh. Công trình này đưa các nguyên lý hình học của thế giới thực vào bài toán phát hiện ảnh tạo sinh. Đây là một hướng tiếp cận khá thú vị khi khai thác một góc nhìn trực quan trong ảnh và kiểm tra toàn bộ quan hệ không gian trong ảnh. Theo hướng phân tích ngữ nghĩa, AnomReason [8] được phát triển như một benchmark dành cho bài toán phát hiện và suy luận các bất thường ngữ nghĩa trong ảnh tạo sinh. Họ cố gắng xây dựng bộ dữ liệu liệt kê toàn bộ các bất thường dưới dạng có cấu trúc. Ví dụ, một bất thường được bài báo định nghĩa dưới 4 trường thông tin chính (minh họa ở Hình 2), bao gồm: tên (name), hiện tượng quan sát (phenomenon), lý do suy luận (reasoning) và mức độ nghiêm trọng (severity). Phương pháp này đáng chú ý với cách biểu diễn cấu trúc các thành phần một cách rõ ràng, giúp phân tích chi tiết nguyên nhân bất hợp lý, tạo cơ sở để kiểm định kết quả phân loại.

Ưu điểm nổi bật của hướng tiếp cận dựa trên các bất thường trực quan là mang lại khả năng giải thích cao, giúp con người dễ dàng quan sát và đối chiếu bằng chứng. Tuy nhiên, nhược điểm lớn nằm ở chỗ các bất thường ngữ nghĩa không phải lúc nào cũng là đặc trưng duy nhất để xác định ảnh tạo sinh. Một bức ảnh thật vẫn có thể chứa những điểm kỳ lạ do ý đồ nghệ thuật của nhiếp ảnh gia; ngược lại, không phải mọi ảnh tạo sinh đều xuất hiện lỗi trực quan rõ rệt. Để khắc phục các hạn chế đơn lẻ, xu hướng nghiên cứu hiện nay đang hướng tới việc kết hợp cả đặc trưng cấp thấp (như chênh lệch điểm ảnh,...) và đặc trưng cấp cao (như cấu trúc ngữ nghĩa của các đối tượng) vào cùng một hệ thống phân loại [19, 27]. Dù vậy, mặc dù việc tích hợp

đa cấp độ này mang lại độ chính xác cao cho bài toán phân loại nhị phân, hệ thống vẫn tồn tại nhiều bất cập nghiêm trọng trong việc suy luận, giải thích bản chất và định vị chính xác vùng bằng chứng mà mô hình đã dựa vào để đưa ra quyết định.

Thứ ba, các phương pháp tích hợp định vị và lý giải kết quả nhận diện dựa trên bằng chứng.

Gần đây, việc ứng dụng các mô hình đa phương thức lớn (MLLM) đã mở ra xu hướng mới trong việc kết hợp khả năng phân loại với sinh giải thích bằng ngôn ngữ tự nhiên và định vị vùng bất thường trên ảnh. Điển hình, AIGI-Holmes [9] xây dựng tập dữ liệu Holmes-Set chứa các nhãn phân loại cùng lời giải thích chi tiết, đồng thời áp dụng quy trình huấn luyện nhiều giai đoạn nhằm nâng cao khả năng giải thích dựa trên tín hiệu thị giác. Trong khi đó, SIDA [10] mở rộng quy mô với tập dữ liệu SID-Set (300.000 ảnh) và đề xuất hệ thống dựa trên MLLM, cho phép thực hiện đồng thời ba tác vụ: phân loại ảnh, định vị vùng ảnh tạo sinh bằng mặt nạ phân đoạn (segmentation mask), và sinh văn bản giải thích. Mặc dù đạt được những tiến bộ đáng ghi nhận, các tiếp cận này vẫn tồn tại một hạn chế cốt lõi: lời giải thích và kết quả định vị vùng bất thường được sinh ra đồng thời nhờ vào một mô hình LISA [28], một MLLM có khả năng phân đoạn vật thể trên ảnh. Nói cách khác, hệ thống vẫn có thể đưa ra một lời giải thích nghe rất hợp lý nhưng không thực sự dựa trên bằng chứng thị giác mà nó đã khoanh vùng.

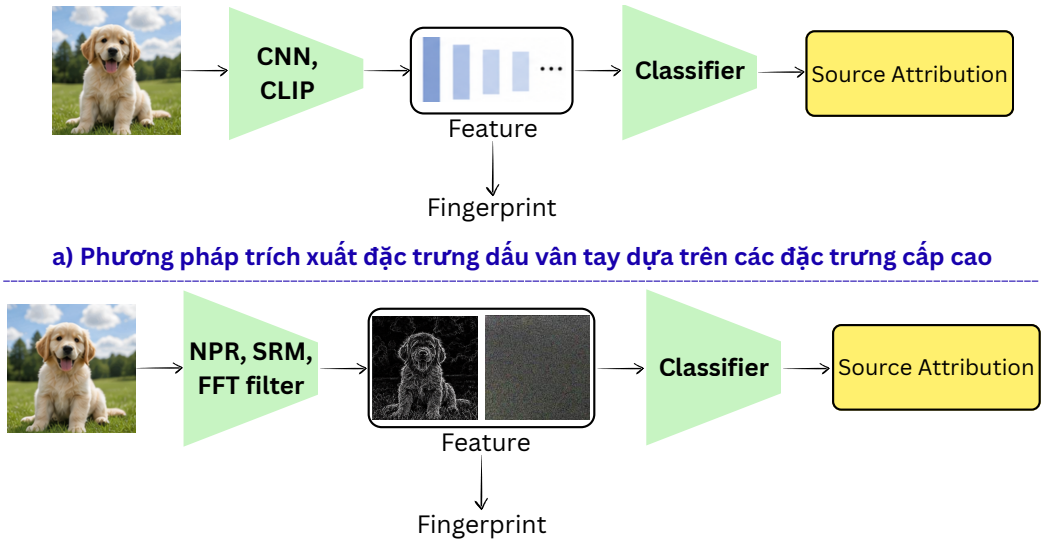
Gần đây, FakeXplain [11] tiếp tục phát triển hướng tiếp cận giải thích gắn với bằng chứng thị giác. Công trình xây dựng bộ dữ liệu FakeXplained, trong đó các bất thường tạo sinh được chú thích bằng bounding box và mô tả ngôn ngữ tương ứng, sau đó sử dụng dữ liệu này để huấn luyện FakeXplainer thực hiện đồng thời nhận diện ảnh tạo sinh, định vị dấu vết và sinh lời giải thích. Bên cạnh đó, X-AIGD [12] đề xuất một benchmark với các chú thích bất thường ở mức chi tiết nhằm đánh giá khả năng diễn giải của những bộ phát hiện ảnh tạo sinh. Kết quả phân tích của X-AIGD cho thấy các bộ phát hiện hiện có có thể vẫn phụ thuộc đáng kể vào những đặc trưng khó diễn giải, ngay cả khi được huấn luyện để nhận biết các bất thường trực quan. Những kết quả này cho thấy tầm quan trọng của việc đánh giá không chỉ độ chính xác phân loại mà còn cả sự liên hệ giữa bằng chứng và quyết định của mô hình.

Tuy nhiên, khả năng sinh lời giải thích và định vị vùng ảnh tương ứng chưa đồng nghĩa với việc các bằng chứng được trình bày thực sự đóng góp vào quyết định phân loại. Chẳng hạn, các trường hợp minh họa trong Hình 2, được phân tích từ kết quả

chú thích của AnomAgent [8], cho thấy một số mô tả bất thường có thể chưa chính xác, đề cập đối tượng một cách mơ hồ hoặc khó ánh xạ đến vùng ảnh cụ thể. Những trường hợp này phản ánh nguy cơ thiếu nhất quán giữa lời giải thích và bằng chứng thị giác, nhưng chưa đủ để kết luận rằng toàn bộ quá trình suy luận của mô hình chỉ mang tính hợp lý hóa sau dự đoán (post-hoc rationalization). Tương tự, ngay cả khi lời giải thích được liên kết với một vùng ảnh xác định, vẫn cần kiểm chứng liệu vùng đó có thực sự ảnh hưởng đến kết quả phân loại hay không.

Nhìn chung, các nghiên cứu gần đây đã đạt nhiều tiến bộ trong việc kết hợp nhận diện, định vị và giải thích ảnh tạo sinh. Tuy nhiên, một vấn đề cần tiếp tục nghiên cứu là đánh giá tính nhất quán và độ trung thực (faithfulness) của lời giải thích đối với những bằng chứng mà hệ thống thực sự sử dụng. Vì vậy, hướng nghiên cứu này không chỉ tập trung phát hiện và biểu diễn các dấu vết tạo sinh mà còn hướng đến phân tích vai trò, mức độ đóng góp của từng bằng chứng và xây dựng cơ chế suy luận, lý giải có thể kiểm chứng. Đây là cơ sở để mở rộng việc phân tích bằng chứng từ nhận diện ảnh tạo sinh sang truy tìm nguồn gốc, trong đó các dấu vết cần được đánh giá thêm về khả năng phân biệt giữa những nguồn tạo sinh khác nhau.

3.2 Bài toán truy tìm nguồn gốc tạo sinh ảnh



Hình 4. Minh họa hai hướng khai thác đặc trưng cấp cao và dấu vết pháp chứng cấp thấp cho bài toán truy tìm nguồn tạo sinh ảnh.

Khác với bài toán nhận diện ảnh tạo sinh nhằm phân biệt ảnh thật và ảnh do AI tạo ra, bài toán truy tìm nguồn gốc (source attribution) hướng đến xác định mô hình hoặc hệ thống có khả năng đã tạo ra một hình ảnh. Thách thức quan trọng của bài

toán này là khai thác những đặc trưng mang thông tin phân biệt giữa các nguồn tạo sinh, thường được gọi là dấu vân tay mô hình (model fingerprints). Hình 4 minh họa hai hướng khai thác đặc trưng phổ biến: đặc trưng cấp cao từ các mô hình thị giác và dấu vết pháp chứng cấp thấp. Bên cạnh việc trích xuất đặc trưng, các nghiên cứu gần đây còn mở rộng sang khả năng truy tìm nguồn chưa biết, kết hợp nhiều loại bằng chứng và lý giải kết quả. Có thể tổng hợp các hướng nghiên cứu chính như sau:

Thứ nhất, các phương pháp truy tìm nguồn dựa trên đặc trưng học sâu (feature-based attribution).

Hướng tiếp cận này khai thác khả năng biểu diễn hình ảnh của các mô hình thị giác được huấn luyện trước, chẳng hạn CNN hoặc CLIP, để phân biệt các nguồn tạo sinh. Tiêu biểu, Cioni và cộng sự [29] đề xuất sử dụng đặc trưng từ các mô hình thị giác nền tảng để thực hiện truy tìm nguồn trong điều kiện open-set, đồng thời cho thấy hiệu quả tốt hơn một số phương pháp dựa trên đặc trưng tần số trong các thiết lập thử nghiệm của họ. Ưu điểm của hướng tiếp cận này là tận dụng được các biểu diễn thị giác có khả năng tổng quát hóa, kể cả khi dữ liệu huấn luyện cho từng nguồn sinh còn hạn chế. Tuy nhiên, do các đặc trưng học sâu có thể chứa thông tin về nội dung, phong cách và phân bố dữ liệu, mô hình có nguy cơ khai thác những tương quan không trực tiếp phản ánh bản chất của nguồn tạo sinh. Vì vậy, độ chính xác phân loại cao chưa đủ để khẳng định các đặc trưng được sử dụng thực sự mang dấu vết đặc trưng của quá trình sinh ảnh.

Thứ hai, các phương pháp khai thác dấu vân tay pháp chứng (forensic fingerprint).

Khác với việc sử dụng các biểu diễn thị giác tổng quát, hướng tiếp cận này tập trung khai thác những dấu vết thống kê và cấu trúc tín hiệu mà quá trình tạo sinh có thể để lại trên ảnh, chẳng hạn phân bố nhiễu, tương quan điểm ảnh và đặc trưng miền tần số. Các nghiên cứu như ManiFPT [18] đã đề xuất cách định nghĩa và phân tích dấu vân tay mô hình. Gần đây nghiên cứu Causal Fingerprints [30] hướng đến việc tách dấu vết nguồn khỏi thông tin nội dung (content) và phong cách (style) thông qua không gian biểu diễn ít phụ thuộc ngữ nghĩa được xây dựng từ sai khác tái tạo của mô hình khuếch tán.

Những nghiên cứu này cho thấy tiềm năng của việc khai thác các dấu vết liên quan đến quá trình tạo sinh thay vì chỉ dựa trên biểu diễn nội dung ảnh. Tuy nhiên, các dấu vết pháp chứng thường khó diễn giải trực quan và có thể chịu ảnh hưởng bởi các phép xử lý hậu kỳ như nén, làm mờ hoặc thay đổi kích thước ảnh. Bên cạnh đó,

mặc dù Causal Fingerprints đã nghiên cứu khả năng tách thông tin nguồn khỏi nội dung và phong cách, kết quả thực nghiệm trong những thiết lập cụ thể chưa đồng nghĩa với việc đã xác định đầy đủ nguyên nhân hình thành dấu vết đối với mọi kiến trúc mô hình. Việc phân tích ảnh hưởng riêng của kiến trúc, dữ liệu huấn luyện, quá trình tối ưu và cơ chế sinh ảnh đến các dấu vết quan sát được vẫn là một hướng cần tiếp tục nghiên cứu.

Thứ ba, các phương pháp truy tìm nguồn trong môi trường mở (open-set source attribution).

Một thách thức quan trọng của bài toán truy tìm nguồn là khả năng xử lý hình ảnh đến từ những mô hình chưa xuất hiện trong dữ liệu huấn luyện. Khác với thiết lập closed-set, trong đó mọi ảnh tạo sinh được giả định thuộc một tập nguồn đã biết, thiết lập open-set yêu cầu hệ thống có khả năng nhận biết và từ chối gán nhãn khi ảnh không phù hợp với các nguồn đã quan sát. Tiêu biểu, POSE [31] đề xuất cơ chế mở rộng không gian nguồn chưa biết thông qua việc mô phỏng các dấu vết khác biệt trong khi duy trì nội dung ngữ nghĩa. Gần đây, đặc trưng Forensic Self-Descriptions [32] đã khai thác các cấu trúc pháp chứng vi mô thông qua các bộ lọc dự đoán và biểu diễn sai khác ở nhiều mức độ. Phương pháp này hỗ trợ nhận diện ảnh tạo sinh không cần mẫu huấn luyện từ nguồn sinh và truy tìm nguồn trong môi trường mở.

Thứ tư, các phương pháp truy tìm nguồn kết hợp bằng chứng và giải thích (evidence-aware attribution).

Bên cạnh việc nâng cao độ chính xác truy tìm nguồn, các nghiên cứu gần đây bắt đầu quan tâm đến khả năng kết hợp nhiều loại đặc trưng và cung cấp thông tin hỗ trợ lý giải kết quả. Tiêu biểu, EXACT [19] đề xuất hệ thống kết hợp hai nhánh biểu diễn: nhánh ngữ nghĩa dựa trên CLIP và nhánh dấu vết cấp thấp. Phương pháp sử dụng cơ chế kết hợp đặc trưng, đồng thời hỗ trợ nhận diện ảnh tạo sinh, truy tìm nguồn và định vị ở mức điểm ảnh. Ngoài ra, EXACT tích hợp mô hình đa phương thức lớn để tạo báo cáo pháp chứng bằng ngôn ngữ tự nhiên từ các kết quả phân tích. Đây là một bước tiến đáng chú ý trong việc kết hợp nhiều nguồn thông tin và mở rộng khả năng diễn giải của hệ thống.

Tuy nhiên, việc kết hợp các đặc trưng, định vị vùng ảnh và sinh báo cáo giải thích chưa đủ để khẳng định rằng các bằng chứng được trình bày thực sự mang tính đặc trưng cho nguồn sinh hoặc có đóng góp trực tiếp vào quyết định truy tìm nguồn. Đặc biệt, cần phân biệt giữa những dấu vết giúp xác định ảnh có nguồn gốc tạo sinh và những dấu vết có khả năng phân biệt giữa các mô hình tạo sinh khác nhau. Một bất

thường hình học hoặc ngữ nghĩa có thể hỗ trợ nhận diện ảnh tạo sinh nhưng không nhất thiết đủ để xác định nguồn sinh cụ thể. Ngược lại, các dấu vân tay cấp thấp có thể mang giá trị phân biệt nguồn nhưng khó được biểu diễn và giải thích trực quan. Do đó, khả năng lý giải trong source attribution cần được xây dựng dựa trên việc phân tích vai trò, giá trị phân biệt và mức độ đóng góp của từng bằng chứng, thay vì chỉ dựa trên kết quả phân loại và các mô tả được sinh ra sau đó.

Nhìn chung, các nghiên cứu về truy tìm nguồn tạo sinh đã đạt nhiều tiến bộ trong khai thác đặc trưng, phân tích dấu vân tay, xử lý nguồn chưa biết và kết hợp nhiều nhiệm vụ pháp chứng. Tuy nhiên, việc làm rõ mối quan hệ giữa cơ chế tạo sinh, dấu vết quan sát được và quyết định truy tìm nguồn vẫn cần được nghiên cứu sâu hơn. Đặc biệt, các hệ thống tạo sinh mã nguồn đóng thường không công khai đầy đủ kiến trúc, trọng số và quy trình sinh ảnh, gây khó khăn cho việc phân tích nguyên nhân hình thành dấu vết. Vì vậy, hướng nghiên cứu này ưu tiên khai thác các mô hình tạo sinh mở như một môi trường có kiểm soát để khảo sát ảnh hưởng của kiến trúc, dữ liệu huấn luyện và quy trình sinh ảnh đến những dấu vết đặc trưng. Trên cơ sở đó, nghiên cứu hướng đến xác định và lựa chọn các bằng chứng có giá trị phân biệt nguồn, kiểm chứng mức độ đóng góp của chúng vào quyết định và xây dựng lời giải thích đáng tin cậy, đồng thời hỗ trợ nhận biết những nguồn tạo sinh chưa xuất hiện trong dữ liệu huấn luyện.

3.3 Benchmark và dataset

Bộ dữ liệu đóng vai trò quan trọng trong việc nghiên cứu khả năng nhận diện, truy tìm nguồn tạo sinh và phân tích các dấu vết trên ảnh. Bảng 1 tổng hợp một số bộ dữ liệu và benchmark tiêu biểu, với sự khác biệt về quy mô, nguồn tạo sinh, nhiệm vụ đánh giá và các dạng chú thích bằng chứng.

Nhìn chung, các bộ dữ liệu hiện nay ngày càng đa dạng về quy mô, kiến trúc và nguồn tạo sinh. Những bộ dữ liệu như WildFake, AIGIBench và GenImage chủ yếu hỗ trợ đánh giá khả năng nhận diện và tổng quát hóa trên nhiều nguồn sinh, trong khi Synthbuster và DRAGON cung cấp nhãn nguồn tạo điều kiện cho các nghiên cứu truy tìm nguồn. Tuy nhiên, việc có nhãn mô hình sinh chưa đồng nghĩa với việc đã có giao thức đánh giá truy tìm nguồn trong môi trường mở (open-set attribution), đặc biệt đối với khả năng nhận biết và từ chối gán nguồn chưa biết.

Bên cạnh đó, SID-Set, AnomReason và FakeXplained đã bổ sung các chú thích về vùng ảnh bị can thiệp, bất thường ngữ nghĩa và lời giải thích. Tuy nhiên, những

Bảng 1. Tổng hợp các bộ dữ liệu và benchmark tiêu biểu cho bài toán nhận diện, truy tìm nguồn và phân tích bằng chứng tạo sinh.

Dataset / Year	**Samples**	**Generative Sources**	**Primary Tasks**
CIFAKE [33] (2024)	120K (60K real + 60K fake)	1 (Stable Diffusion 1.4)	Detection
WildFake [13] (2025)	3.69M	23 sources (GAN, Diffusion, commercial models)	Detection
AIGIBench [14] (2025)	144K per training setting	Multiple (GAN, SD, FLUX, Midjourney, DALL-E, etc.)	Detection
SID-Set [10] (2025)	300K	Multiple (FLUX, SDXL, Kandinsky, etc.)	Detection, localization, explanation
Synthbuster [15] (2023)	9K fake	9 generators (DALL-E, Midjourney, SD, etc.)	Detection
GenImage [16] (2023)	2.68M	8 generators (GAN, Diffusion, etc.)	Detection
DRAGON [34] (2025)	2.6M	25 diffusion models	Detection, attribution
AnomReason [8] (2026)	21,539 fake	3 (Midjourney, SD3.5, FLUX)	Semantic anomaly reasoning
FakeXplained [11] (2026)	8K+ fake	28 generators	Detection, localization, explanation

chú thích này chủ yếu phục vụ nhận diện ảnh tạo sinh hoặc phân tích bất thường trực quan, chưa trực tiếp phản ánh các dấu vết có giá trị phân biệt giữa những nguồn tạo sinh khác nhau. Do đó, hướng nghiên cứu này cần xây dựng các giao thức đánh giá phù hợp nhằm phân biệt vai trò của bằng chứng trong nhận diện và truy tìm nguồn, đồng thời kiểm chứng mức độ đóng góp và tính trung thực của các lời giải thích. Việc khai thác các mô hình tạo sinh mở trong môi trường có kiểm soát cũng tạo điều kiện nghiên cứu mối quan hệ giữa cơ chế tạo sinh và những dấu vết quan sát được.

4 Nội dung nghiên cứu

4.1 Nội dung 1: Phân tích, biểu diễn và định vị các dấu vết tạo sinh trong hình ảnh

Nội dung đầu tiên tập trung nghiên cứu các phương pháp phát hiện, phân tích và biểu diễn những dấu vết liên quan đến quá trình tạo sinh ảnh. Nghiên cứu dự kiến khai thác các dấu vết ở nhiều mức độ, bao gồm đặc trưng cấp thấp cùng các đặc trưng cấp cao. Trên cơ sở đó, nghiên cứu hướng đến xây dựng một tập bằng chứng có cấu trúc, trong đó các dấu vết được phân tích theo đặc điểm, khả năng biểu diễn và vai trò đối với từng nhiệm vụ. Đối với các bất thường trực quan, bằng chứng có thể được định vị thông qua vùng ảnh hoặc mặt nạ phân đoạn; trong khi những dấu vết thống kê có thể được biểu diễn dưới dạng bản đồ đặc trưng hoặc thông tin toàn cục.

Một vấn đề quan trọng là đánh giá giá trị của từng loại bằng chứng đối với bài

toán nhận diện ảnh tạo sinh và truy tìm nguồn tạo sinh. Nghiên cứu dự kiến xây dựng các thí nghiệm so sánh giữa việc sử dụng riêng đặc trưng cấp thấp, đặc trưng cấp cao, kết hợp hai nhóm đặc trưng và lựa chọn bằng chứng theo từng nhiệm vụ. Thông qua các thí nghiệm này, nghiên cứu phân tích mức độ đóng góp và tính bổ sung giữa các nhóm dấu vết, đồng thời xác định những bằng chứng có khả năng hỗ trợ nhận diện ảnh tạo sinh nhưng chưa đủ thông tin để phân biệt nguồn sinh. Kết quả được đánh giá thông qua các chỉ số nhận diện như Accuracy, F1-score và AUROC, cùng độ chính xác định vị như IoU hoặc mAP đối với những bằng chứng có chú thích vị trí phù hợp. Bên cạnh đó, nghiên cứu xem xét tính ổn định của các dấu vết trong những điều kiện dữ liệu khác nhau, làm cơ sở cho việc lựa chọn và khai thác bằng chứng.

4.2 Nội dung 2: Truy tìm nguồn tạo sinh dựa trên các bằng chứng phân biệt nguồn

Nội dung thứ hai tập trung nghiên cứu phương pháp xác định nguồn tạo sinh dựa trên các dấu vết đã được phân tích trước đó. Do không phải mọi bằng chứng giúp nhận diện ảnh tạo sinh đều mang giá trị phân biệt nguồn, nghiên cứu dự kiến xây dựng cơ chế đánh giá, lựa chọn và kết hợp các bằng chứng phù hợp với bài toán source attribution. Đặc biệt, nghiên cứu ưu tiên khai thác các mô hình tạo sinh mở như một môi trường có kiểm soát nhằm tìm hiểu mối quan hệ giữa kiến trúc mô hình, dữ liệu huấn luyện, quy trình sinh ảnh và các dấu vết quan sát được. Thông qua việc đối chiếu các mô hình có sự tương đồng hoặc khác biệt về những yếu tố này, nghiên cứu hướng đến xác định những đặc trưng phản ánh nguồn tạo sinh, đồng thời hạn chế sự phụ thuộc vào nội dung và phong cách hình ảnh.

Để kiểm chứng giá trị phân biệt nguồn, nghiên cứu dự kiến thực hiện các thí nghiệm đối chứng, trong đó nội dung và câu lệnh tạo ảnh được kiểm soát giữa các mô hình sinh nhằm kiểm chứng tác động của từng yếu tố như dữ liệu, kiến trúc, cơ chế sinh ảnh lên các dấu vết tạo sinh. Bên cạnh đó, các thí nghiệm loại bỏ từng nhóm đặc trưng (ablation study) và phân tích sự thay đổi kết quả dự đoán được sử dụng để đánh giá mức độ đóng góp của từng loại bằng chứng. Nghiên cứu cũng khảo sát tính ổn định của các dấu vết khi hình ảnh trải qua những phép xử lý như nén JPEG, thay đổi kích thước hoặc làm mờ. Hiệu quả truy tìm nguồn được đánh giá thông qua các chỉ số như Top-1 Accuracy và Macro-F1, kết hợp với các phân tích về khả năng phân biệt nguồn và độ bền vững của bằng chứng trong những điều kiện thử nghiệm

khác nhau.

Bên cạnh các nguồn đã biết, nghiên cứu còn xem xét bài toán truy tìm nguồn trong môi trường mở (open-set source attribution). Theo đó, một số mô hình tạo sinh được giữ lại làm nguồn chưa biết trong quá trình đánh giá nhằm kiểm tra khả năng phát hiện và từ chối gán nhãn khi không đủ bằng chứng để xác định nguồn. Đồng thời, nghiên cứu xem xét khả năng thích nghi với các nguồn mới khi có thêm dữ liệu tham chiếu, hướng đến việc mở rộng hệ thống mà không cần huấn luyện lại toàn bộ mô hình.

4.3 Nội dung 3: Suy luận và lý giải kết quả dựa trên bằng chứng

Nội dung thứ ba tập trung xây dựng cơ chế suy luận và lý giải kết quả nhận diện ảnh tạo sinh và truy tìm nguồn dựa trên các bằng chứng đã được phát hiện và lựa chọn. Nghiên cứu dự kiến khai thác khả năng của mô hình ngôn ngữ lớn đa phương thức (MLLM) trong việc kết hợp thông tin hình ảnh với các bằng chứng có cấu trúc, bao gồm loại dấu vết, vị trí khi có thể xác định và mức độ đóng góp đối với từng quyết định. Thay vì để MLLM trực tiếp tạo ra lời giải thích chỉ từ ảnh đầu vào và nhãn dự đoán, nghiên cứu hướng đến việc sử dụng tập bằng chứng đã được phân tích làm cơ sở cho quá trình suy luận. Đối với bài toán nhận diện, lời giải thích cần làm rõ những dấu vết hỗ trợ kết luận ảnh tạo sinh; trong khi với bài toán truy tìm nguồn, lời giải thích cần chỉ ra những bằng chứng có giá trị phân biệt và mức độ hỗ trợ của chúng đối với nguồn sinh được dự đoán.

Một vấn đề trọng tâm là kiểm chứng tính nhất quán và độ trung thực (faithfulness) của lời giải thích đối với quyết định của hệ thống. Nghiên cứu dự kiến đánh giá hai khía cạnh: mức độ liên kết giữa lời giải thích và bằng chứng được xác định (evidence grounding), và mức độ ảnh hưởng thực sự của bằng chứng đến kết quả dự đoán (evidence faithfulness). Đối với grounding, các mô tả được đối chiếu với bằng chứng và vị trí tương ứng thông qua chú thích tham chiếu hoặc đánh giá của con người. Đối với faithfulness, nghiên cứu xem xét các thí nghiệm loại bỏ hoặc làm suy yếu từng nhóm bằng chứng trong điều kiện kiểm soát, từ đó phân tích sự thay đổi của kết quả dự đoán.

Bên cạnh đó, nghiên cứu hướng đến hạn chế những lời giải thích không có cơ sở, không nhất quán với bằng chứng hoặc khẳng định quá mức so với thông tin quan sát được. Đối với những trường hợp bằng chứng chưa đủ để xác định nguồn sinh, hệ thống cần thể hiện mức độ bất định và giải thích cơ sở của quyết định từ chối

gán nguồn. Kết quả nghiên cứu được đánh giá thông qua khả năng liên kết lời giải thích với bằng chứng, mức độ trung thực đối với quyết định và khả năng phản ánh sự không chắc chắn của hệ thống. Qua đó, nghiên cứu hướng đến xây dựng quá trình suy luận và lý giải có thể kiểm chứng, thay vì chỉ tạo ra những mô tả hợp lý về mặt ngôn ngữ.

5 Kế hoạch nghiên cứu

5.1 Năm 1: Khảo sát và hệ thống hóa các dấu vết tạo sinh

Nghiên cứu tập trung khảo sát và hệ thống hóa các dấu vết tạo sinh từ nhiều hướng tiếp cận, bao gồm đặc trưng thống kê, miền tần số, bất thường hình học, ngữ nghĩa và dấu vân tay mô hình (model fingerprinting). Trên cơ sở đó, xây dựng hệ thống phân loại (taxonomy) các dấu vết theo đặc điểm, cách biểu diễn và vai trò đối với hai nhiệm vụ nhận diện ảnh tạo sinh và truy tìm nguồn. Đồng thời, nghiên cứu tổng hợp các bộ dữ liệu, xác định tiêu chí đánh giá bằng chứng và xây dựng tập dữ liệu thử nghiệm ban đầu từ các mô hình tạo sinh mở.

Kết quả dự kiến:

- Hệ thống phân loại dấu vết tạo sinh và các tiêu chí đánh giá bằng chứng;
- Giao thức đánh giá và tập dữ liệu thử nghiệm ban đầu phục vụ nghiên cứu.

5.2 Năm 2: Phát triển phương pháp phát hiện và định vị bằng chứng

Nghiên cứu phát triển phương pháp phát hiện và biểu diễn các dấu vết tạo sinh ở nhiều mức độ, từ tín hiệu cấp thấp đến các bất thường hình học và ngữ nghĩa. Các bằng chứng được biểu diễn bằng vùng ảnh, mặt nạ, bản đồ đặc trưng hoặc thông tin thống kê tùy theo bản chất của chúng. Đồng thời, thực hiện các thí nghiệm so sánh và kết hợp các nhóm đặc trưng nhằm đánh giá khả năng nhận diện ảnh tạo sinh, độ chính xác định vị và vai trò của từng loại bằng chứng đối với các nhiệm vụ phân loại.

Kết quả dự kiến:

- Phương pháp phát hiện, biểu diễn và định vị bằng chứng tạo sinh;
- Kết quả thực nghiệm đánh giá hiệu quả nhận diện và mức độ đóng góp của từng nhóm bằng chứng.

5.3 Năm 3: Phát triển phương pháp truy tìm nguồn tạo sinh dựa trên bằng chứng

Nghiên cứu tập trung xác định và lựa chọn các dấu vết có giá trị phân biệt nguồn tạo sinh. Các mô hình tạo sinh mở được sử dụng trong môi trường có kiểm soát nhằm phân tích mối quan hệ giữa kiến trúc, dữ liệu huấn luyện, quy trình sinh ảnh và dấu vết quan sát được. Trên cơ sở đó, phát triển phương pháp kết hợp bằng chứng để truy tìm nguồn, đồng thời đánh giá mức độ đóng góp và tính ổn định của các dấu vết thông qua các thí nghiệm đối chứng, ablation và xử lý hậu kỳ. Nghiên cứu cũng xem xét khả năng nhận biết và từ chối gán nguồn chưa biết trong môi trường open-set.

Kết quả dự kiến:

- Phương pháp truy tìm nguồn dựa trên các bằng chứng có giá trị phân biệt;
- Kết quả phân tích mối quan hệ giữa cơ chế tạo sinh và các dấu vết đặc trưng;
- Đánh giá khả năng truy tìm nguồn trong điều kiện closed-set và open-set.

5.4 Năm 4: Xây dựng cơ chế suy luận, lý giải và hoàn thiện hệ thống

Nghiên cứu xây dựng cơ chế suy luận và lý giải kết quả nhận diện, truy tìm nguồn dựa trên các bằng chứng đã được phát hiện và lựa chọn. Mô hình ngôn ngữ lớn đa phương thức (MLLM) có thể được khai thác để kết hợp thông tin hình ảnh và bằng chứng có cấu trúc nhằm tạo ra lời giải thích dễ hiểu. Trọng tâm là kiểm chứng mức độ liên kết giữa lời giải thích và bằng chứng (grounding), độ trung thực của lời giải thích đối với quyết định (faithfulness) và khả năng phản ánh mức độ bất định. Cuối cùng, nghiên cứu tích hợp các thành phần, đánh giá toàn diện trên nhiều nguồn tạo sinh và hoàn thiện luận án.

Kết quả dự kiến:

- Cơ chế suy luận và lý giải dựa trên bằng chứng có thể kiểm chứng;
- Kết quả đánh giá grounding, faithfulness và mức độ bất định;
- Hệ thống tích hợp và luận án tiến sĩ hoàn chỉnh.

6 Tài liệu tham khảo

[1] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. "High-resolution image synthesis with latent diffusion models". In: *2022 IEEE/CVF conference on computer vision and pattern recognition (CVPR)*. ieee. 2022, pp. 10674–10685.

[2] James Betker, Gabriel Goh, Li Jing, Tim Brooks, Jianfeng Wang, Linjie Li, Long Ouyang, Juntang Zhuang, Joyce Lee, Yufei Guo, et al. "Improving image generation with better captions". In: *Computer Science. https://cdn. openai. com/papers/dall-e-3. pdf* 2.3 (2023), p. 8.

[3] Black Forest Labs, Stephen Batifol, Andreas Blattmann, Frederic Boesel, Saksham Consul, Cyril Diagne, Tim Dockhorn, Jack English, Zion English, Patrick Esser, Sumith Kulal, Kyle Lacey, Yam Levi, Cheng Li, Dominik Lorenz, Jonas Müller, Dustin Podell, Robin Rombach, Harry Saini, and Axel Sauer. *FLUX.1 Kontext: Flow Matching for In-Context Image Generation and Editing in Latent Space*. 2025. arXiv: 2506.15742 [cs.GR].

[4] Shilin Yan, Ouxiang Li, Jiayin Cai, Yanbin Hao, Xiaolong Jiang, Yao Hu, and Weidi Xie. "A Sanity Check for AI-generated Image Detection". In: *International Conference on Learning Representations*. 2025.

[5] Huangsen Cao, Yongwei Wang, Yinfeng Liu, Sixian Zheng, Kangtao Lv, Zhimeng Zhang, Bo Zhang, Xin Ding, and Fei Wu. "HyperDet: generalizable detection of synthesized images by generating and merging a mixture of hyper LoRAs". In: *arXiv preprint arXiv:2410.06044* (2024).

[6] Chuangchuang Tan, Yao Zhao, Shikui Wei, Guanghua Gu, Ping Liu, and Yunchao Wei. "Rethinking the up-sampling operations in cnn-based generative network for generalizable deepfake detection". In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2024, pp. 28130–28139.

[7] Ayush Sarkar, Hanlin Mai, Amitabh Mahapatra, Svetlana Lazebnik, David A Forsyth, and Anand Bhattad. "Shadows don't lie and lines can't bend! generative models don't know projective geometry... for now". In: *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. 2024, pp. 28140–28149.

[8] Chuangchuang Tan, Xiang Ming, Jinglu Wang, Renshuai Tao, Bin Li, Yunchao Wei, Yao Zhao, and Yan Lu. "Semantic visual anomaly detection and reasoning in ai-generated images". In: *International Conference on Learning Representations*. Vol. 2026. 2026, pp. 111907–111942.

[9] Ziyin Zhou, Yunpeng Luo, Yuanchen Wu, Ke Sun, Jiayi Ji, Ke Yan, Shouhong Ding, Xiaoshuai Sun, Yunsheng Wu, and Rongrong Ji. "Aigi-holmes: Towards explainable and generalizable ai-generated image detection via multimodal large language models". In: *2025 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE. 2025, pp. 18746–18758.

[10] Zhenglin Huang, Jinwei Hu, Xiangtai Li, Yiwei He, Xingyu Zhao, Bei Peng, Baoyuan Wu, Xiaowei Huang, and Guangliang Cheng. “Sida: Social media image deepfake detection, localization and explanation with large multimodal model”. In: *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. 2025, pp. 28831–28841.

[11] Yikun Ji, Yan Hong, Qi Fan, Jun Lan, Huijia Zhu, Weiqiang Wang, Liqing Zhang, and Jianfu Zhang. “FakeXplain: AI-Generated Image Detection via Human-Aligned Grounded Reasoning”. In: *International Conference on Learning Representations*. 2026.

[12] Yao Xiao, Weiyan Chen, Jiahao Chen, Zijie Cao, Weijian Deng, Binbin Yang, ZiYi Dong, Xiangyang Ji, Wei Ke, Pengxu Wei, and Liang Lin. “Unveiling Perceptual Artifacts: A Fine-Grained Benchmark for Interpretable AI-Generated Image Detection”. In: *International Conference on Learning Representations*. 2026.

[13] Yan Hong, Jianming Feng, Haoxing Chen, Jun Lan, Huijia Zhu, Weiqiang Wang, and Jianfu Zhang. “Wildfake: A large-scale and hierarchical dataset for ai-generated images detection”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 39. 4. 2025, pp. 3500–3508.

[14] Ziqiang Li, Jiazhen Yan, Ziwen He, Kai Zeng, Weiwei Jiang, Lizhi Xiong, and Zhangjie Fu. “Is Artificial Intelligence Generated Image Detection a Solved Problem?” In: *Advances in Neural Information Processing Systems*. 2025.

[15] Quentin Bammey. “Synthbuster: Towards Detection of Diffusion Model Generated Images”. In: *IEEE Open Journal of Signal Processing* 5 (2024), pp. 1–9. DOI: 10.1109/OJSP.2023.3337714.

[16] Mingjian Zhu, Hanting Chen, Qiangyu Yan, Xudong Huang, Guanyu Lin, Wei Li, Zhijun Tu, Hailin Hu, Jie Hu, and Yunhe Wang. “Genimage: A million-scale benchmark for detecting ai-generated image”. In: *Advances in neural information processing systems* 36 (2023), pp. 77771–77782.

[17] Ning Yu, Larry S. Davis, and Mario Fritz. “Attributing Fake Images to GANs: Learning and Analyzing GAN Fingerprints”. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2019, pp. 7556–7566.

[18] Hae Jin Song, Mahyar Khayatkhoei, and Wael AbdAlmageed. “ManiFPT: Defining and Analyzing Fingerprints of Generative Models”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2024, pp. 10791–10801.

[19] Hui Shi, MingYang Liu, and ChengCheng Gong. “EXACT: An Explainable Adaptive SemantiC-Trace framework for AI-generated image forensics”. In: *Computer Vision and Image Understanding* 271 (2026), p. 104871. DOI: 10.1016/j.cviu.2026.104871.

[20] Sheng-Yu Wang, Oliver Wang, Richard Zhang, Andrew Owens, and Alexei A Efros. “CNN-generated images are surprisingly easy to spot... for now”. In: *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. 2020, pp. 8692–8701.

[21] Utkarsh Ojha, Yuheng Li, and Yong Jae Lee. “Towards Universal Fake Image Detectors That Generalize Across Generative Models”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. June 2023, pp. 24480–24489.

[22] Riccardo Corvi, Davide Cozzolino, Giada Zingarini, Giovanni Poggi, Koki Nagano, and Luisa Verdoliva. “On The Detection of Synthetic Images Generated by Diffusion Models”. In: *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2023, pp. 1–5. DOI: 10.1109/ICASSP49357.2023.10095167.

[23] Jonas Ricker, Simon Damm, Thorsten Holz, and Asja Fischer. “Towards the Detection of Diffusion Model Deepfakes”. In: *arXiv preprint arXiv:2210.14571* (2022).

[24] Hui Guo, Shu Hu, Xin Wang, Ming-Ching Chang, and Siwei Lyu. “Eyes Tell All: Irregular Pupil Shapes Reveal GAN-Generated Faces”. In: *2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2022, pp. 2904–2908. DOI: 10.1109/ICASSP43922.2022.9746597.

[25] Xin Yang, Yuezun Li, Honggang Qi, and Siwei Lyu. “Exposing GAN-synthesized Faces Using Landmark Locations”. In: *Proceedings of the 7th ACM Workshop on Information Hiding and Multimedia Security*. 2019, pp. 113–118. DOI: 10.1145/3335203.3335724.

[26] Yuval Nirkin, Lior Wolf, Yosi Keller, and Tal Hassner. “DeepFake Detection Based on Discrepancies Between Faces and Their Context”. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44.12 (2022), pp. 9719–9732. DOI: 10.1109/TPAMI.2021.3093446.

[27] Huangsen Cao, Qin Mei, Zhiheng Li, Yuxi Li, Zhan Meng, Ying Zhang, Chen Li, Zhimeng Zhang, Xin Ding, Yongwei Wang, Jing Lyu, and Fei Wu. “REVEAL: Reasoning-Enhanced Forensic Evidence Analysis for Explainable AI-Generated Image Detection”. In: *arXiv preprint arXiv:2511.23158* (2025).

[28] Xin Lai, Zhuotao Tian, Yukang Chen, Yanwei Li, Yuhui Yuan, Shu Liu, and Jiaya Jia. “LISA: Reasoning Segmentation via Large Language Model”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2024, pp. 9579–9589. DOI: 10.1109/CVPR52733.2024.00915.

[29] Dario Cioni, Christos Tzelepis, Lorenzo Seidenari, and Ioannis Patras. “Are CLIP Features All You Need for Universal Synthetic Image Origin Attribution?” In: *European Conference on Computer Vision Workshops*. Springer, 2024, pp. 363–382.

[30] Hui Xu, Chi Liu, Congcong Zhu, Minghao Wang, Youyang Qu, and Longxiang Gao. “Causal Fingerprints of AI Generative Models”. In: *arXiv preprint arXiv:2509.15406* (2025).

[31] Tianyun Yang, Danding Wang, Fan Tang, Xinying Zhao, Juan Cao, and Sheng Tang. “Progressive Open Space Expansion for Open-Set Model Attribution”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2023, pp. 15856–15865.

[32] Tai D. Nguyen, Aref Azizpour, and Matthew C. Stamm. “Forensic Self-Descriptions Are All You Need for Zero-Shot Detection, Open-Set Source Attribution, and Clustering of AI-generated Images”. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. June 2025, pp. 3040–3050.

[33] Jordan J Bird and Ahmad Lotfi. “Cifake: Image classification and explainable identification of ai-generated synthetic images”. In: *IEEE Access* 12 (2024), pp. 15642–15650.

[34] Giulia Bertazzini, Daniele Baracchi, Dasara Shullani, Isao Echizen, and Alessandro Piva. *DRAGON: A Large-Scale Dataset of Realistic Images Generated by Diffusion Models*. 2025. arXiv: 2505.11257 [cs.CV].