

ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

Họ tên NCS: Dương Đình Phương Dao

**BÀI LUẬN VỀ HƯỚNG NGHIÊN CỨU
LUẬN ÁN TIẾN SĨ**

Tên đề tài:

**PHÁT HIỆN VÀ LÝ GIẢI CÁC YẾU TỐ TẠO SINH
TRONG NỘI DUNG HÌNH ẢNH**

Ngành: Khoa Học Máy Tính

Mã số: 9480101

Cán bộ hướng dẫn 1: TS. Nguyễn Vinh Tiệp

Thành phố Hồ Chí Minh, tháng 05 năm 2026

MỤC LỤC

1	Giới thiệu bài toán	1
1.1	Bối cảnh nghiên cứu	1
1.2	Định nghĩa bài toán	1
1.3	Khoảng trống và động lực nghiên cứu	2
2	Mục tiêu nghiên cứu	3
2.1	MT1: Tổng hợp và phân loại các bằng chứng trên ảnh tạo sinh	3
2.2	MT2: Xây dựng hệ thống phân loại dựa trên cơ sở bằng chứng	3
2.3	MT3: Tạo sinh các giải thích chính xác và trực quan	4
3	Tổng quan tình hình nghiên cứu	5
3.1	Bài toán phân loại ảnh thật và ảnh tạo sinh	5
3.2	Các nghiên cứu về lý giải kết quả phát hiện	7
3.3	Bộ dữ liệu	8
4	Nội dung nghiên cứu	9
4.1	Nội dung 1: Xây dựng bộ phát hiện và giải thích dấu vết tạo sinh trong ảnh một cách tổng quát	9
4.2	Nội dung 2: Tích hợp cơ chế định vị để xác định chính xác vị trí dấu vết	10
4.3	Nội dung 3: Xây dựng cơ chế biểu diễn và suy luận bằng chứng một cách có cấu trúc	10
5	Kế hoạch nghiên cứu	11
6	Tài liệu tham khảo	11

1 Giới thiệu bài toán

1.1 Bối cảnh nghiên cứu

Trong những năm gần đây, các mô hình tạo sinh hình ảnh như Stable Diffusion [1], DALL-E [2], FLUX [3],... đã có nhiều bước phát triển vượt trội, mang lại nhiều ứng dụng ấn tượng trong việc tạo ra hình ảnh chất lượng cao chỉ từ một câu mô tả bằng ngôn ngữ tự nhiên. Khả năng này mở ra nhiều ứng dụng tích cực trong các lĩnh vực như thiết kế, quảng cáo, sáng tạo nội dung và giáo dục.

Tuy nhiên, sự phát triển này đồng thời cũng tạo ra một vấn đề quan trọng trong việc xác định một hình ảnh là ảnh chụp thực tế hay ảnh được tạo sinh nhờ vào trí tuệ nhân tạo (AI). Câu hỏi này đặc biệt đáng quan tâm khi hình ảnh được sử dụng trong các ngữ cảnh đòi hỏi độ tin cậy cao như báo chí, bằng chứng số hay thông tin chính trị và xã hội. Để giải quyết bài toán phát hiện ảnh tạo sinh này, một số bộ dữ liệu đã được nghiên cứu và phát triển như GenImage [4] hay CIFAKE [5] đều là những benchmark lớn chứa thông tin về những cặp ảnh thật và ảnh tạo sinh từ nhiều mô hình tạo ảnh đa dạng, được dùng để huấn luyện các mô hình phân loại tự động.


Tuy vậy, các bộ phát hiện ảnh thật hay ảnh tạo sinh này cũng đang vấp phải vấn đề khi chúng có thể dự đoán rất chính xác rằng một ảnh là ảnh tạo sinh bởi AI, nhưng lại không biết được bằng chứng nào trong ảnh đã dẫn đến quyết định đó. Ví dụ, một mô hình có thể trả lời rằng “Ảnh này có xác suất lên đến 97% là do AI tạo ra.” nhưng nếu hỏi tại sao thì mô hình có thể không trả lời được hoặc chỉ có thể trả lời một cách mập mờ như “Do ảnh chứa các chi tiết không tự nhiên.”. Có thể thấy rằng, câu trả lời này là hoàn toàn không đủ cơ sở để con người có thể kiểm chứng. Do đó, hiện nay, nhu cầu không còn chỉ nằm ở việc phát hiện ảnh có phải do AI tạo sinh không mà đang chuyển dần sang việc giải thích được các yếu tố khiến mô hình đưa ra quyết định phân loại ảnh.

1.2 Định nghĩa bài toán

Định nghĩa bài toán được minh họa trong Hình 1, theo đó ta có thể tổng quát hóa như sau:

- **Đầu vào:** Một hình ảnh bất kỳ I .
- **Đầu ra:**
 - ◊ (1) Nhãn phân loại y thuộc $\{Real; AI - Generated\}$, tương ứng với ảnh thật và ảnh được tạo bởi AI.

- ◇ (2) Các giải thích: $R = \{r_1, r_2, \dots, r_n\}$ với r_i biểu diễn một yếu tố chứng minh ảnh là ảnh tạo sinh.
- ◇ (3) Vị trí các dấu vết có tính cục bộ: $M_i = Localization(e_i)$



Hình 1. Minh họa đầu vào (input) và đầu ra (output) của hệ thống một cách tổng quan.

1.3 Khoảng trống và động lực nghiên cứu

Nghiên cứu được đề xuất xuất phát từ ba vấn đề chính:

- **Thứ nhất, các giải thích hiện nay chưa gắn chặt với quá trình ra quyết định.** Các hệ thống như trước đây [6, 7, 8] thường thực hiện theo hướng $I \rightarrow \text{Detection} \rightarrow \text{Explanation}$, tức đưa ra nhãn Real/AI trước rồi mới sinh lời giải thích. Vì vậy, lời giải thích có thể hợp lý về mặt ngôn ngữ nhưng chưa chắc phản ánh những bằng chứng thực sự được sử dụng để phân loại.
- **Thứ hai, giải thích còn phụ thuộc vào dữ liệu huấn luyện.** Các mô hình dựa trên MLLM [9, 8] thường được tinh chỉnh trên dữ liệu gồm ảnh, nhãn và lời giải thích tương ứng. Cách này giúp tạo ra giải thích tự nhiên, nhưng có nguy cơ mô hình học lại các kiểu giải thích thường xuất hiện trong dữ liệu thay vì thực sự kiểm tra và phát hiện những dấu vết đó trong ảnh. Điều này làm hạn chế khả năng tổng quát khi gặp những dạng bất thường hoặc ảnh tạo sinh mới.
- **Thứ ba, các phương pháp phát hiện hiện nay [10, 11, 12] chủ yếu khai thác từng loại dấu vết riêng biệt.** Các phương pháp như HyperDet [13] và NPR [14] tập trung vào các dấu vết ở mức điểm ảnh như nhiễu hoặc quan hệ

thống kê; trong khi Sarkar và cộng sự [15] cho thấy ảnh tạo sinh còn có thể được phát hiện thông qua sự thiếu nhất quán về hình học, đường thẳng, bóng và quan hệ vật thể–bóng. Điều này cho thấy một ảnh có thể chứa nhiều loại bằng chứng khác nhau, nhưng các phương pháp hiện nay vẫn chưa có cơ chế thống nhất để tổng hợp chúng trong cùng một quá trình phân loại.

- **Thứ tư, thiếu cơ chế định vị bằng chứng một cách trực quan.** Phần lớn hệ thống chỉ cung cấp nhãn và mô tả bằng văn bản, trong khi chưa chỉ rõ bằng chứng được đề cập nằm ở đâu trên ảnh. Do đó, một hệ thống lý giải hiệu quả cần kết hợp phân loại + giải thích + định vị, chẳng hạn sử dụng bounding box hoặc mask để ánh xạ từng bằng chứng về vị trí tương ứng trên ảnh.

Tất cả những vấn đề nêu trên chính là động lực chính thúc đẩy nghiên cứu này.

2 Mục tiêu nghiên cứu

2.1 MT1: Tổng hợp và phân loại các bằng chứng trên ảnh tạo sinh

Như đã trình bày trước đó, các bằng chứng được dùng để phân loại ảnh tạo sinh và ảnh thật đã và đang được nghiên cứu rộng rãi. Mỗi nghiên cứu đều chứng minh khả năng phân loại ở những khía cạnh khác nhau của ảnh từ những bằng chứng mang tính toàn cục như độ chênh lệch bất thường giữa các điểm ảnh hoặc nhiễu trong các biểu diễn đặc trưng, cho đến những bằng chứng mang tính cục bộ như các khiếm khuyết (artifact) trong quá trình sinh ảnh hay mối quan hệ phi logic của các vật thể trong ảnh. Mỗi dấu vết đều cung cấp một góc nhìn quan trọng trên ảnh, tuy nhiên, chưa có nghiên cứu nào thực hiện tổng hợp và phân loại các bằng chứng này một cách hệ thống và tổng quát. Điều này khiến cho các hệ thống trước đây bị phụ thuộc vào một góc nhìn phiến diện trong ảnh, khiến chúng dễ dàng bị đánh lừa bởi những bộ tấn công [16, 17].


Vì vậy, việc hệ thống các bằng chứng này đặc biệt quan trọng giúp các giải thích được đưa ra một cách chặt chẽ dựa trên bằng chứng cụ thể. Đồng thời, việc xác định chính xác phân loại của các dấu vết tạo sinh trong ảnh giúp việc chỉnh sửa và cải thiện các dấu vết này trở nên dễ dàng và có cơ sở hơn.

2.2 MT2: Xây dựng hệ thống phân loại dựa trên cơ sở bằng chứng

Các hệ thống trước đây, thường xây dựng bộ phân loại dựa trên các đặc trưng được khai thác một cách riêng lẻ hoặc phụ thuộc hoàn toàn vào các MLLMs, xem

Hình 2(a, b). Tuy đạt được độ chính xác cao trong việc phân loại nhưng lại chưa thật sự để lại dấu ấn trong phần giải thích. Phần giải thích thường dài dòng, khó hiểu và không chỉ ra được vấn đề thật sự đang tồn tại trong ảnh do AI tạo sinh.

Nghiên cứu này hướng đến xây dựng một hệ thống, được minh họa trong Hình 2(c) trong đó ảnh được phân tích bởi nhiều góc độ và bằng chứng, mỗi yếu tố tập trung vào một nhóm dấu vết khác nhau. Các kết quả sau đó được tổng hợp để hình thành tập bằng chứng và đưa vào quá trình suy luận.




Hình 2. So sánh các hướng tiếp cận trong phát hiện và giải thích ảnh tạo sinh: (a) phương pháp phân loại nhị phân dựa trên đặc trưng, (b) phương pháp dựa trên mô hình ngôn ngữ lớn đa phương thức (MLLM), và (c) phương pháp đề xuất dựa trên chuỗi bằng chứng kết hợp phát hiện, giải thích và định vị bằng chứng trên ảnh.

2.3 MT3: Tạo sinh các giải thích chính xác và trực quan

Các giải thích của phần lớn mô hình hiện nay vấp phải hai vấn đề lớn, chính là phụ thuộc vào kết quả phân loại trước đó và học ánh xạ từ dữ liệu huấn luyện. Điều này không chỉ làm hạn chế hiệu suất phân loại mà các lý giải còn bị giới hạn trong những giải thích tổng quát từ các bộ dữ liệu được xây dựng. Vì vậy, các bằng chứng được tổng hợp và phát triển trong nghiên cứu này đóng vai trò đặc biệt quan trọng trong việc làm cơ sở cho các giải thích, giúp chúng bám sát vào nội dung hình ảnh thực tế ở nhiều khía cạnh khác nhau.

Bên cạnh đó, việc đưa ra các giải thích trong các nghiên cứu trước đây [18] cũng gặp phải hạn chế lớn trong việc truyền tải thông tin đến người dùng cuối. Hình 3 minh họa nội dung giải thích của AnomAgent. Theo đó, các nội dung giải thích

thường khá dài dòng, phức tạp nhưng đôi lúc lại không thật sự ánh xạ chính xác đến một đối tượng cụ thể trong ảnh đang được nhắc đến gây ra những mập mờ và khó hiểu. Vì vậy, nghiên cứu này cũng hướng đến giải quyết các bất cập này thông qua một cơ chế định vị trực quan bằng các công cụ như bounding box, mask,... giúp xác định chính xác vùng hoặc vị trí vật thể đang được nhắc đến trong các bằng chứng lý giải.



Hình 3. Minh họa hạn chế trong giải thích của AnomAgent [18]: các mô tả dài và phức tạp dẫn đến định vị bằng chứng mơ hồ hoặc không thể xác định chính xác vật thể được đề cập trong ảnh.

3 Tổng quan tình hình nghiên cứu

3.1 Bài toán phân loại ảnh thật và ảnh tạo sinh

Để giải quyết vấn đề này, các nghiên cứu về phát hiện ảnh do AI tạo sinh đã phát triển theo nhiều hướng khác nhau. Nhìn tổng thể, có thể chia các phương pháp hiện nay thành hai hướng chính. Hướng thứ nhất tập trung phân tích đặc trưng của toàn bộ hình ảnh, nhằm tìm ra những dấu vết thống kê hoặc dấu vết pháp chứng (forensis) mà các mô hình tạo sinh để lại trong quá trình sinh ảnh. Hướng thứ hai tập trung vào các vùng hoặc hiện tượng bất thường cụ thể trong ảnh, chẳng hạn cấu trúc bàn tay, chữ, bóng, phản chiếu hoặc các quan hệ hình học. Hai hướng này không loại trừ nhau mà phản ánh hai cách tiếp cận khác nhau đối với câu hỏi: "Ảnh AI khác ảnh thật ở điểm nào?"

Đầu tiên, với hướng phân tích toàn ảnh. Ban đầu, các phương pháp phát hiện

ảnh tạo sinh chủ yếu được xem xét như một bài toán phân loại ảnh [10, 11, 19]. Với cách tiếp cận này, một ảnh đầu vào được đưa qua một bộ trích xuất đặc trưng, sau đó đặc trưng được sử dụng để dự đoán ảnh thuộc lớp ảnh thật hay ảnh do AI tạo ra. Có thể khái quát quá trình này dưới dạng: $I \rightarrow \text{Feature Extractor} \rightarrow \text{Classifier} \rightarrow \text{Real, AI-generatic}$. Mục tiêu của mô hình là tìm ra một không gian đặc trưng trong đó ảnh thật và ảnh tạo sinh có sự khác biệt đủ rõ để có thể phân biệt được. Điều đáng chú ý là mô hình không nhất thiết phải hiểu nội dung của ảnh theo cách con người quan sát. Thay vào đó, nó có thể khai thác những khác biệt rất nhỏ trong tín hiệu hình ảnh mà con người khó nhận biết, chẳng hạn đặc trưng trong miền tần số, nhiễu, kết cấu, quan hệ giữa các điểm ảnh hoặc dấu vết được hình thành trong quá trình lấy mẫu và tái tạo ảnh của mô hình sinh. Một hướng nghiên cứu đáng chú ý trong nhóm này là khai thác quan hệ giữa các điểm ảnh [14, 20]. Ý tưởng chính là dựa vào những chênh lệch bất thường giữa các giá trị điểm ảnh trong vùng cục bộ của ảnh tạo sinh và ảnh chụp thực tế. Một hướng khác là khai thác dấu vết trong miền nhiễu và tần số thông qua các đặc trưng từ bộ lọc SRM [13]. Các bộ lọc như SRM vốn được sử dụng nhằm trích xuất các đặc trưng pháp chứng từ hình ảnh để phân tích thành phần tín hiệu bất thường. HyperDet phát triển ý tưởng này bằng cách phân chia các bộ lọc SRM thành nhiều nhóm, từ đó tạo ra nhiều góc nhìn đặc trưng pháp chứng khác nhau và cuối cùng tổng hợp các quan sát này để đưa ra quyết định phân loại cuối cùng. Nhìn chung, hướng phân tích toàn ảnh này có ưu điểm lớn trong việc phát hiện những những dấu vết cực kỳ nhỏ mà mắt người không thể quan sát. Đây cũng là lý do tại sao các phương pháp dựa trên đặc trưng thống kê, nhiễu, tần số hoặc quan hệ điểm ảnh vẫn đóng vai trò quan trọng trong các hệ thống phát hiện ảnh tạo sinh. Tuy nhiên, chính đặc điểm này lại tạo ra một hạn chế lớn khi mục tiêu nghiên cứu không chỉ là phát hiện mà còn là giải thích. Việc mô hình phát hiện dựa trên những đặc trưng mà con người không thể quan sát hoặc diễn giải, thì rất khó xác định liệu mô hình có thực sự học được bản chất dấu vết của ảnh tạo sinh hay chỉ đang khai thác một đặc điểm phụ thuộc (overfit) vào bộ dữ liệu.

Thứ hai với hướng phân tích các vùng và điểm bất thường cục bộ. Trước những hạn chế của việc chỉ phân tích đặc trưng toàn ảnh, một hướng nghiên cứu khác tập trung trực tiếp vào những hiện tượng mà con người có thể quan sát và kiểm chứng. Thay vì xem xét toàn bộ ảnh có đặc trưng giống ảnh AI hay không, các phương pháp theo hướng này [15, 21, 22] tập trung vào các vùng và vật thể cục bộ trong ảnh. Một ví dụ tiêu biểu phân tích ảnh theo hướng hình học và quan hệ vật lý [15]. Nghiên

cứu này cho rằng các mô hình tạo sinh có thể tạo ra hình ảnh nhìn có vẻ hợp lý ở cấp độ tổng thể nhưng lại không tuân thủ đầy đủ những quy luật hình học của thế giới thực. Các tác giả nghiên cứu các đặc trưng như đường thẳng và quan hệ giữa vật thể với bóng. Điểm đáng chú ý là hệ thống không cần trực tiếp đưa toàn bộ pixel của ảnh vào bộ phân loại mà có thể sử dụng những đặc trưng hình học đã được trích xuất để phân biệt ảnh thật và ảnh tạo sinh. Tương tự với các nghiên cứu theo nhánh bài toán phát hiện các điểm khiếm khuyết (artifact) và bất thường về mặt logic của các vật thể trong ảnh và quan hệ giữa chúng [18]. Những nghiên cứu này tập trung vào việc xác định các dấu vết cục bộ còn sót lại trong quá trình sinh ảnh.

Điều này cho thấy dấu vết của ảnh AI không nhất thiết chỉ nằm trong những đặc trưng cấp thấp như nhiễu hoặc quan hệ giữa các điểm ảnh. Một ảnh tạo sinh có thể để lại dấu vết ở nhiều cấp độ khác nhau, từ tín hiệu đặc trưng cho tới những quy luật mà con người sử dụng để hiểu thế giới. Tuy nhiên, phần lớn các nghiên cứu vẫn tập trung vào một hoặc một nhóm bằng chứng cụ thể. Điều này tạo ra một khoảng trống quan trọng. Một bộ phát hiện chuyên về quan hệ điểm ảnh có thể phát hiện tốt dấu vết pháp chứng ở mức pixel nhưng không nhất thiết hiểu được ý nghĩa hoặc quan hệ không gian giữa các vật thể trong ảnh. Ngược lại, một phương pháp kiểm tra hình học hoặc phát hiện điểm bất thường có thể chỉ ra nhiều vùng lỗi trong ảnh nhưng sẽ thất bại khi ảnh không chứa bất kỳ điểm bất thường bề mặt nào. Do đó, vấn đề không còn đơn thuần là tìm thêm một loại dấu vết mới, mà là nghiên cứu cách kết hợp nhiều loại bằng chứng có bản chất khác nhau thành một hệ thống phân tích thống nhất.

3.2 Các nghiên cứu về lý giải kết quả phát hiện

Sự phát triển của các phương pháp phát hiện dựa trên đặc trưng toàn ảnh và các bằng chứng cục bộ đã đạt được nhiều kết quả tích cực, nhưng đồng thời đặt ra một câu hỏi mới: nếu một hệ thống nói rằng ảnh là do AI tạo ra, làm thế nào để nó giải thích quyết định đó cho con người? Đây là động lực dẫn đến sự xuất hiện của nhóm nghiên cứu về phát hiện ảnh AI có khả năng lý giải.

Một số nghiên cứu tiêu biểu như AIGI-Holmes và SIDA thể hiện các mức độ phát triển khác nhau cho bài toán này. Một hướng tiếp cận phổ biến là sử dụng mô hình ngôn ngữ đa phương thức để phân tích hình ảnh và sinh ra lời giải thích bằng ngôn ngữ tự nhiên. Thay vì chỉ trả lời ảnh là thật hay giả, mô hình được yêu cầu mô tả những dấu hiệu khiến nó đưa ra kết luận, chẳng hạn cấu trúc bàn tay bất thường,

chữ bị biến dạng, bóng không nhất quán hoặc các quan hệ hình học không hợp lý. Các nghiên cứu như AIGI-Holmes tập trung xây dựng dữ liệu huấn luyện có chứa cả kết quả phát hiện và lời giải thích, qua đó giúp mô hình có khả năng thực hiện đồng thời nhận biết và giải thích. Một số hướng khác như SIDA tiếp tục bổ sung khả năng định vị, cho phép hệ thống không chỉ mô tả bất thường bằng ngôn ngữ mà còn chỉ ra vùng ảnh được cho là có dấu hiệu giả mạo.

Nhìn chung, điểm tiền bộ quan trọng của các nghiên cứu này là giúp kết quả trở nên trực quan hơn đối với con người và tạo điều kiện để người dùng kiểm tra lại quyết định của hệ thống. Đặc biệt, việc kết hợp phát hiện với định vị giúp thu hẹp phạm vi kiểm tra từ toàn bộ ảnh xuống những khu vực đáng ngờ. Tuy nhiên, các phương pháp này vẫn tồn tại một hạn chế quan trọng liên quan đến mối quan hệ giữa quyết định, bằng chứng và lời giải thích. Trong nhiều hệ thống, quá trình cơ bản vẫn có thể được hình dung là mô hình trước tiên đưa ra quyết định Real/AI-generated, sau đó sử dụng một mô hình ngôn ngữ hoặc một cơ chế giải thích để tạo ra lý do cho quyết định đó. Khi đó, một lời giải thích có thể hợp lý về mặt ngôn ngữ nhưng chưa chắc trung thành với bằng chứng thực sự mà bộ phát hiện sử dụng. Một vấn đề khác xuất phát từ chính cách xây dựng dữ liệu huấn luyện cho các mô hình có khả năng lý giải. Khi các lời giải thích được cung cấp trực tiếp trong bộ dữ liệu, mô hình có nguy cơ học được mối quan hệ giữa nhãn và những cách giải thích thường xuất hiện, thay vì thực sự kiểm tra sự tồn tại của bằng chứng trong ảnh. Điều này đặc biệt đáng lo ngại khi mô hình được áp dụng cho những ảnh được tạo bởi các mô hình sinh khác, trong đó các dấu vết có thể hoàn toàn khác với dữ liệu huấn luyện.

3.3 Bộ dữ liệu

Các bộ dữ liệu ban đầu cho bài toán phân loại ảnh thực tế và ảnh tạo sinh thường có cấu trúc đơn giản bao gồm ảnh và nhãn phân loại tương ứng. Một số bộ dữ liệu có thể kể đến như:

- CIFAKE [5], chứa khoảng 60.000 ảnh thật và 60.000 ảnh tạo sinh được tổng hợp từ Stable Diffusion.
- GenImage [4], được xây dựng với quy mô lớn hơn với hơn 2 triệu ảnh thật và ảnh tạo sinh được tổng hợp từ nhiều mô hình tạo sinh khác nhau nhằm làm tăng tính đa dạng về nguồn sinh ảnh.
- Ngoài ra, còn có nhiều benchmark khác như CNNSpot [10], SynthBuster [23], WildFake [24],... đều được xây dựng với những nguồn ảnh thật và ảnh tạo sinh

khác nhau.

Bên cạnh đó, các nghiên cứu gần đây bắt đầu xây dựng dữ liệu ở mức chi tiết hơn, chứa thêm các thông tin về nội dung giải thích dựa trên kết quả. Một số bộ dữ liệu như:

- SynArtifact-1K [25], chứa khoảng 1.300 ảnh do AI tạo sinh được chú thích các điểm khiếm khuyết (Artifact) do mô hình tạo sinh sinh ra.
- AnomReason [26], đây là bộ dữ liệu được tổ chức theo cấu trúc bao gồm các thành phần lý giải chi tiết cho các điểm bất thường trong ảnh tạo sinh. Bộ dữ liệu chứa các giải thích phức tạp và chi tiết cho các bất thường cục bộ trong ảnh.
- AIGI-Holmes [8], bộ dữ liệu chứa ảnh, nhãn phân loại và cả phần giải thích nhằm huấn luyện các mô hình thị giác-ngôn ngữ cho tác vụ phân loại và giải thích.
- SIDA [6], chứa thêm các thông tin định vị vùng bị chỉnh sửa và các giải thích bằng ngôn ngữ.

4 Nội dung nghiên cứu

4.1 Nội dung 1: Xây dựng bộ phát hiện và giải thích dấu vết tạo sinh trong ảnh một cách tổng quát

Các nghiên cứu hiện nay đã cho thấy ảnh do AI tạo sinh có thể để lại nhiều loại dấu vết khác nhau. Những dấu vết này có thể xuất hiện ở nhiều cấp độ, từ những đặc trưng rất thấp như nhiễu hoặc quan hệ giữa các điểm ảnh, đến những đặc trưng có ý nghĩa cao hơn như kết cấu, hình học, bóng phản chiếu và quan hệ ngữ nghĩa giữa các vật thể. Điều này cho thấy không tồn tại một loại bằng chứng duy nhất có thể giải thích toàn bộ sự khác biệt giữa ảnh thật và ảnh tạo sinh. Vì vậy, nếu chỉ đơn thuần xây dựng một bộ phân loại dựa trên trích xuất đặc trưng thì mô hình tuy có thể đạt được độ chính xác cao nhưng rất khó biết được nó thực sự dựa vào dấu vết nào và rất dễ bị phụ thuộc vào dữ liệu huấn luyện. Do đó, hướng nghiên cứu đầu tiên là tập trung xây dựng một hệ thống các bằng chứng có phân loại rõ ràng, tương ứng với nhiều loại dấu vết khác nhau đa dạng. Các bằng chứng này nên được tổng hợp và là cơ sở quan trọng để đưa ra suy luận cuối cùng cho hệ thống phân loại ảnh thật, giả.

Đề tài dự kiến xây dựng một tập hợp các bằng chứng dưới nhiều góc nhìn khác nhau trên ảnh, trong đó mỗi góc nhìn tập trung vào một khía cạnh cụ thể của ảnh.

Chẳng hạn, một khía cạnh có thể tập trung phân tích dấu vết ở mức điểm ảnh, một khía cạnh khác lại tập trung vào các đặc trưng về mặt hình học, trong khi một khía cạnh khác sẽ xem xét đến thuộc tính của mỗi vật thể trong ảnh có phù hợp với các tri thức thông thường trong thế giới tự nhiên hay không. Theo đó, mỗi thông tin từ các góc nhìn này sẽ không trực tiếp đưa ra quyết định cuối cùng mà chúng sẽ được tổng hợp thành một tập các bằng chứng để đưa vào mô hình suy luận. Cách tiếp cận này giúp hệ thống không chỉ đưa ra một kết luận phân loại mà còn có thể giải thích kết quả được hình thành từ những bằng chứng nào. Việc sử dụng kết hợp nhiều góc nhìn khác nhau từ ảnh cũng giúp giải quyết một hạn chế lớn của các mô hình ngôn ngữ đa phương thức khi chúng có thể quan sát toàn bộ ảnh và sinh ra một lời giải thích rất tự nhiên, nhưng điều đó không đảm bảo rằng chúng đã thực sự kiểm tra từng loại bằng chứng.

4.2 Nội dung 2: Tích hợp cơ chế định vị để xác định chính xác vị trí dấu vết

Việc xác định loại dấu vết tạo sinh vẫn chưa đủ nếu hệ thống không xác định được chính xác vị trí dấu vết đó ở đâu. Ví dụ điển hình là nghiên cứu phát hiện các điểm bất thường của AnomReason [26]. Theo đó, hệ thống cung cấp thông tin về các điểm bất thường có trong ảnh kèm các giải thích chi tiết. Tuy nhiên, các giải thích này lại gặp khó khăn khi ảnh chứa nhiều chi tiết hoặc vật thể nhập nhằng, xem thêm ví dụ trong <Ảnh minh họa caption phân tích rõ sai ở điểm nào>. Điều này gây ra sự sai lệch và gây khó hiểu cho người dùng trong quá trình kiểm định các kết luận từ mô hình. Vì vậy, đề tài dự kiến tích hợp cơ chế định vị dấu vết vào quá trình phát hiện và lý giải thông qua các công cụ như khung giới hạn (bounding box) hoặc mặt nạ (mask).

4.3 Nội dung 3: Xây dựng cơ chế biểu diễn và suy luận bằng chứng một cách có cấu trúc

Sau khi phát hiện và định vị các dấu vết trên ảnh, đề tài hướng đến việc biểu diễn các thông tin thu được dưới dạng có cấu trúc rõ ràng, có thể kiểm tra và suy luận được, thay vì chỉ chuyển toàn bộ thông tin vào một mô hình để đưa ra kết luận cho người dùng. Do các phương pháp hiện nay thường biểu diễn ảnh dưới dạng các đặc trưng trong các không gian ẩn khiến việc xác định chính xác mô hình phân loại đang dựa vào thông tin nào để đưa ra quyết định trở nên khó khăn và khó diễn giải.

Vì vậy, đề tài hướng đến nghiên cứu một cách biểu diễn bằng chứng có cấu trúc,

trong đó, các thông tin quan sát được từ ảnh sẽ được chuyển thành các thành phần có ý nghĩa rõ ràng. Mục tiêu của nội dung này là chuyển quá trình từ mô hình nhìn ảnh và đưa ra một kết luận khó kiểm chứng thành mô hình quan sát các thuộc tính, hình thành các mệnh đề bằng chứng và suy luận từ các mệnh đề đó.

5 Kế hoạch nghiên cứu

Luận án được triển khai trong 04 năm và được trình bày chi tiết trong Bảng 1.

Bảng 1. Kế hoạch nghiên cứu dự kiến

Năm	Nội dung nghiên cứu	Kết quả dự kiến
1	Khảo sát và hệ thống hóa các loại dấu vết tạo sinh.	Xây dựng hệ thống phân loại các nhóm bằng chứng phục vụ phát hiện, lý giải.
2	Xây dựng các bộ phát hiện bằng chứng theo nhiều góc nhìn và cơ chế tổng hợp bằng chứng để phân loại ảnh.	Hệ thống phát hiện ảnh thật/AI-generated dựa trên nhiều loại bằng chứng, có khả năng tổng quát trên nhiều mô hình tạo sinh.
3	Nghiên cứu định vị dấu vết và biểu diễn bằng chứng có cấu trúc; xây dựng cơ chế suy luận dựa trên các bằng chứng.	Hệ thống có khả năng xác định vị trí dấu vết và đưa ra giải thích rõ ràng, có thể kiểm chứng dựa trên bằng chứng.
4	Hoàn thiện hệ thống, đánh giá trên nhiều bộ dữ liệu và mô hình tạo sinh; nghiên cứu khả năng ứng dụng và mở rộng hệ thống.	Hoàn thiện hệ thống phát hiện–định vị–giải thích; công bố kết quả nghiên cứu và hoàn thiện luận án.

6 Tài liệu tham khảo

- [1] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. “High-resolution image synthesis with latent diffusion models”. In: *2022 IEEE/CVF conference on computer vision and pattern recognition (CVPR)*. iee. 2022, pp. 10674–10685.
- [2] James Betker, Gabriel Goh, Li Jing, Tim Brooks, Jianfeng Wang, Linjie Li, Long Ouyang, Juntang Zhuang, Joyce Lee, Yufei Guo, et al. “Improving image generation with better captions”. In: *Computer Science*. <https://cdn.openai.com/papers/dall-e-3.pdf> 2.3 (2023), p. 8.

- [3] Patrick Esser, Sumith Kulal, Andreas Blattmann, Rahim Entezari, Jonas Müller, Harry Saini, Yam Levi, Dominik Lorenz, Axel Sauer, Frederic Boesel, et al. “Scaling rectified flow transformers for high-resolution image synthesis”. In: *Forty-first international conference on machine learning*. 2024.
- [4] Mingjian Zhu, Hanting Chen, Qiangyu Yan, Xudong Huang, Guanyu Lin, Wei Li, Zhijun Tu, Hailin Hu, Jie Hu, and Yunhe Wang. “Genimage: A million-scale benchmark for detecting ai-generated image”. In: *Advances in neural information processing systems* 36 (2023), pp. 77771–77782.
- [5] Jordan J Bird and Ahmad Lotfi. “Cifake: Image classification and explainable identification of ai-generated synthetic images”. In: *IEEE Access* 12 (2024), pp. 15642–15650.
- [6] Zhenglin Huang, Jinwei Hu, Xiangtai Li, Yiwei He, Xingyu Zhao, Bei Peng, Baoyuan Wu, Xiaowei Huang, and Guangliang Cheng. “Sida: Social media image deepfake detection, localization and explanation with large multimodal model”. In: *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. 2025, pp. 28831–28841.
- [7] Yixuan Li, Xuelin Liu, Xiaoyang Wang, Bu Sung Lee, Shiqi Wang, Anderson Rocha, and Weisi Lin. “Fakebench: Probing explainable fake image detection via large multimodal models”. In: *IEEE Transactions on Information Forensics and Security* (2025).
- [8] Ziyin Zhou, Yunpeng Luo, Yuanchen Wu, Ke Sun, Jiayi Ji, Ke Yan, Shouhong Ding, Xiaoshuai Sun, Yunsheng Wu, and Rongrong Ji. “Aigi-holmes: Towards explainable and generalizable ai-generated image detection via multimodal large language models”. In: *2025 IEEE/CVF International Conference on Computer Vision (ICCV)*. IEEE. 2025, pp. 18746–18758.
- [9] Michael Yang, Shijian Deng, William T Doan, Kai Wang, Tianyu Yang, Harsh Singh, and Yapeng Tian. “Explainable AI-Generated Image Detection RewardBench”. In: *arXiv preprint arXiv:2511.12363* (2025).
- [10] Sheng-Yu Wang, Oliver Wang, Richard Zhang, Andrew Owens, and Alexei A Efros. “CNN-generated images are surprisingly easy to spot... for now”. In: *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. 2020, pp. 8692–8701.
- [11] Utkarsh Ojha, Yuheng Li, and Yong Jae Lee. “Towards universal fake image detectors that generalize across generative models”. In: *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. 2023, pp. 24480–24489.
- [12] Jonas Ricker, Denis Lukovnikov, and Asja Fischer. “Aeroblade: Training-free detection of latent diffusion images using autoencoder reconstruction error”. In: *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. 2024, pp. 9130–9140.

- [13] Huangsen Cao, Yongwei Wang, Yinfeng Liu, Sixian Zheng, Kangtao Lv, Zhi-meng Zhang, Bo Zhang, Xin Ding, and Fei Wu. “HyperDet: generalizable de-tection of synthesized images by generating and merging a mixture of hyper LoRAs”. In: *arXiv preprint arXiv:2410.06044* (2024).
- [14] Chuangchuang Tan, Yao Zhao, Shikui Wei, Guanghua Gu, Ping Liu, and Yunchao Wei. “Rethinking the up-sampling operations in cnn-based gener-ative network for generalizable deepfake detection”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*. 2024, pp. 28130–28139.
- [15] Ayush Sarkar, Hanlin Mai, Amitabh Mahapatra, Svetlana Lazebnik, David A Forsyth, and Anand Bhattad. “Shadows don’t lie and lines can’t bend! generative models don’t know projective geometry... for now”. In: *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. IEEE. 2024, pp. 28140–28149.
- [16] Yunfeng Diao, Naixin Zhai, Changtao Miao, Zitong Yu, Xingxing Wei, Xun Yang, and Meng Wang. “Vulnerabilities in ai-generated image detection: The challenge of adversarial attacks”. In: *IEEE Transactions on Multimedia* (2026).
- [17] Patrick PK Chan, Chuanxin Zhang, Haitao Chen, Jingwen Deng, Xiao Meng, and Daniel S Yeung. “Evasion on general GAN-generated image detection by disentangled representation”. In: *Information Sciences* 683 (2024), p. 121267.
- [18] Chuangchuang Tan, Xiang Ming, Jinglu Wang, Renshuai Tao, Bin Li, Yun-chao Wei, Yao Zhao, and Yan Lu. “Semantic visual anomaly detection and reasoning in ai-generated images”. In: *International Conference on Learning Representations*. Vol. 2026. 2026, pp. 111907–111942.
- [19] Davide Alessandro Coccomini, Andrea Esuli, Fabrizio Falchi, Claudio Gen-naro, and Giuseppe Amato. “Detecting images generated by diffusers”. In: *PeerJ Computer Science* 10 (2024), e2127.
- [20] Ouxiang Li, Jiayin Cai, Yanbin Hao, Xiaolong Jiang, Yao Hu, and Fuli Feng. “Improving synthetic image detection towards generalization: An image trans-formation perspective”. In: *Proceedings of the 31st ACM SIGKDD conference on knowledge discovery and data mining v. 1*. 2025, pp. 2405–2414.
- [21] Negar Kamali, Karyn Nakamura, Aakriti Kumar, Angelos Chatzimparmpas, Jessica Hullman, and Matthew Groh. “Characterizing photorealism and arti-facts in diffusion model-generated images”. In: *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*. 2025, pp. 1–26.
- [22] Aref Tabatabaei, Zahra Dehghanian, and Maryam Amirmazlaghani. “Beyond Imperfections: A Conditional Inpainting Approach for End-to-End Artifact Removal in VTON and Pose Transfer”. In: *arXiv preprint arXiv:2410.04052* (2024).

- [23] Quentin Bammey. “Synthbuster: Towards detection of diffusion model generated images”. In: *IEEE Open Journal of Signal Processing* 5 (2023), pp. 1–9.
- [24] Yan Hong, Jianming Feng, Haoxing Chen, Jun Lan, Huijia Zhu, Weiqiang Wang, and Jianfu Zhang. “Wildfake: A large-scale and hierarchical dataset for ai-generated images detection”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 39. 4. 2025, pp. 3500–3508.
- [25] Yu Cao et al. “SynArtifact: A Comprehensive Dataset and Visual-Language Model for AI-Generated Artifact Classification”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. 2024.
- [26] J. Smith, A. Doe, et al. “AnomReason: Semantic Visual Anomaly Detection and Reasoning in AI-Generated Images”. In: *arXiv preprint* (2024).